NICO2AI
パイロット講義 #7

畳み込みニューラルネットワーク(1)

17/08/21

土屋祐一郎

前回：全結合NN

例: 3 layers perceptron

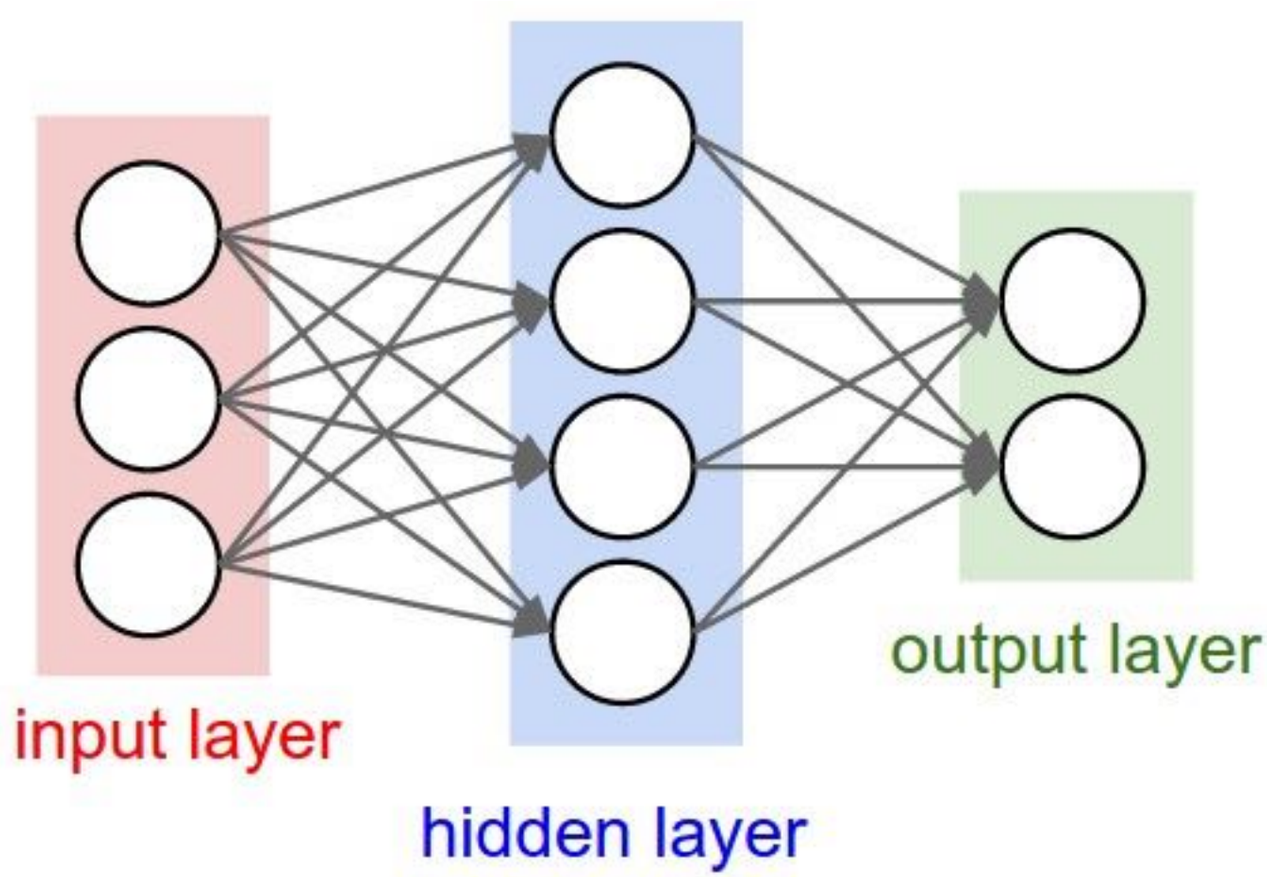

http://cs231n.github.io/assets/nn1/neural_net.jpeg

MLPをより高性能にしたい

- MLPは万能の関数近似器

  (universal function approximator)
  - 十分な数のパラメータ（＝ニューロン結合）があれば、

    任意の関数を任意の精度で近似できる
- →層の数を増やそう！ (Getting deeper!)
  - 浅いネットワークでニューロン数を増やすより効率が

    良い[Larochelle et al., 2007][Bengio, 2009][Delalleau and Bengio, 2011]
    - （単純なケース以外では証明されていない）

Getting deeper, but…

- 層の数を増やせば性能は上がるはず
  - 「“適切な”パラメータを見つけられれば」…
- しかし、現実にはうまくいかない…
  - 学習がうまくいかない

全結合NNをDeepにするときの問題

- 過学習
  - パラメータ多すぎ
- 学習が進まない
  - パラメータ多すぎ
- 計算が重い
  - パラメータ多すぎ

画像への適用時の問題

- 水平移動に弱い
- 回転に弱い
- affine transformに弱い

Convolutional Neural Networks

- 画像認識タスクへの適用が最初のブレイクスルー
- 近年は自然言語処理への適用も

Convolutional Neural Networks 概観

Convolutional Neural Networks 概観

- いきなりですが、最初に、

  Convolutional Neural Networks (CNN)
  がどういうものかざっくり説明します
- その後、
  - CNNがどうして全結合NNの問題を解決しているのか
  - 生物の視神経との関連はどうなっているのか
  - などについて話します

Convolution = Filtering

例：ラプラシアンフィルタ

1	1	1
1	−8	1
1	1	1

畳み込み(convolution)!

Filtering = ピクセルごとの乗算→加算

例：

0×0 + 0×0 + 0×0
+ (-0.5)×0 + 0×0 + 0.5 × 1
+ 0×0 + 0×0 + 0×1
= 0.5

0	0	0
-0.5	0	0.5
0	0	0

を適用

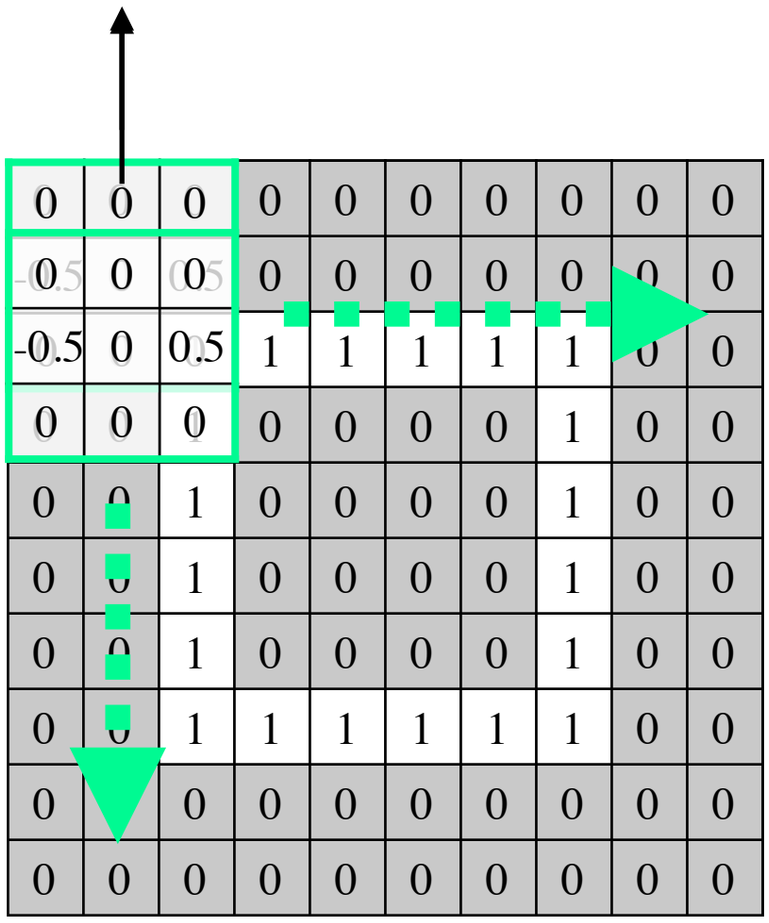

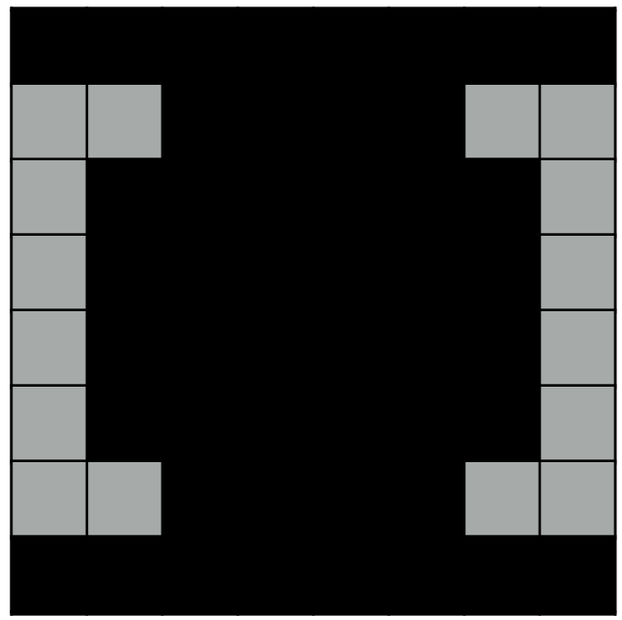

Convolution = Filtering

例：ラプラシアンフィルタ

1	1	1
1	−8	1
1	1	1

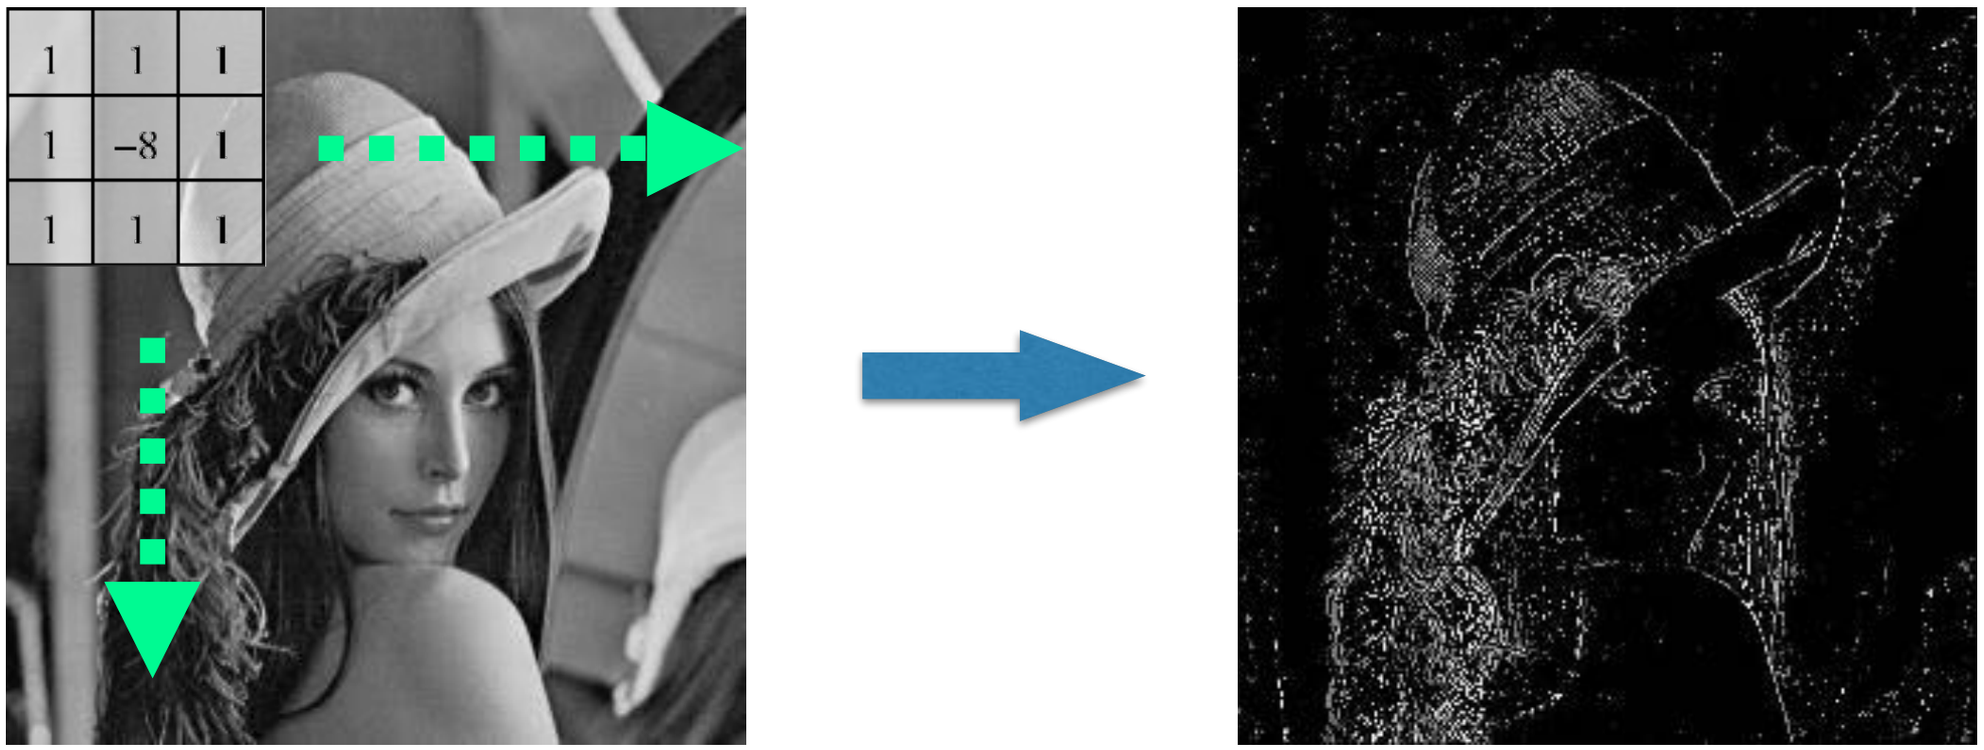

2D convolution

適当に学習されたフィルタ

0.01	-0.12	1.03
-1.11	0.12	-0.56
0.32	-0.34	-0.22

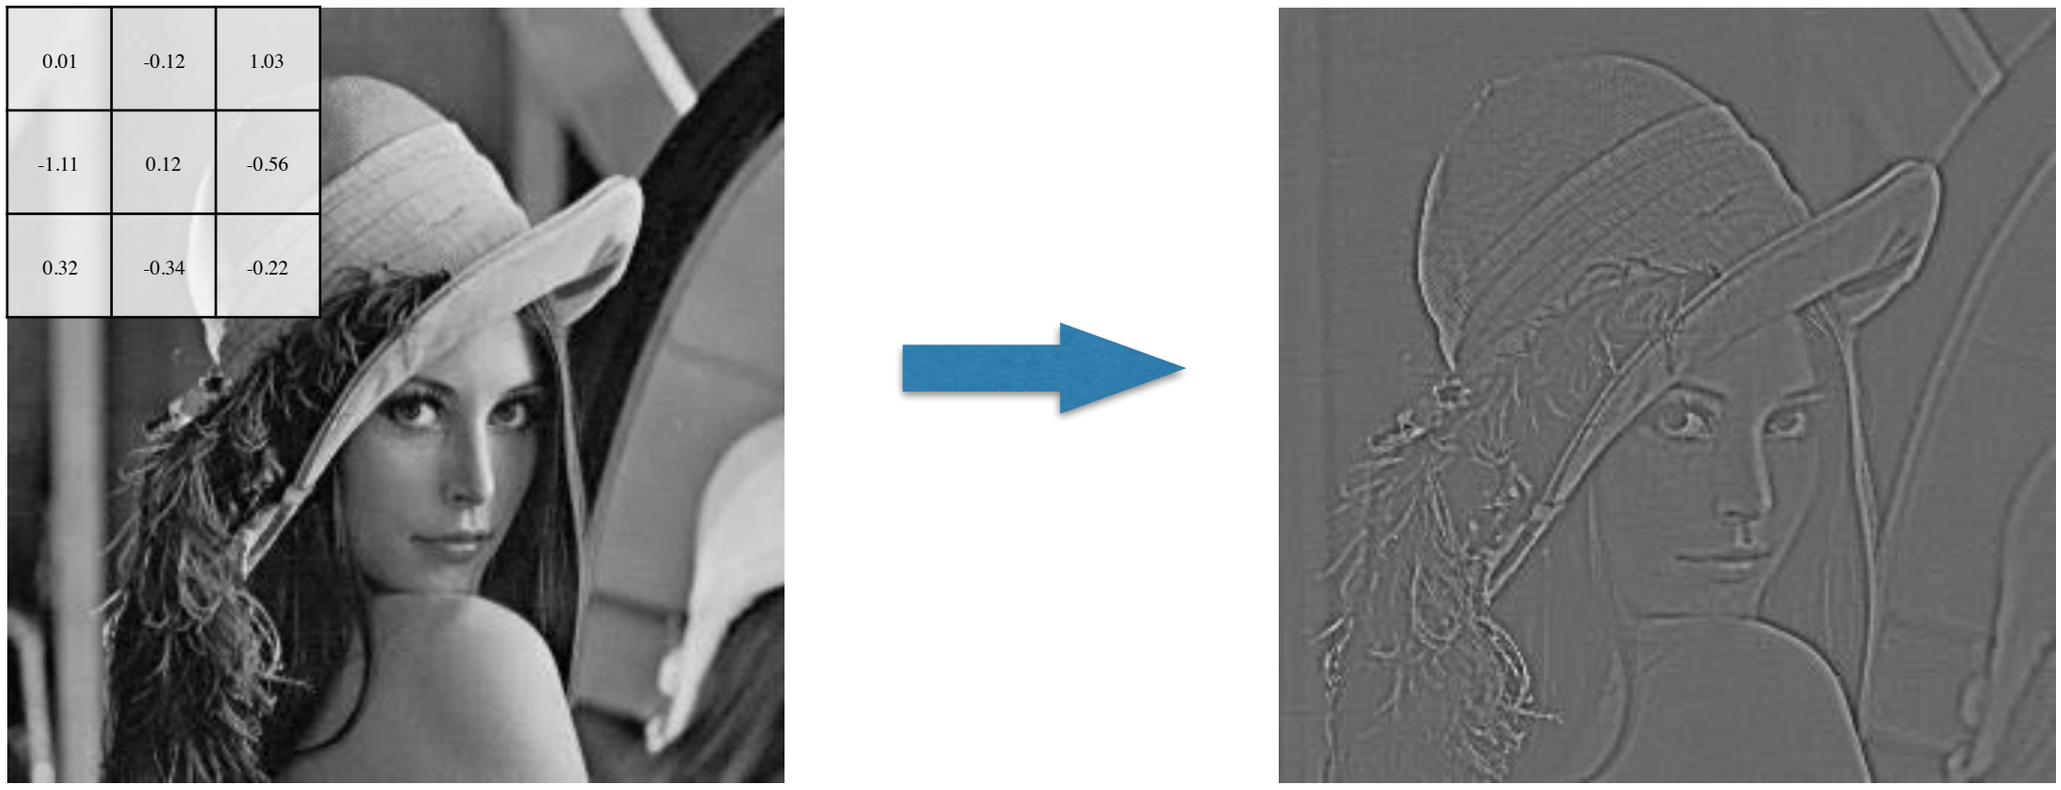

3D Convolution

適当に学習されたフィルタ for R,G,B

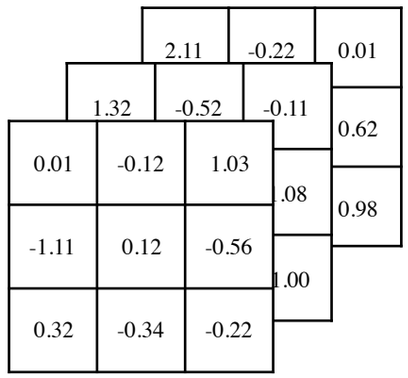

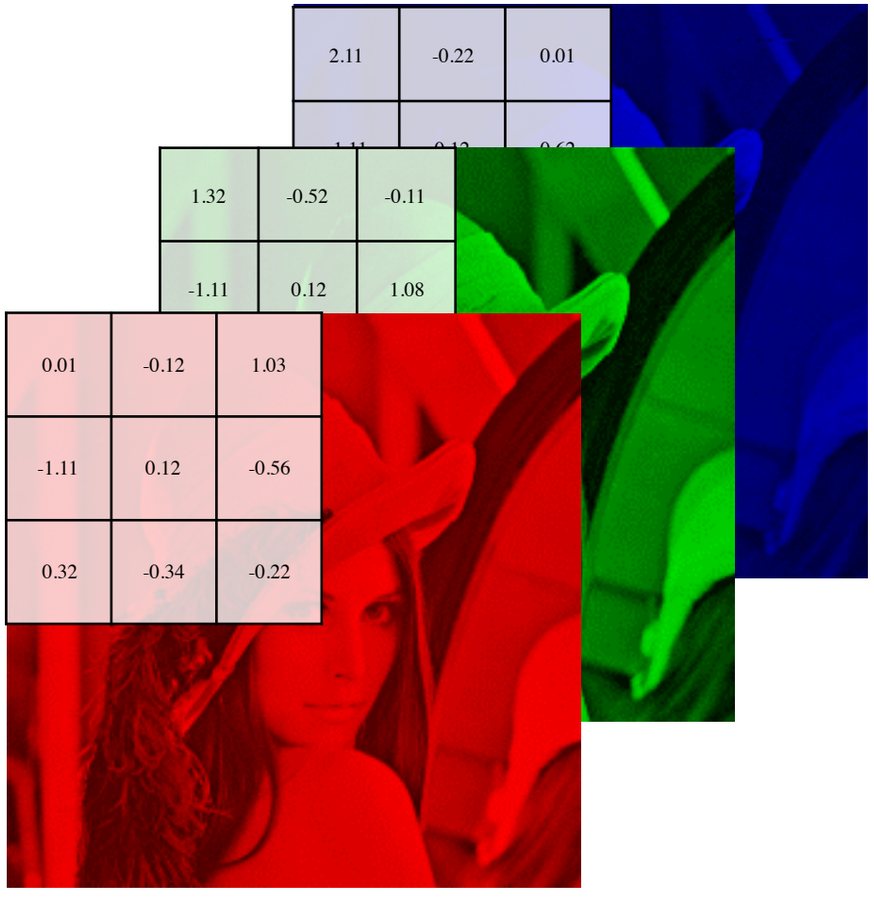

3D Convolution

適当に学習されたフィルタ for R,G,B

＝適当に学習された3次元フィルタ

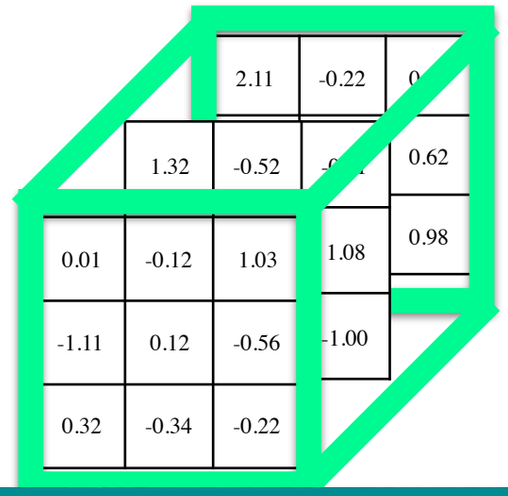

3次元データに3次元フィルタを畳み込んで2次元出力を得る処理

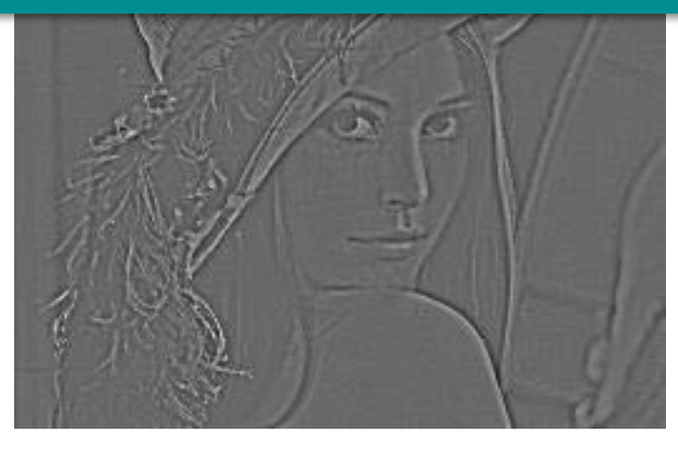

+ b

4D Convolution

適当に学習された3次元フィルタ×複数個

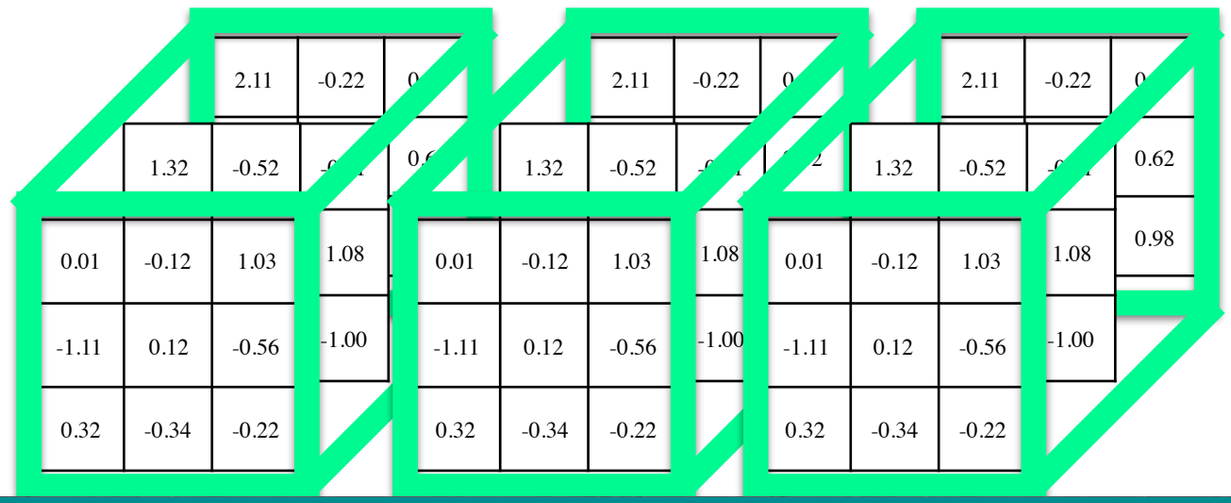

「3次元データに3次元フィルタを畳み込んで2次元出力を得る処理」を複数回行って、3次元出力を得る処理

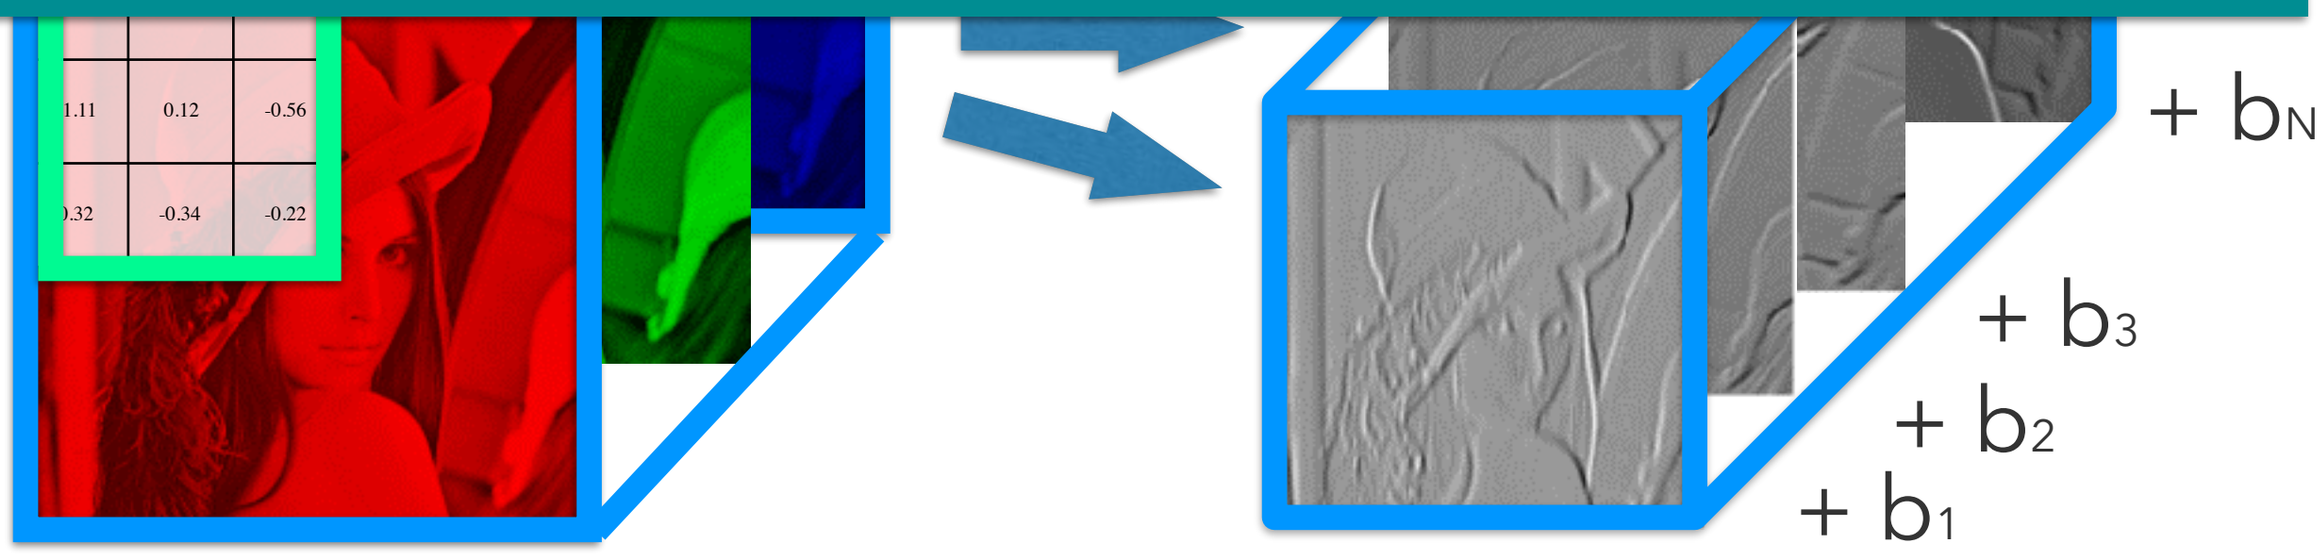

4D convolution

簡略化して書くと…

「3次元データに4次元フィルタを畳み込んで3次元出力を得る」のがCNNの基本処理

Convolutional Neural Networks

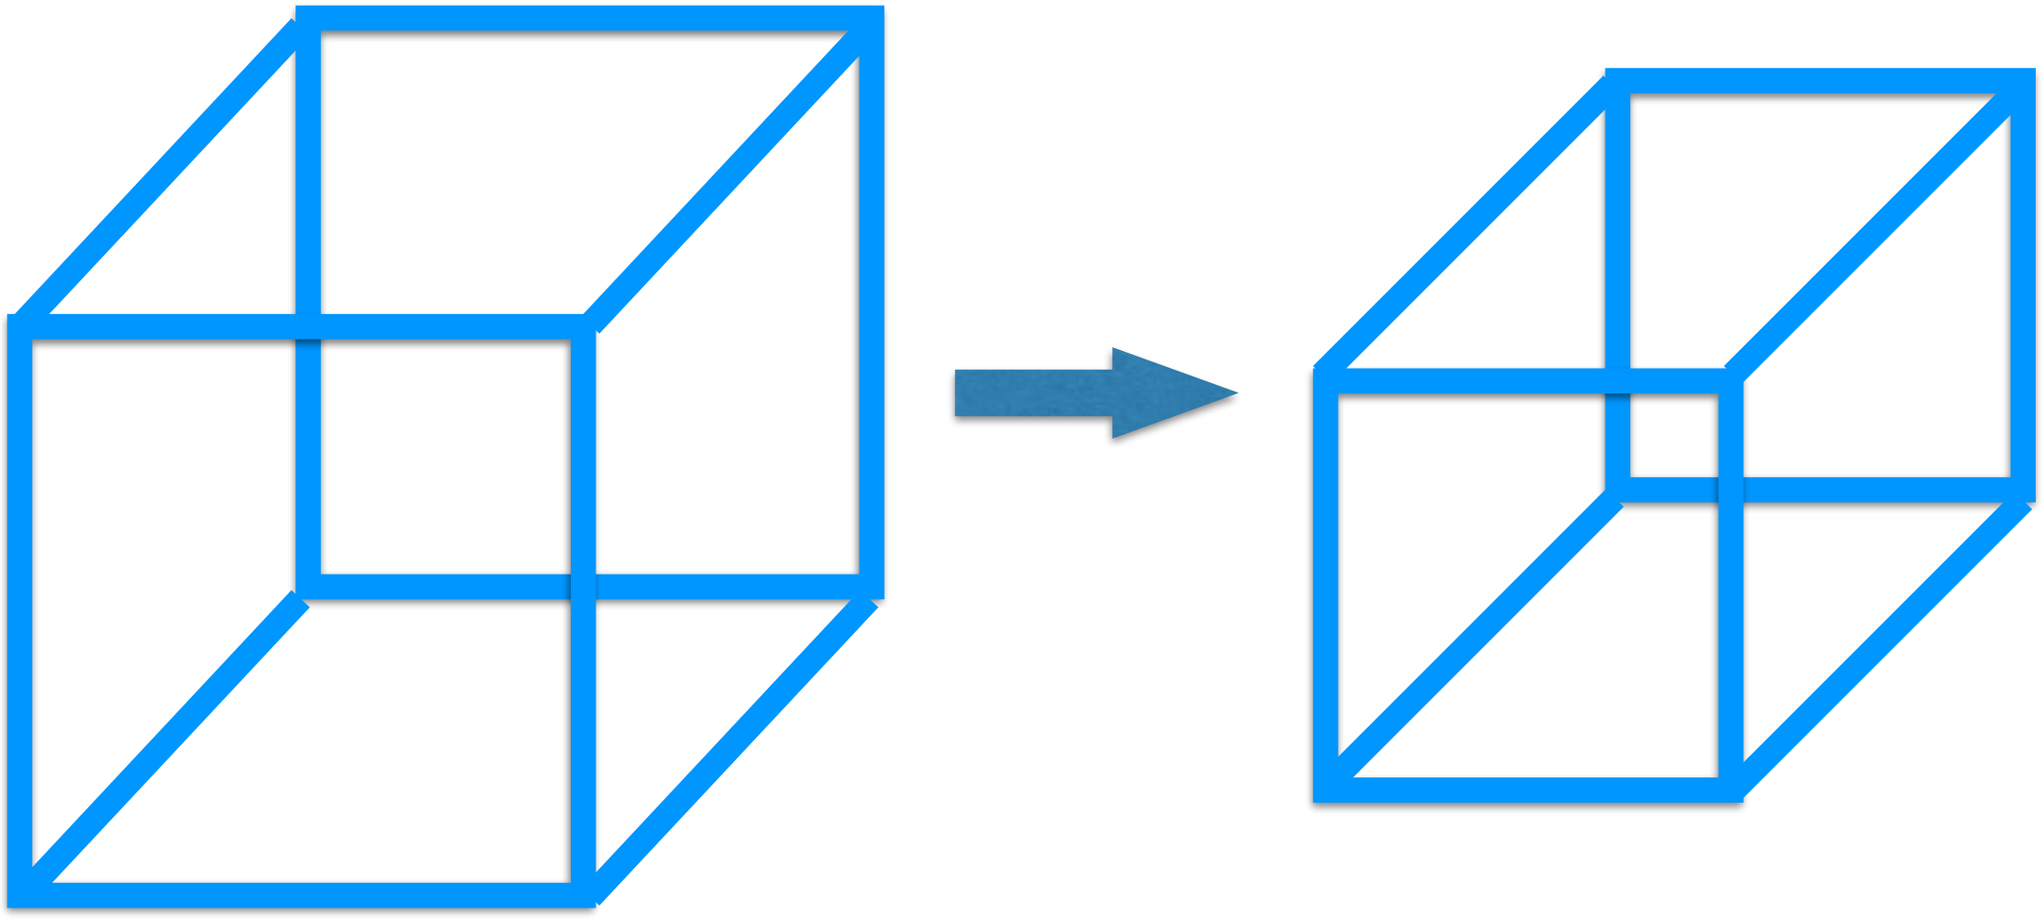

をたくさん繋げて...

Deep convolutional neural networks

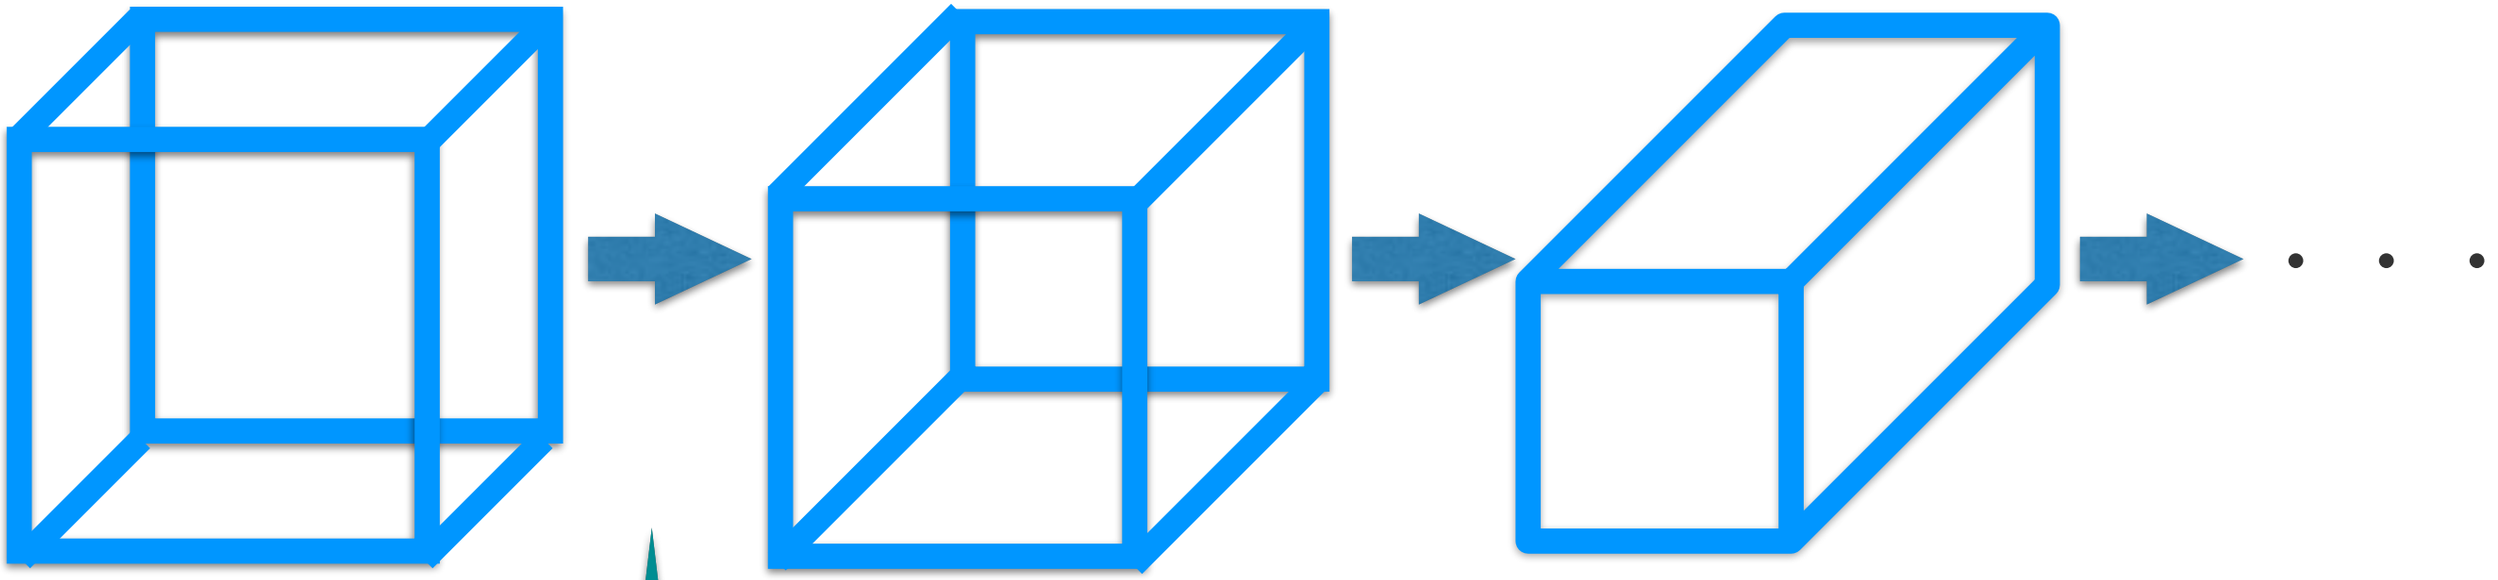

"Convolutional Layer"

AlexNet

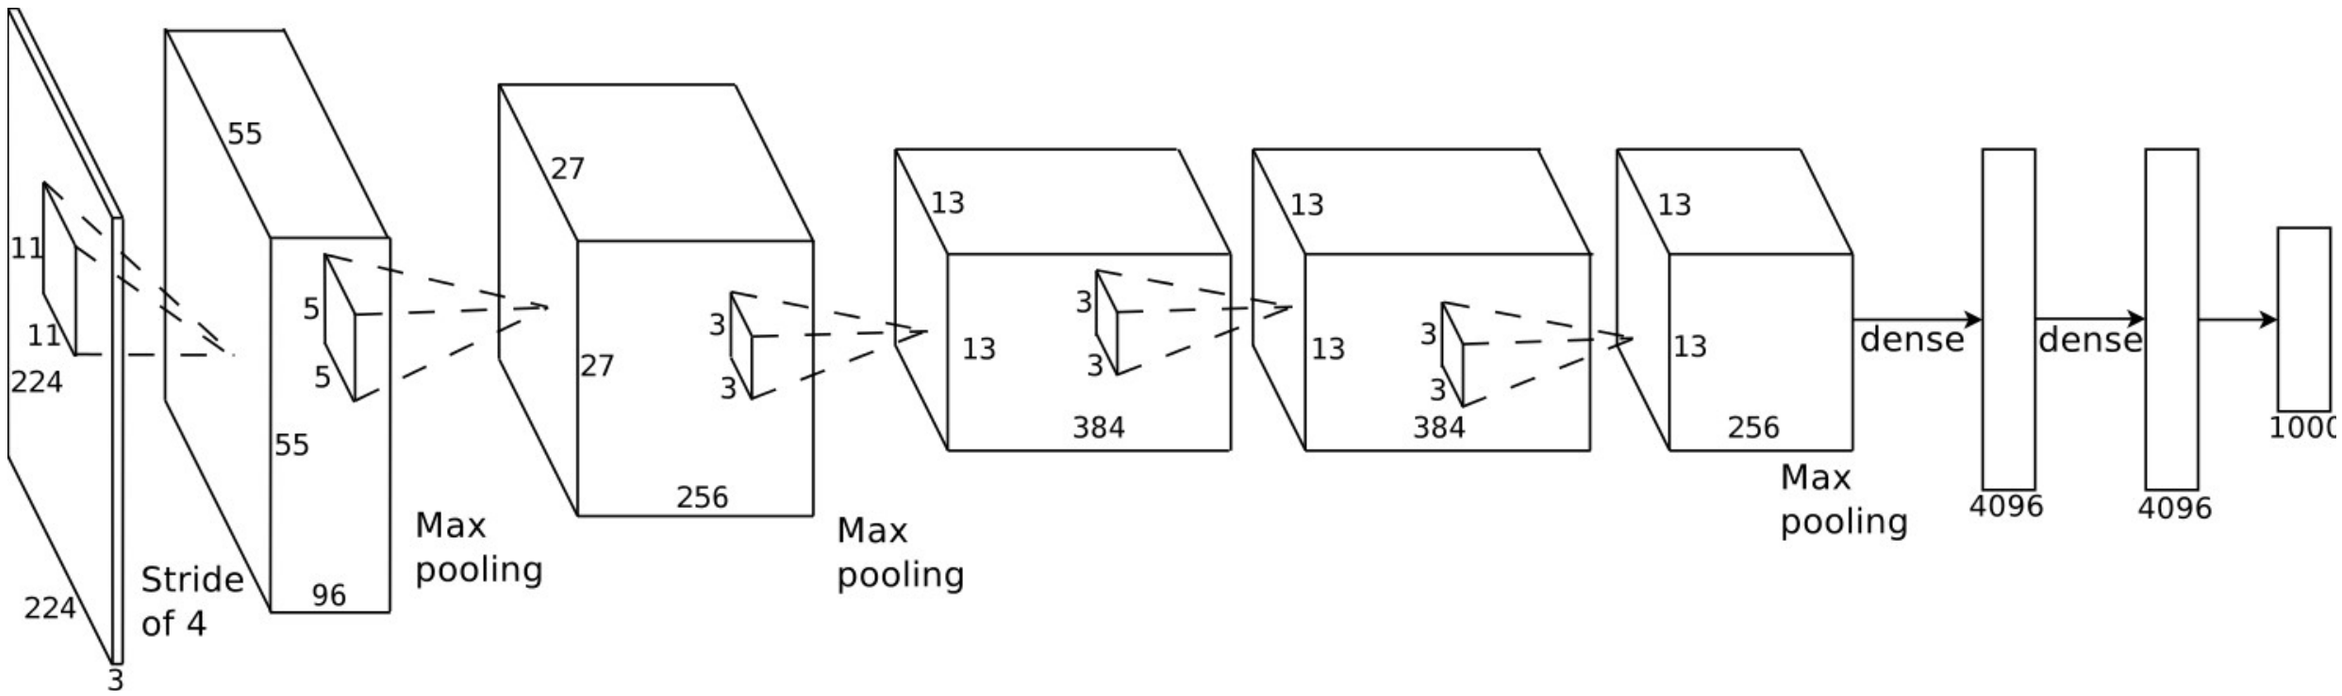

Krizhevsky et.al., 2012

大規模画像認識コンペティションILSVRC2012で優勝

Deep Learningブームの火付け役

DCNN各層のハイパーパラメータ

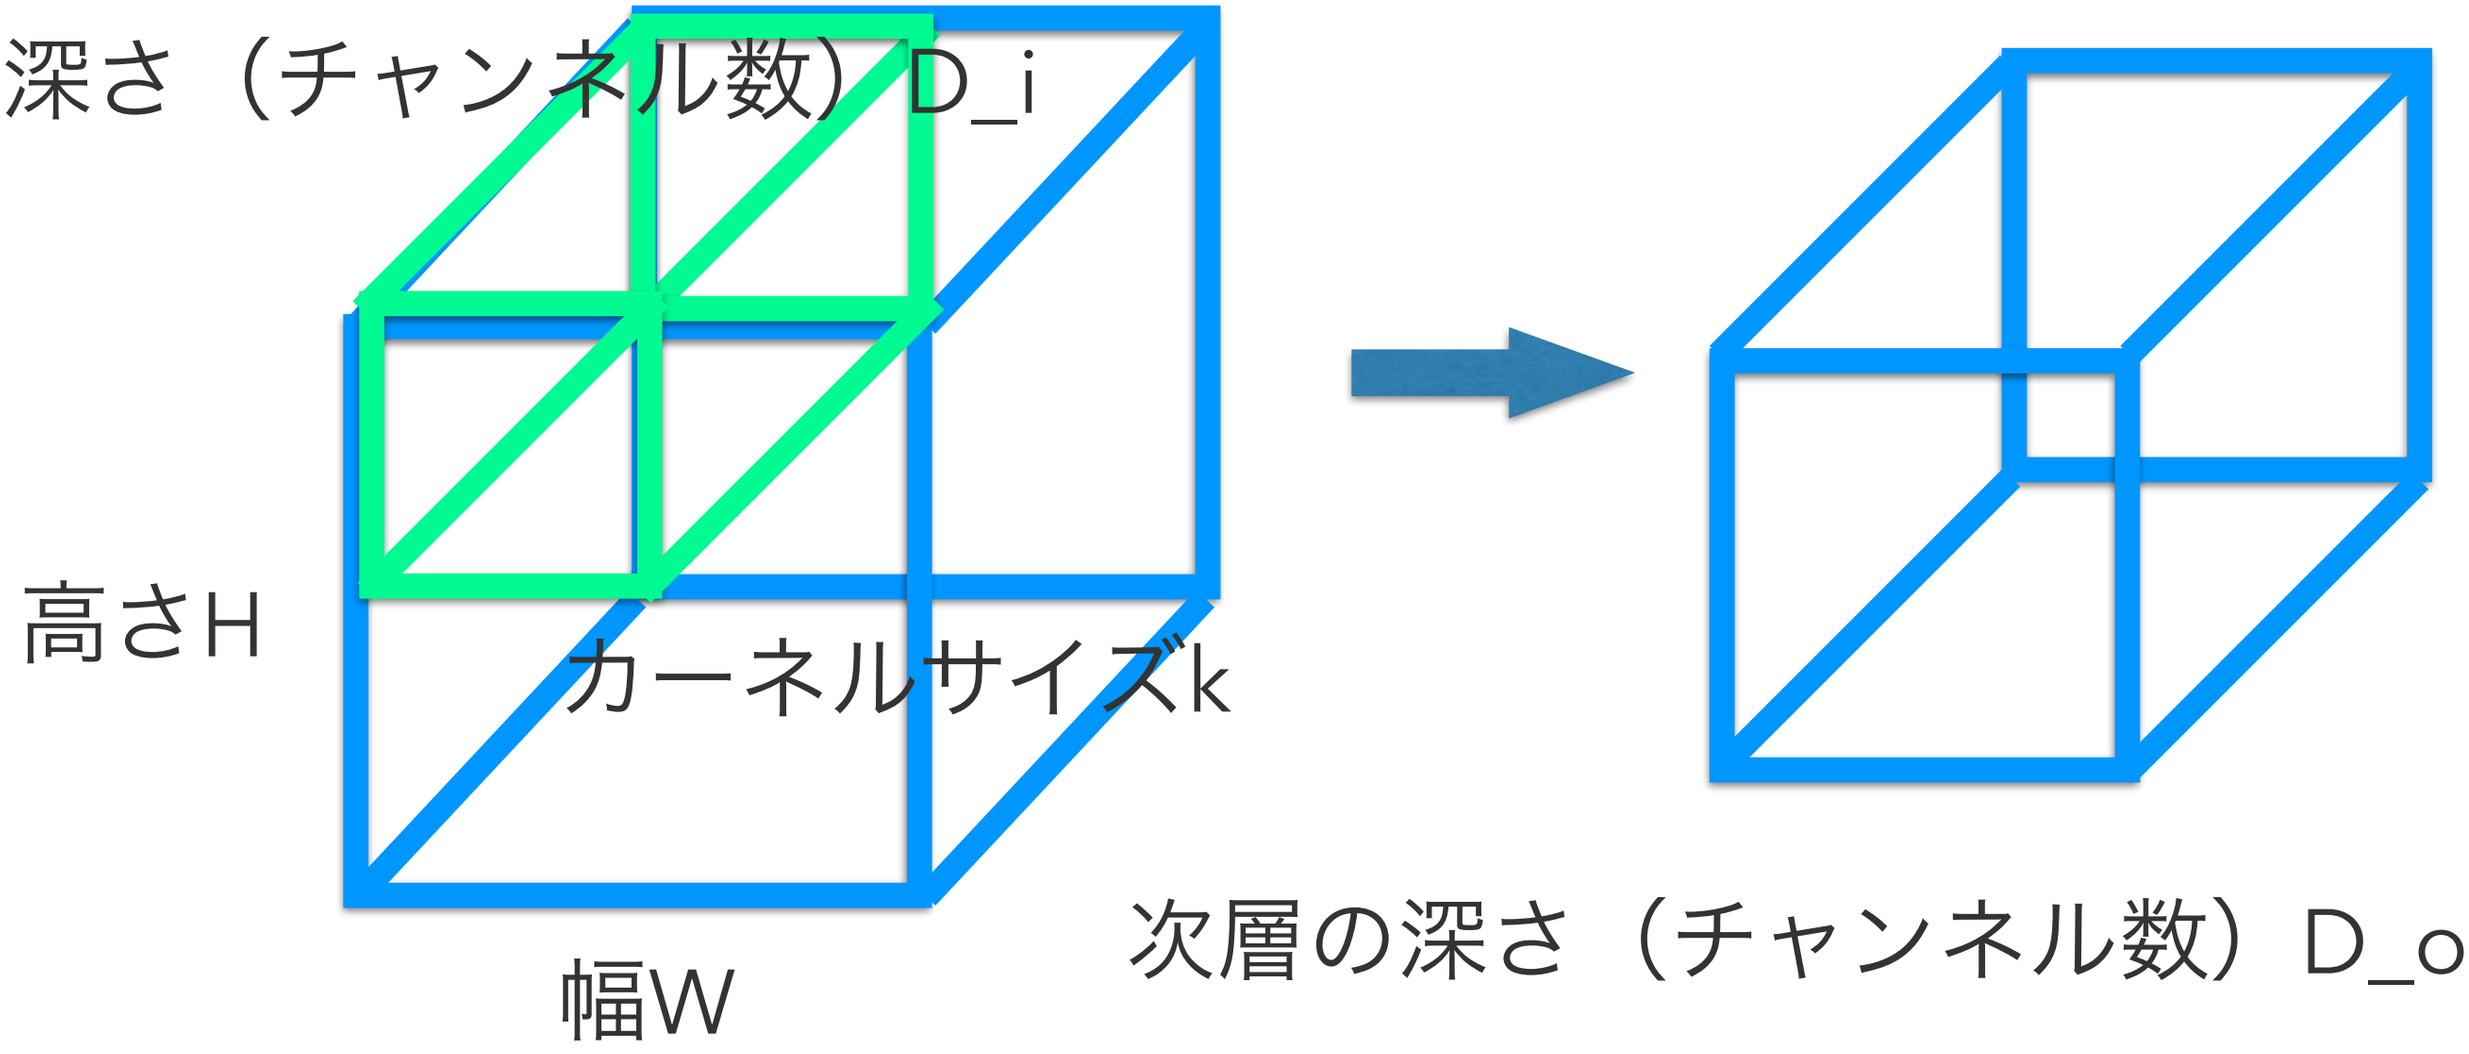

2層目以降のW, Hは、

その前の層のW, H, kから決まる

ここまでのまとめ

- Convolutional Neural Networks
  =Convolutional Layer (畳み込み層)を繋げたタイプの
  ニューラルネットワーク
- Convolution=畳み込みは、フィルタ演算！
- ただし、2次元画像へのフィルタ適用と違って、
  深さ方向も考える

Convolutional Neural Networksの細かい話

Stride

Stride = フィルタを何ピクセルずつずらしていくか

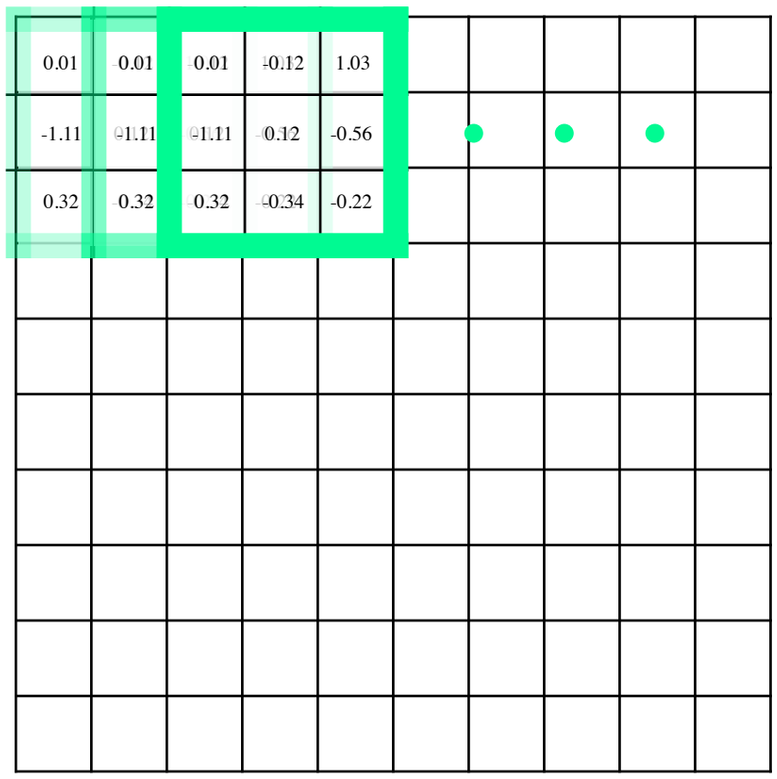

stride=1

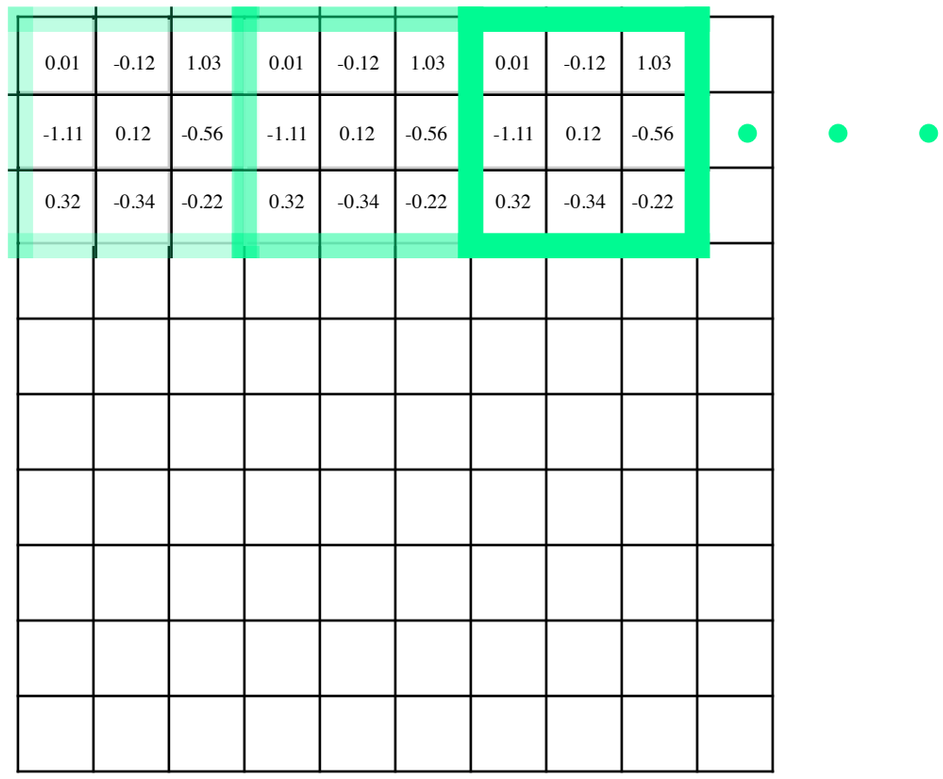

stride=3

Padding

Padding = 入力の上下左右をゼロで埋めて広げる

→画像のエッジ部分の情報を適切に扱えるようになる

例：padding=2

0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0
0	0	101	148	156	129	179	168	20
0	0	130	149	176	198	139	189	11

（再掲）DCNN各層のハイパーパラメータ

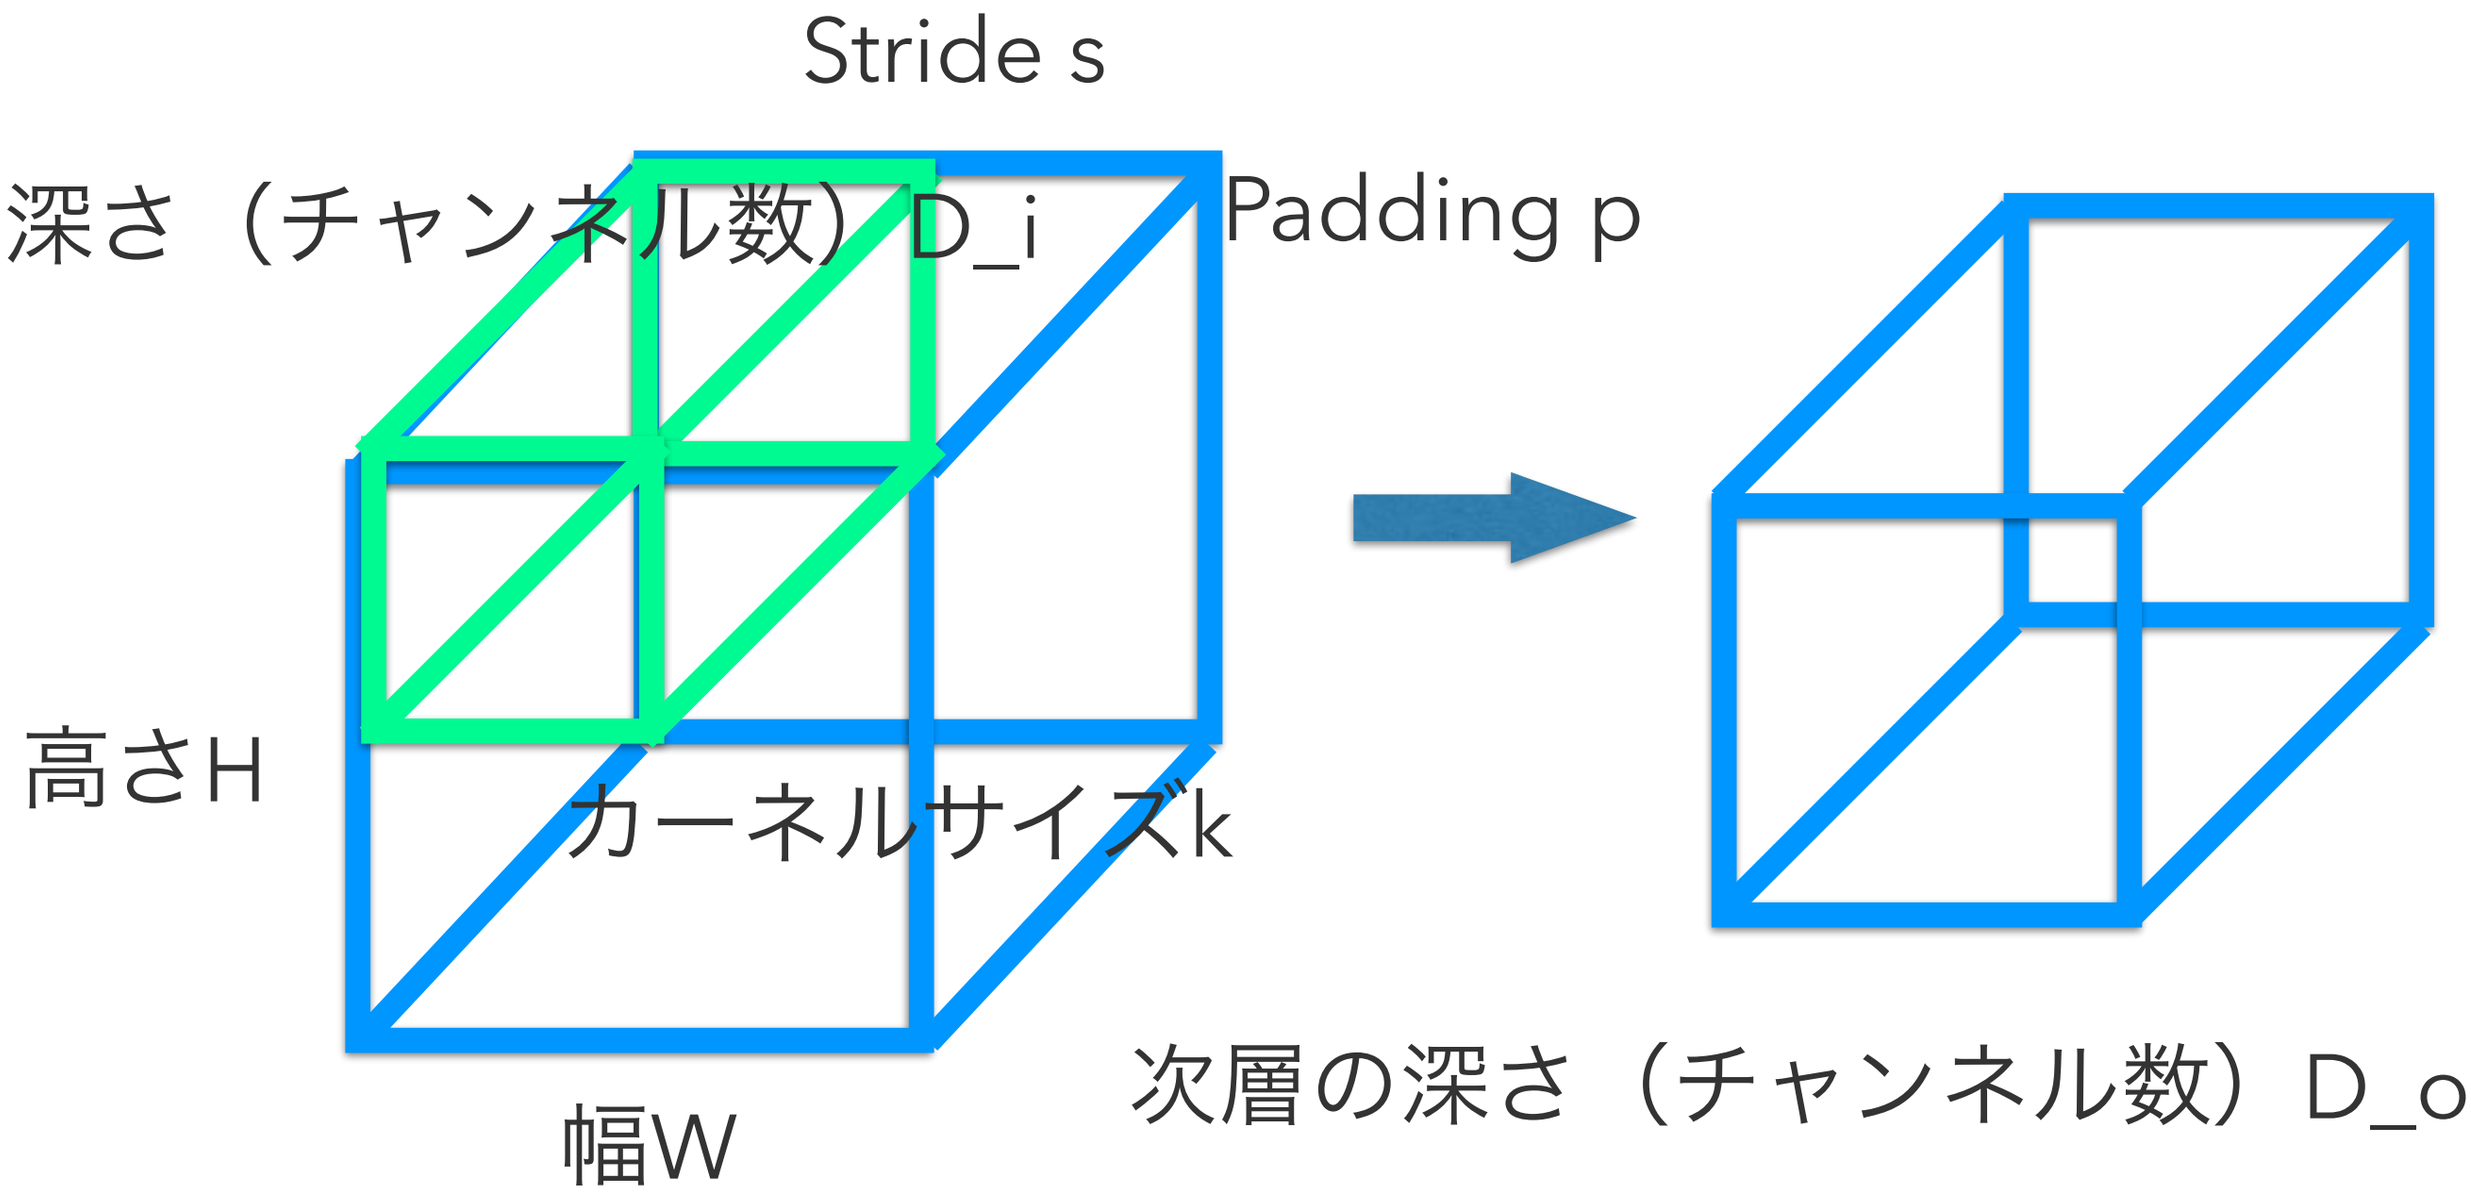

2層目以降のW, Hは、

その前の層のW, H, kから決まる

活性化関数

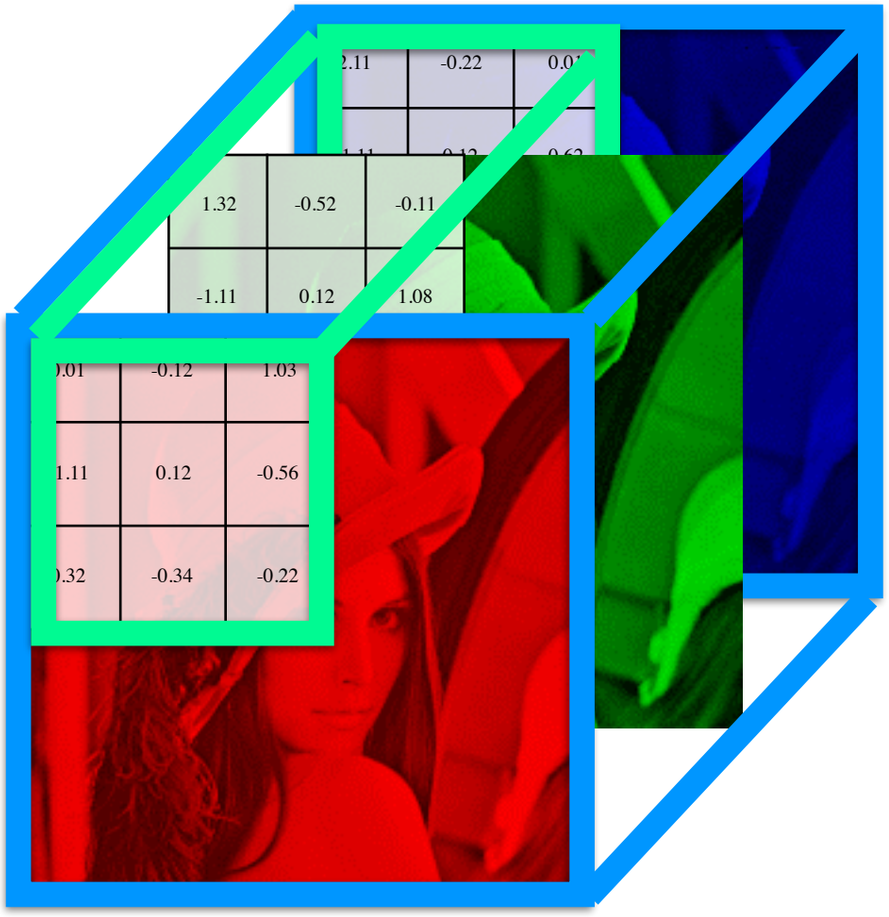

$$f(x)$$

- Sigmoid
- tanh
- ReLU

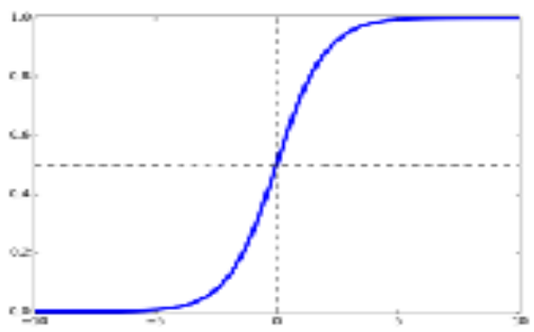

sigmoid

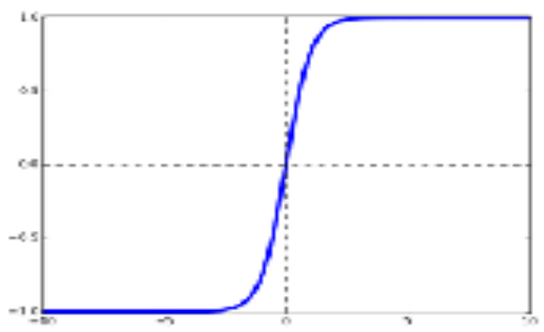

tanh

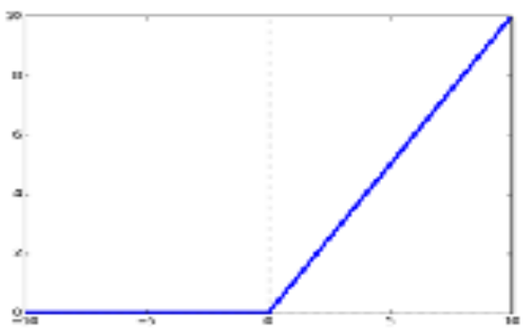

ReLU

https://thinkit.co.jp/sites/default/files/639904.png

Convolutional layer以外のlayer

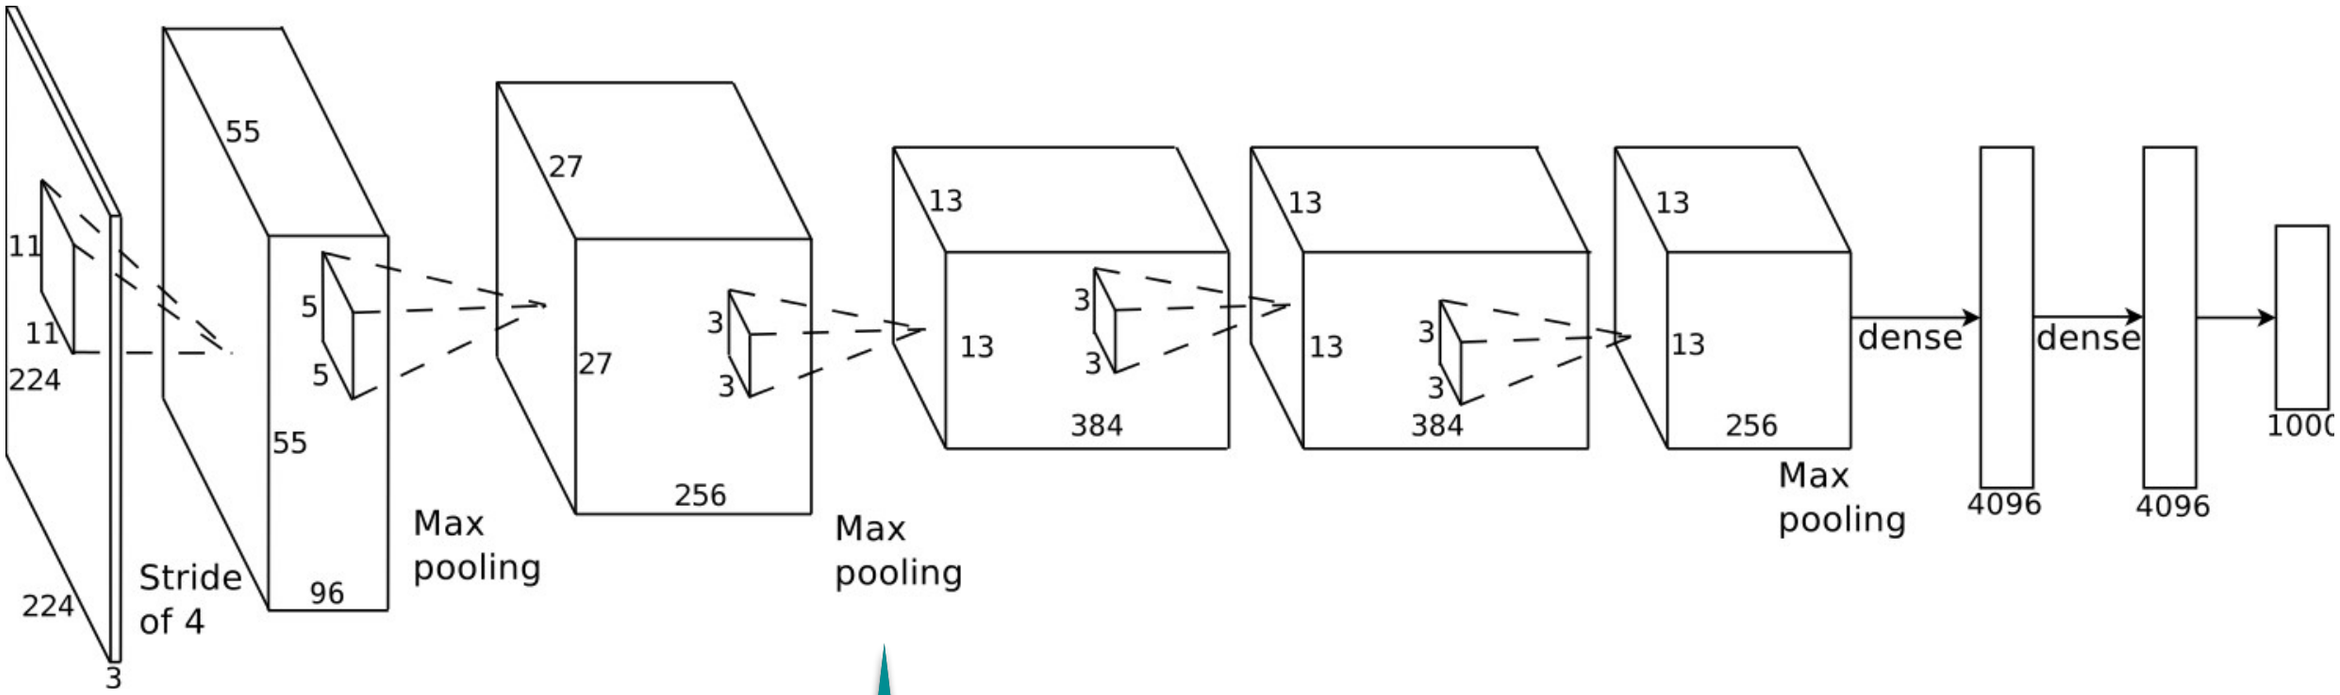

“Max pooling”

Max pooling

前の層にmax()フィルタをかける

=適用範囲のうち、最大値のみをとり、残りを切り捨てる

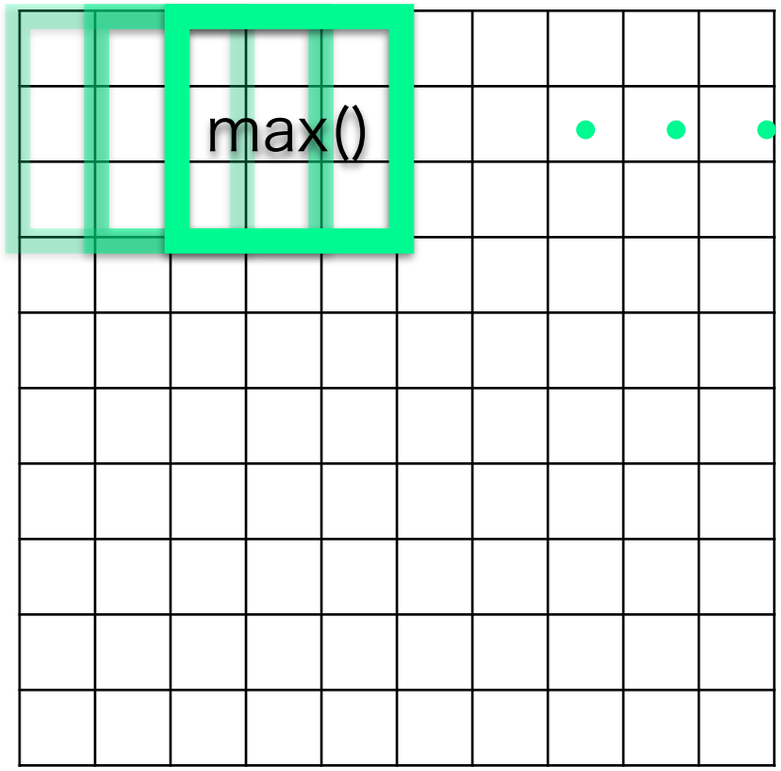

ハイパーパラメータ：

- カーネルサイズk
- Stride s

例: k=2, s=2

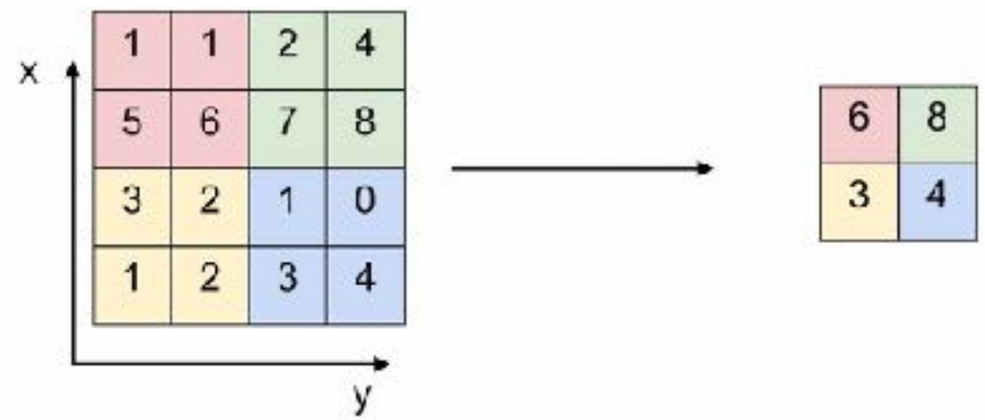

Pooling layer

- Max poolingの他にもいろいろ提案されている
  - Average pooling
- まとめてPooling layerと言ったりする

Convolutional layer以外のlayer

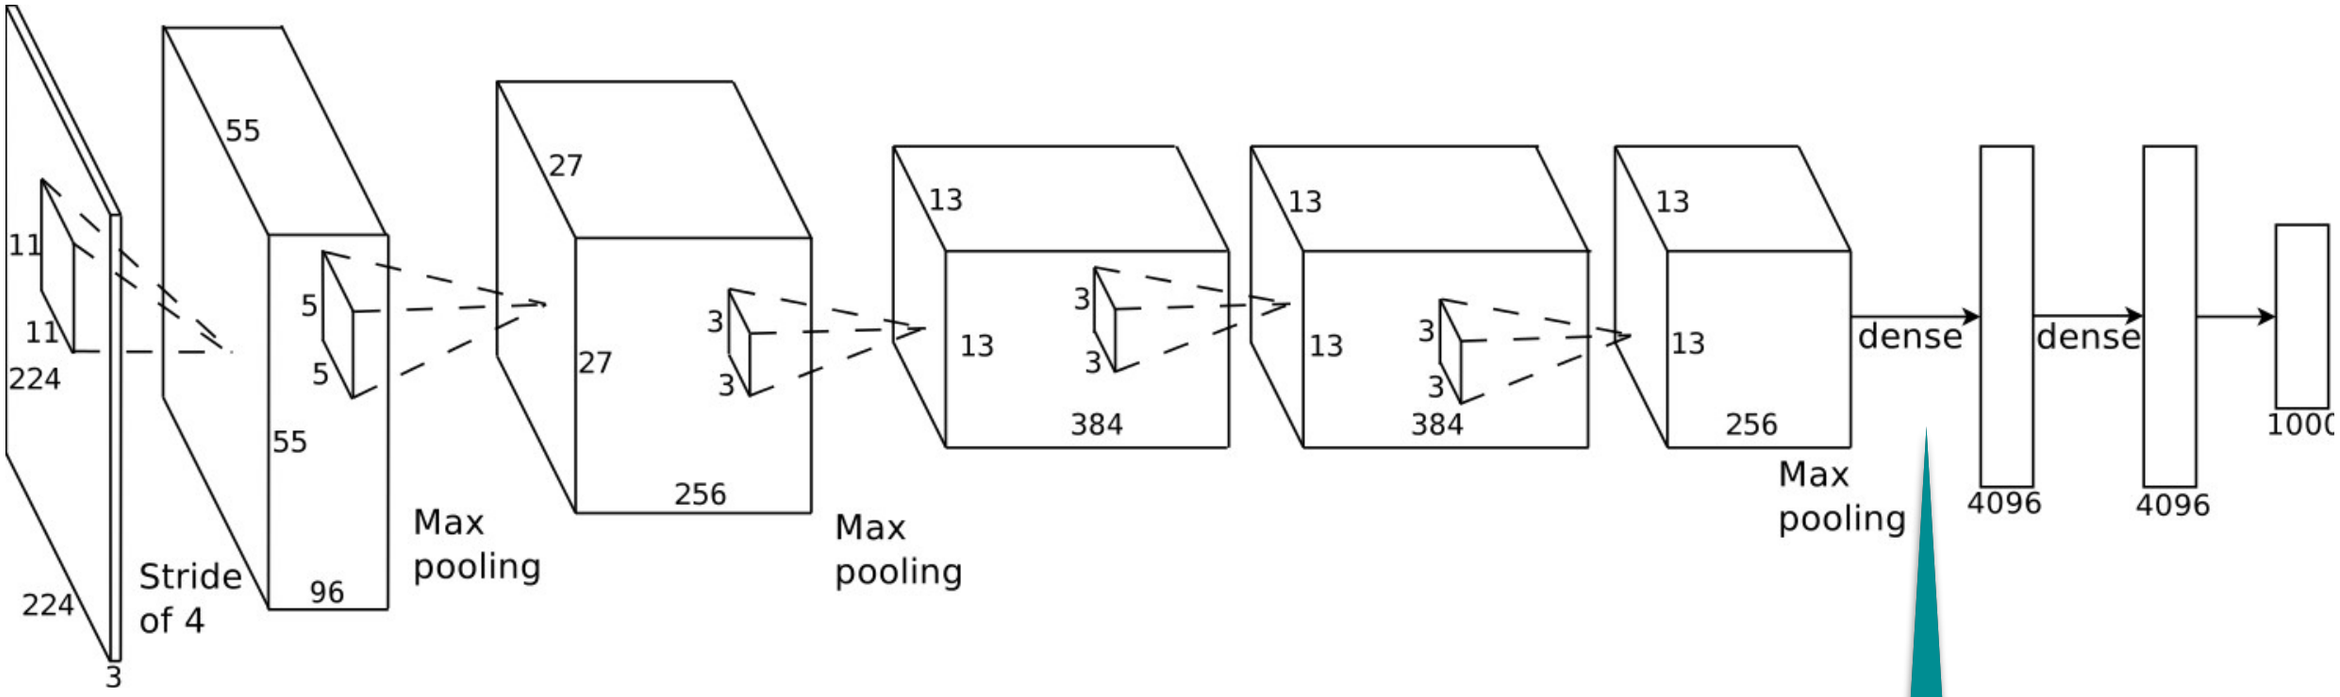

“Dense”

全結合層

- 普通の全結合NNを

  Convolutional Layerの後にくっつけることがよくある

- Dense connected layerと言ったりする

- Convolutional Layerの出力は(W, H, D)の3次元配列

  →(W×H×D)の1次元配列にflattenして入力にする

  (chainerだと気にしなくても良しなにやってくれる)

CNNの学習

誤差逆伝播 Back propagation

- CNNの学習もBPによって行う
- Convolutional Layer
  - 前の層の影響するピクセルに誤差を蓄積させていく
    - 逆畳み込みのような感じ
- Pooling Layer
  - 前の層の影響するピクセルを覚えておいて、

    誤差を逆伝播させる
- (chainerが良しなにやってくれます)

CNNの性能を上げるための様々なテクニック

Data augmentation

- CNN自体は、

  回転不変性・鏡像不変性・affine変換不変性

  などの特性は持っていない

- →学習データを回転・反転・変形などして使うことで、

  これらの変換に対応する

- データ量が増え、過学習抑止効果も

Dropout

- 学習時、ニューロンを一定の確率pで無視する
- 推論時は全てのニューロンを使い、結合重みをp倍する
- 同時に複数のネットワークを学習し、平均を取ったの
と似た効果が得られる（アンサンブル学習）

→正則化と同様の効果＝過学習耐性

Mean normalization

- データセット全体のRGB毎のピクセル値の平均を計算しておき、入力画像から引く
  - 各(x,y)座標毎に平均をとったり、
    x,yは無視して画像全体で平均をとったり

Local Response Normalization (LRN)

- 正規化の一種（他にも色々ある）
- AlexNetにおいては結構重要らしい

「同一位置(ピクセル)において

複数の特徴マップ間で正規化する」

$$b^i_{x,y} = a^i_{x,y} / \left(k + \alpha \sum_{j=max(0,i-\frac{n}{2})}^{min(N-1,i+\frac{n}{2})} (a^j_{x,y})^2 \right)^{\beta}$$

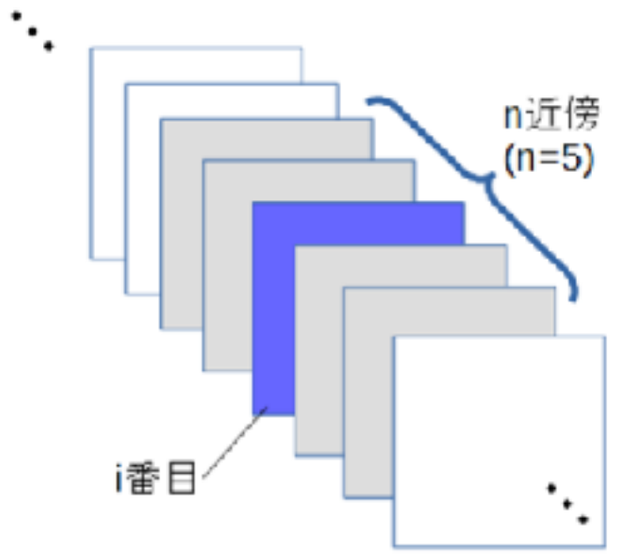

参考) http://may46onez.hatenablog.com/entry/2016/01/08/142843

CNNの定性的な特徴

CNNの定性的な特徴

- パラメータ数が少ない
  - Weight sharing
    - 同じ重み(フィルタ)を複数領域で共有
    - 対象ドメイン（画像）のlocalityが前提
    - 過学習しづらい
    - 計算が楽
- 平行移動不変性
  - pooling

フィルタの自動獲得

CNNを学習させると、

識別に有効なフィルタが自動的に獲得される

AlexNetの1層目の可視化

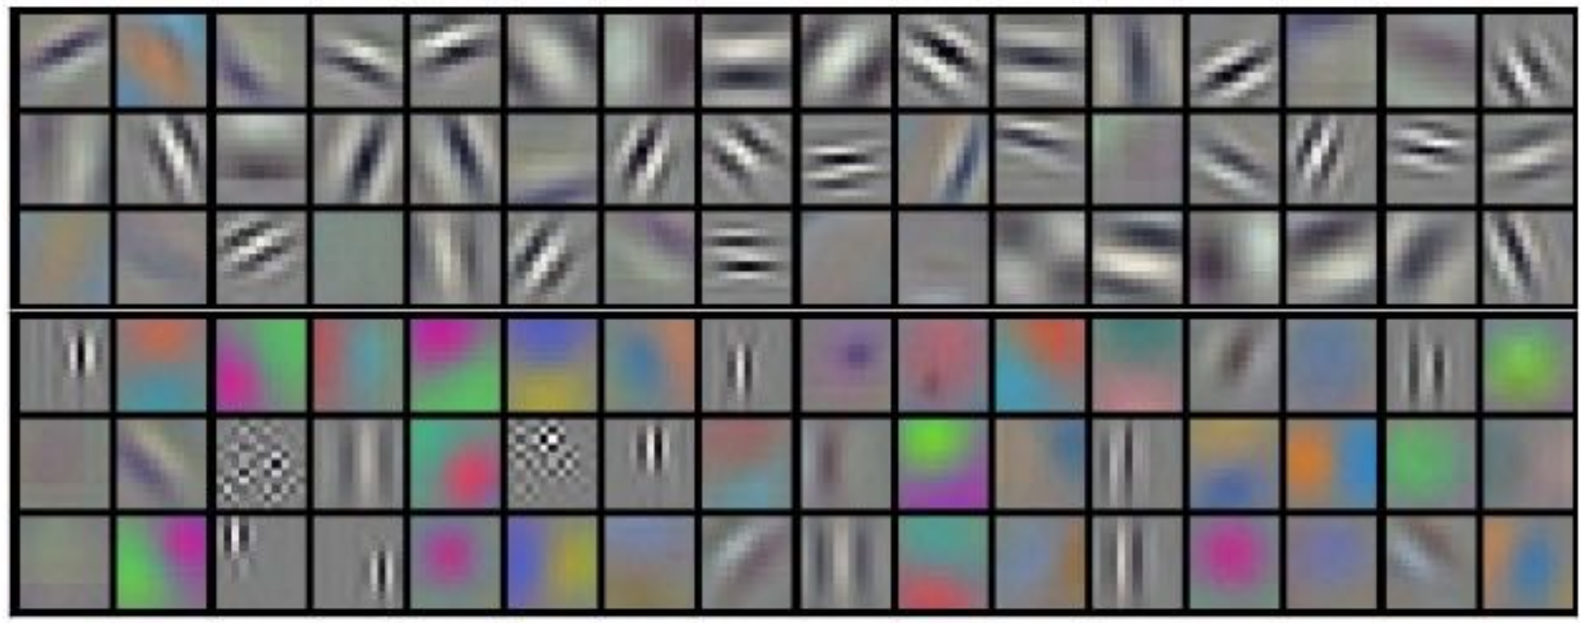

Krizhevsky et.al., 2012

End-to-Endの画像識別器

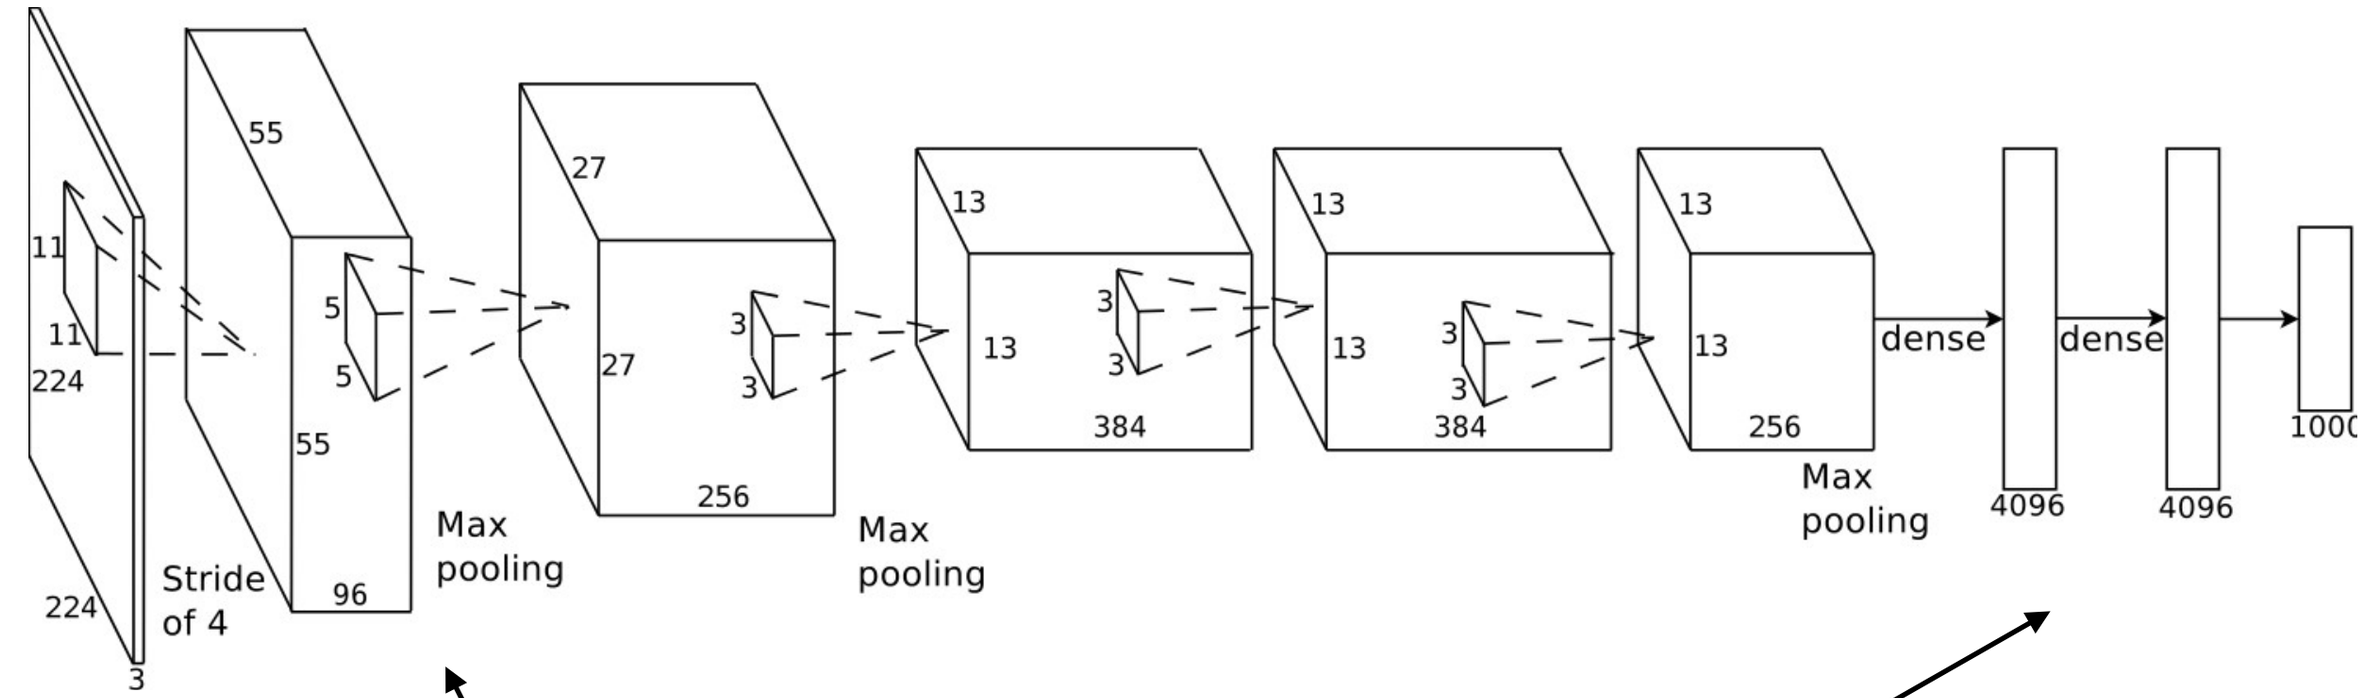

Convolutional Layerを特徴抽出器、

Dense Layerを識別器と見ることもできる

→SVMに置き換えたりもできる

従来（Deep NN以前）、研究者が手作業で頑張っていた

特徴フィルタの設計が自動化される

特徴抽出器としてのCNN

フィルタ＝特徴抽出

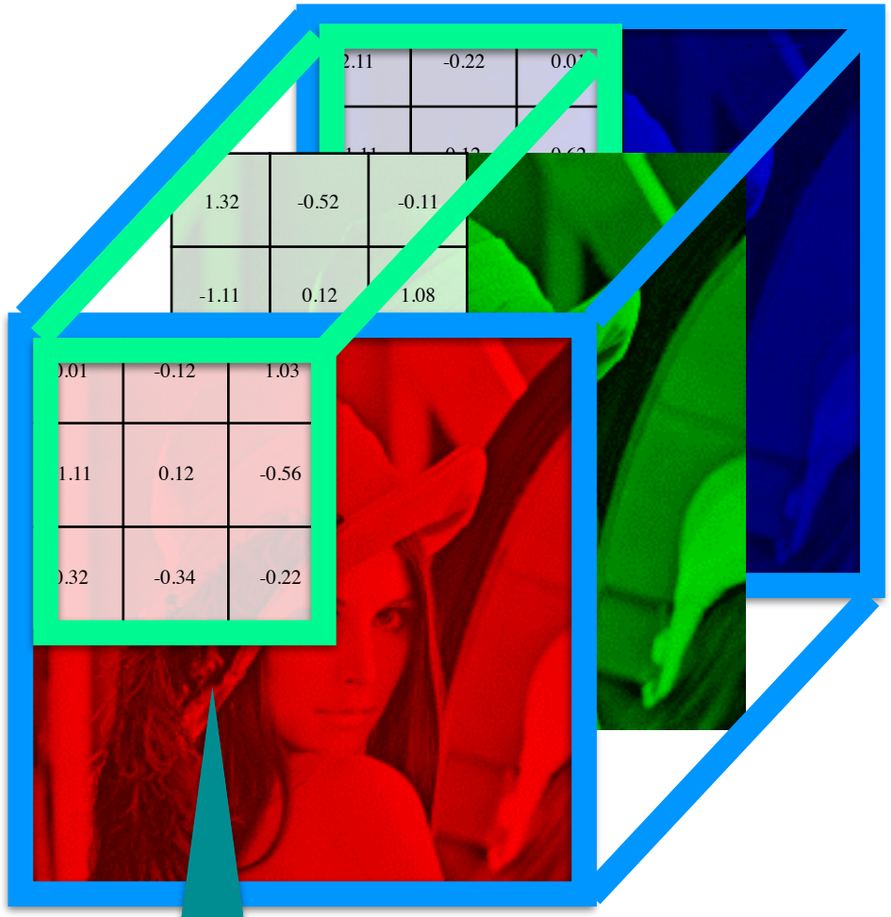

たとえば
エッジに強く
反応するフィルタ

エッジが強調された画像

各層の出力＝特徴マップ

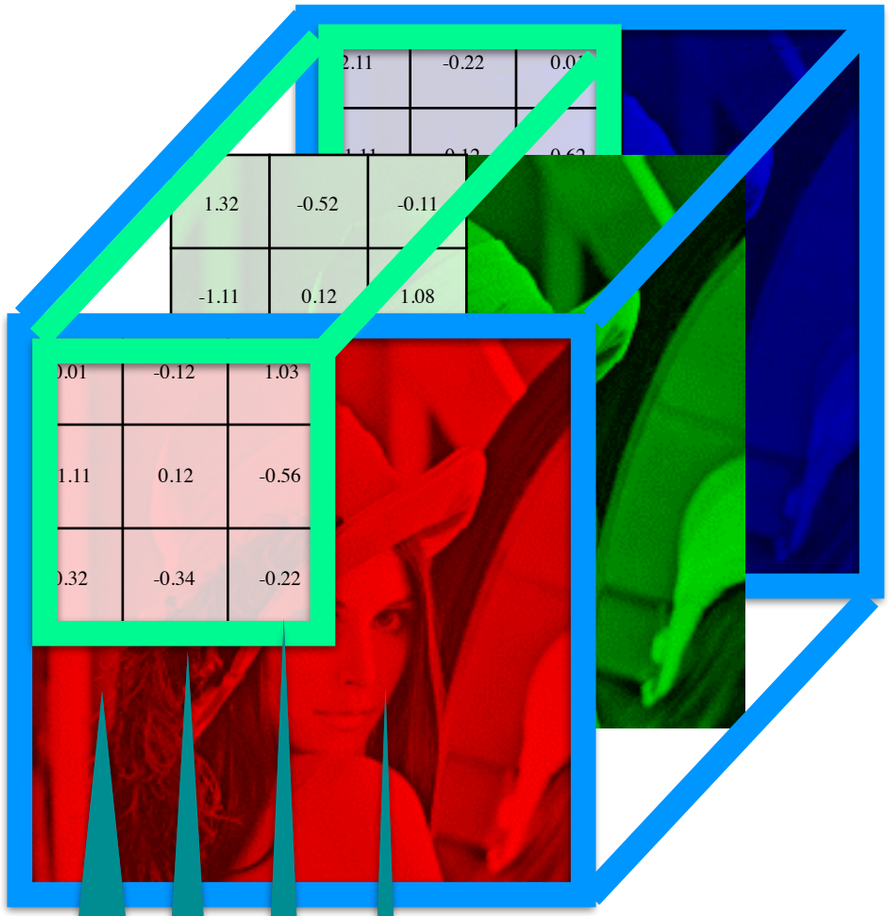

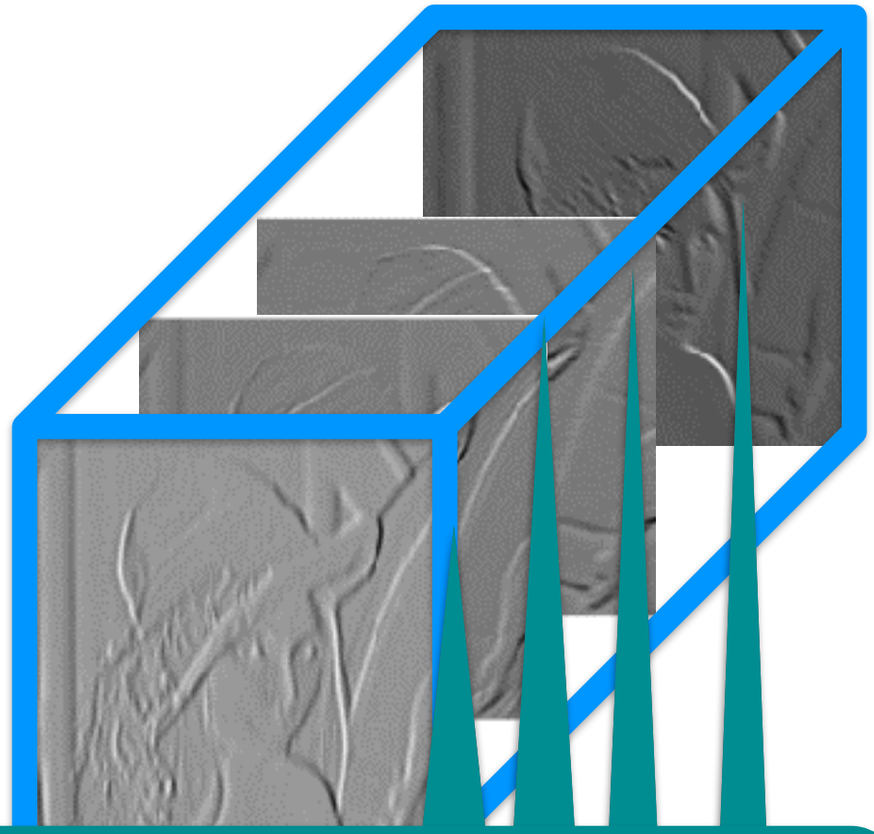

エッジ（細）

エッジ（太）

Rチャンネル
のエッジ

～みたいな
曲線

・・・

“特徴マップ”

エッジ（細）

エッジ（太）

Rチャンネル

～みたいな曲線
が強調された画像

・・・

より高次の特徴へ

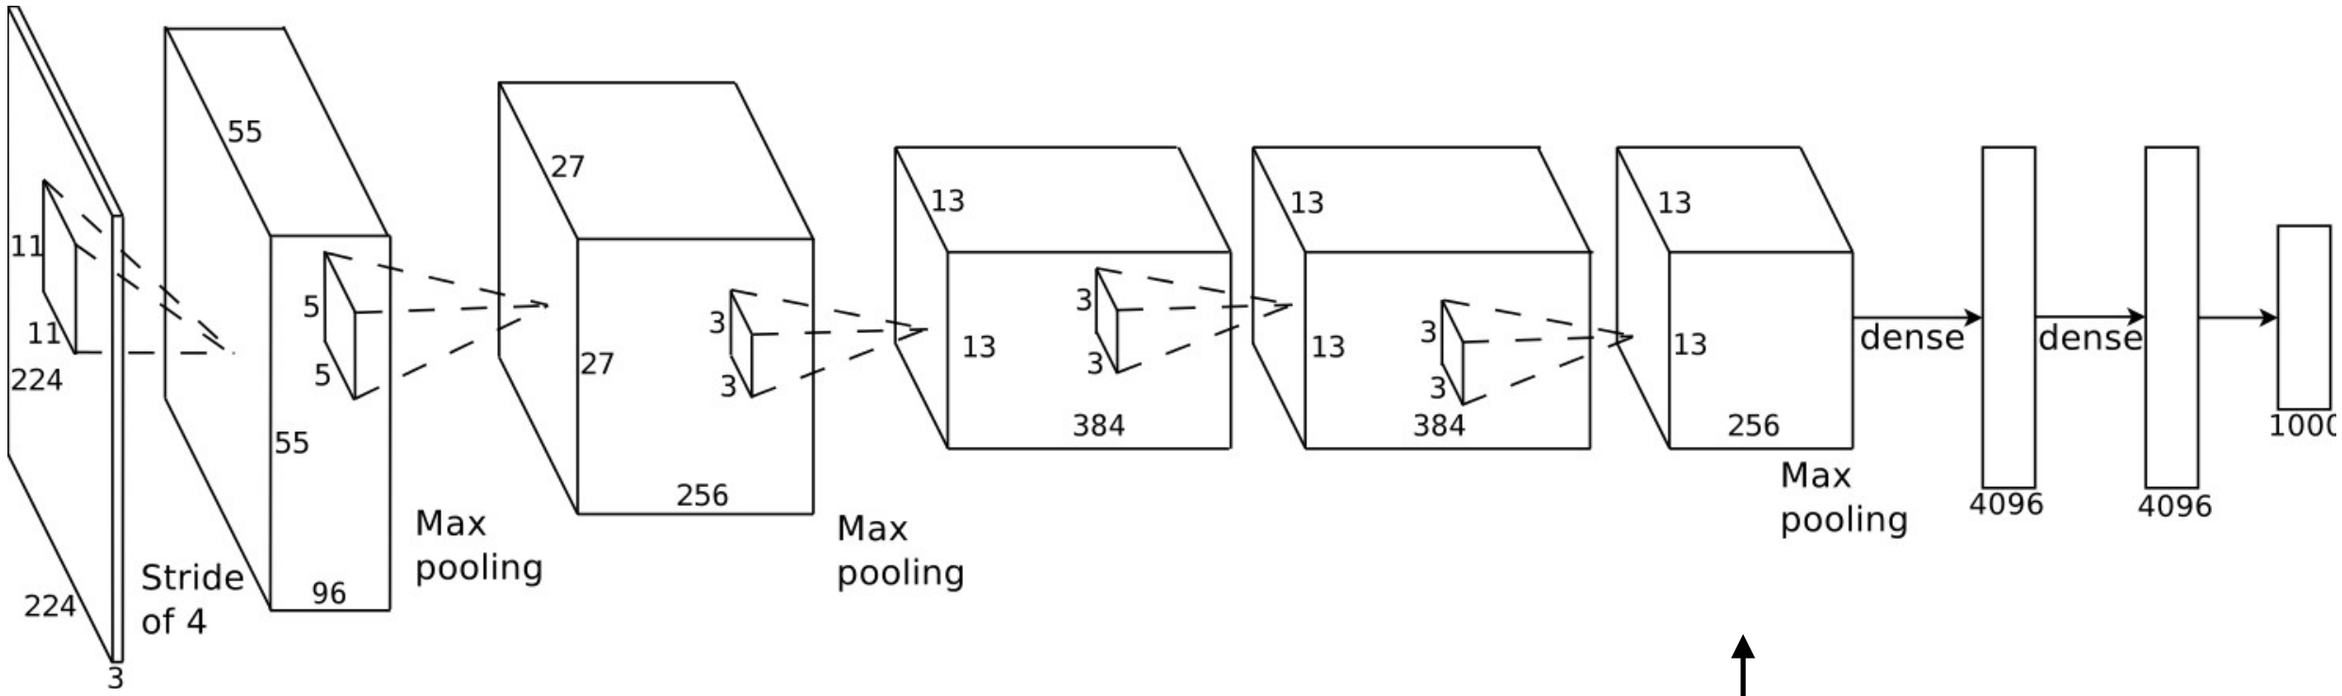

低次の特徴

エッジ・形状・色など

高次の特徴

「顔のパーツっぽさ」など

参考) VGG16の可視化

- https://blog.keras.io/how-convolutional-neural-networks-see-the-world.html

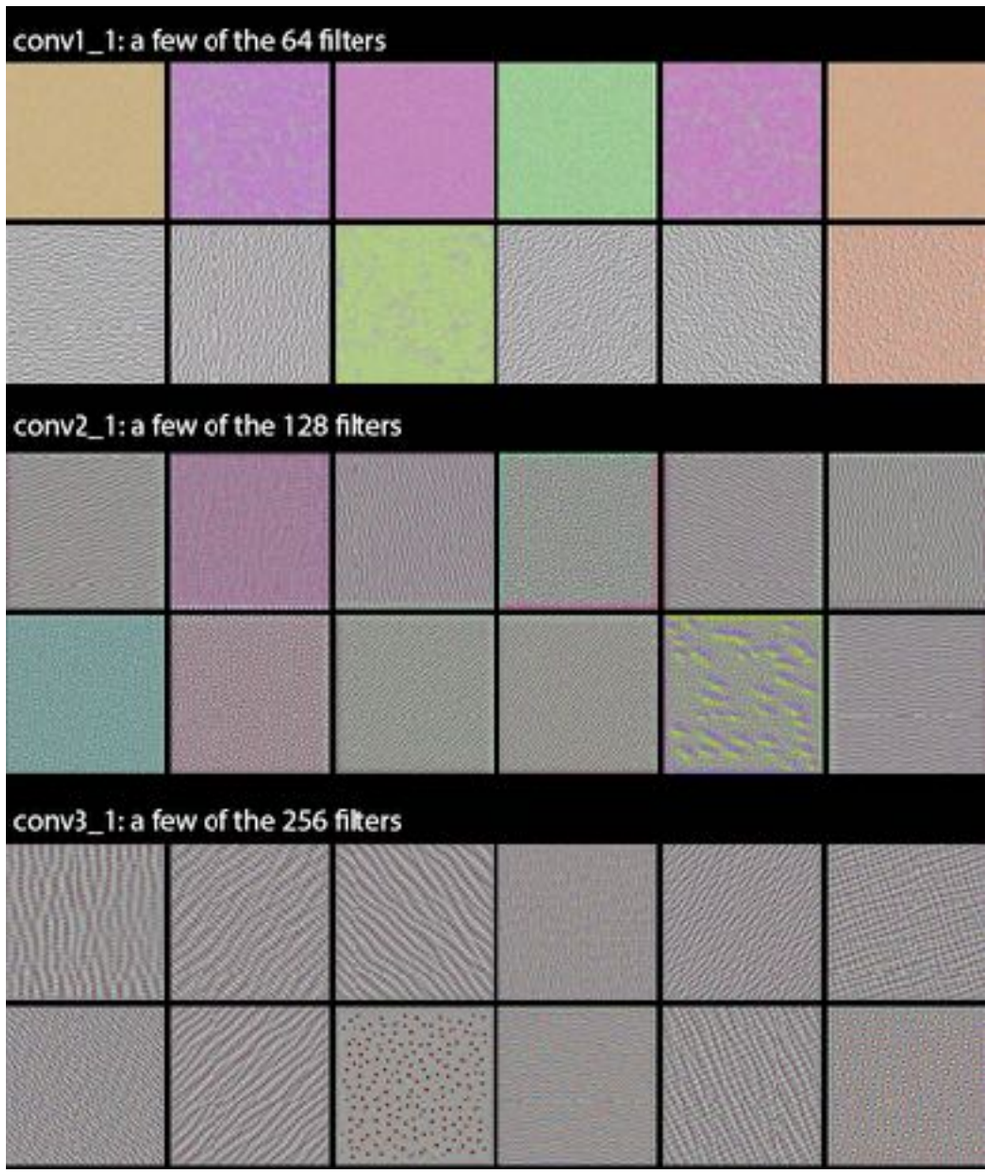

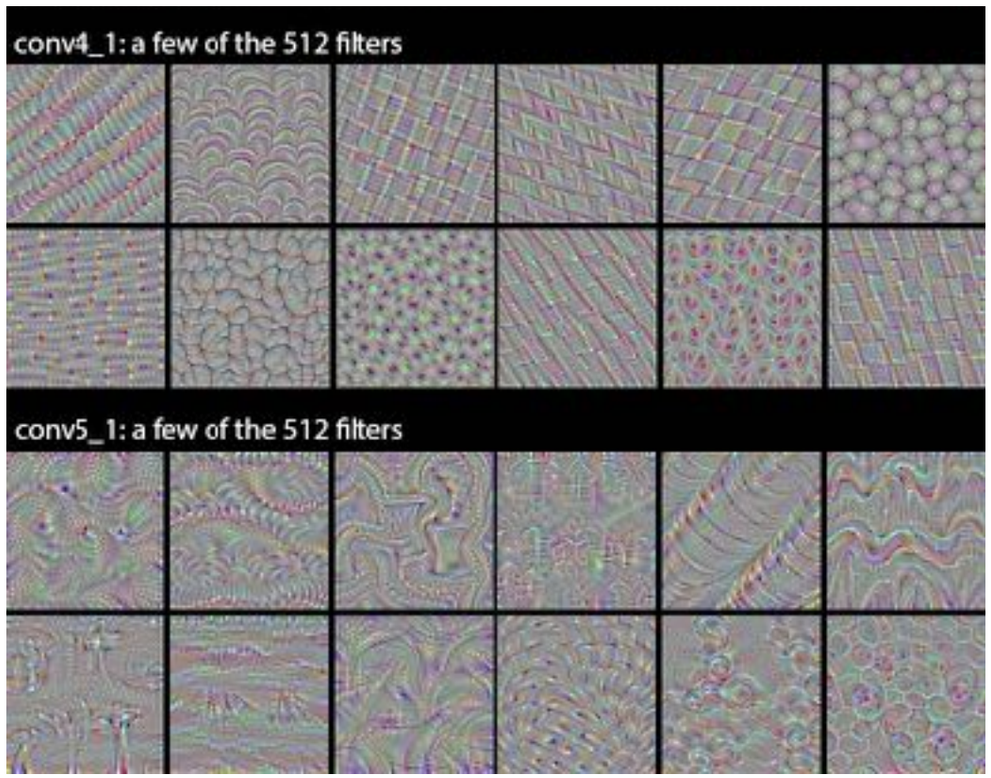

CNNと生物の視覚野の類似性

Hubel and Wieselの実験

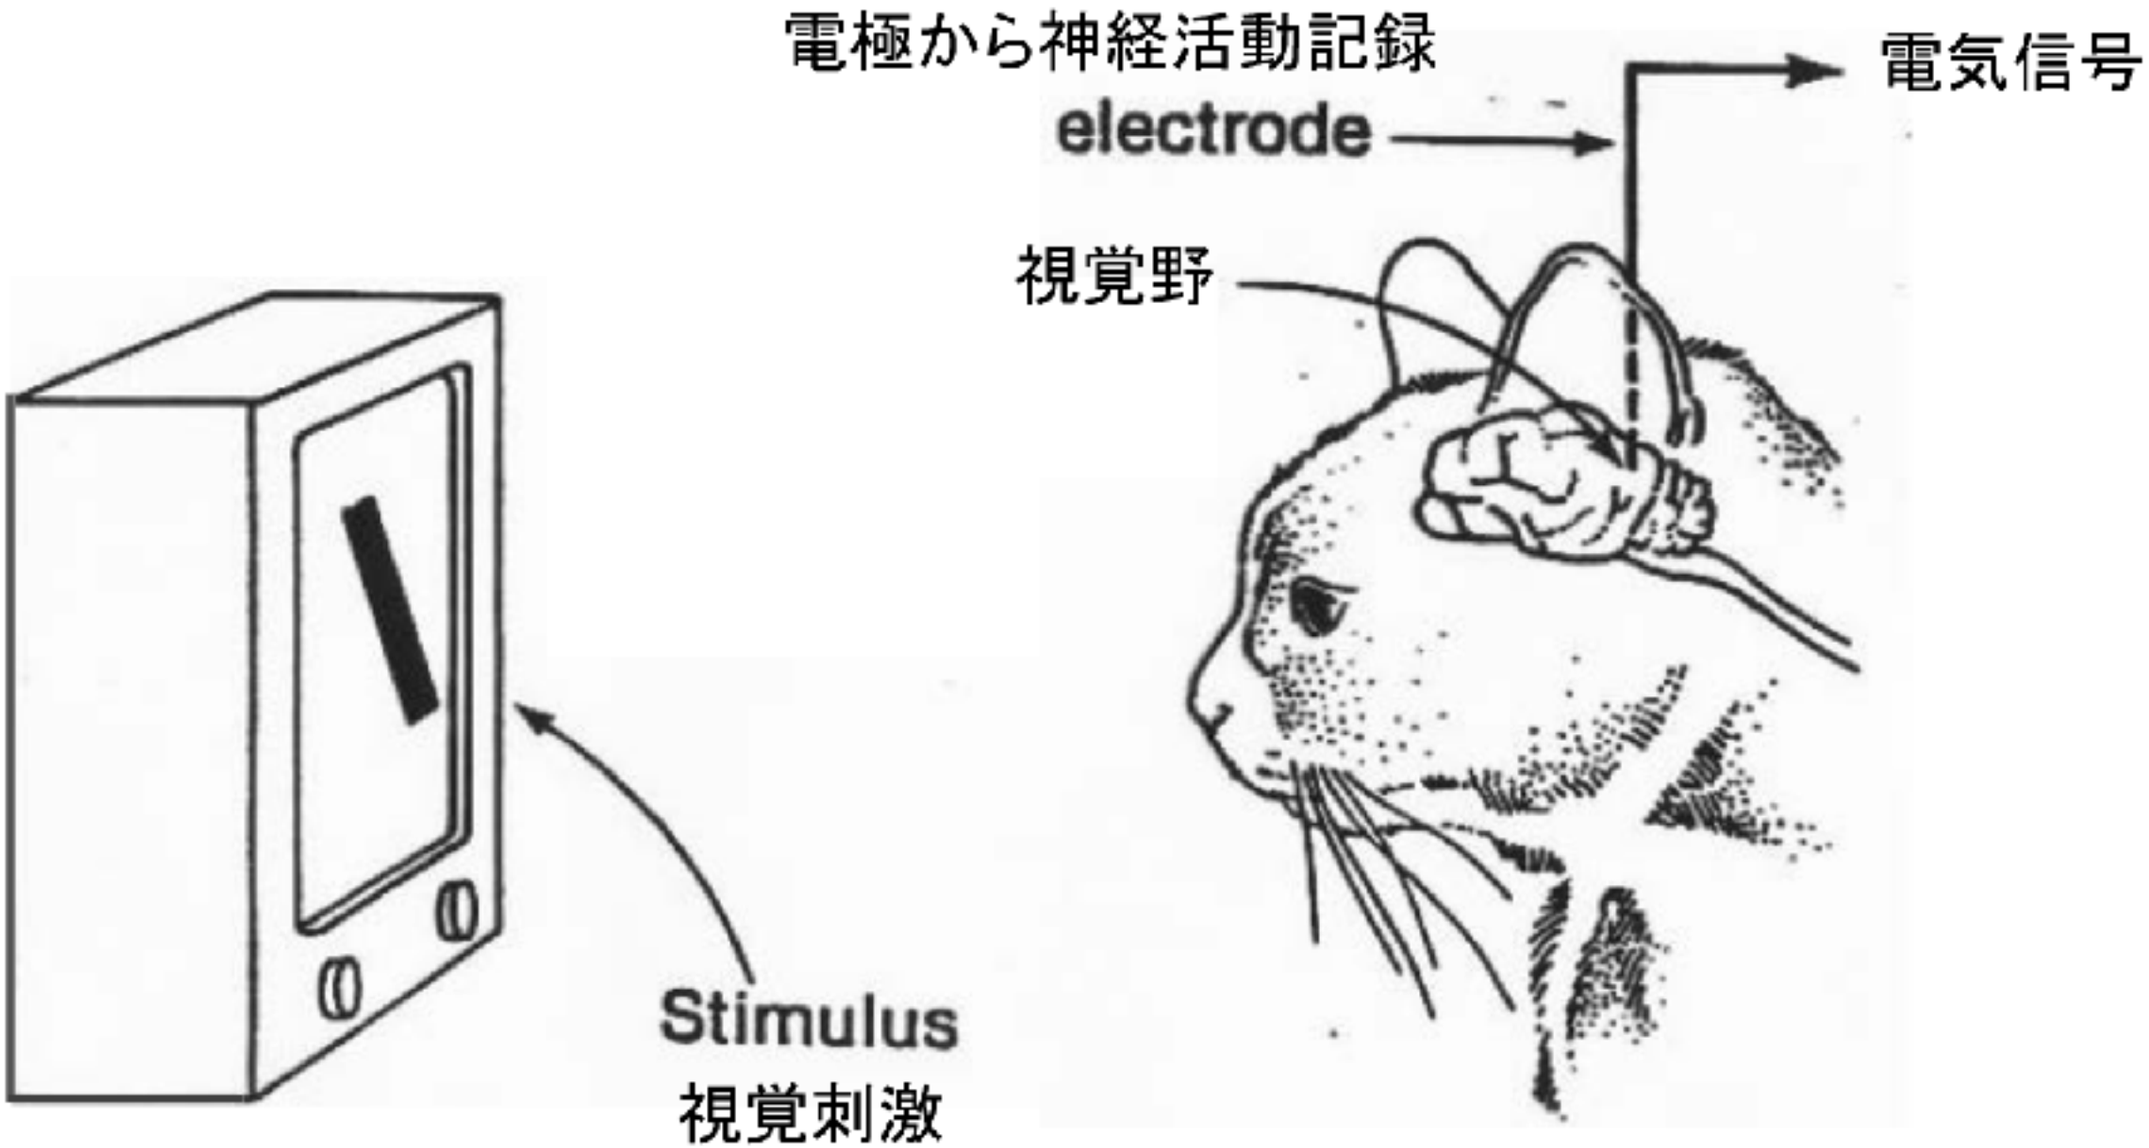

傾き選択性のある細胞

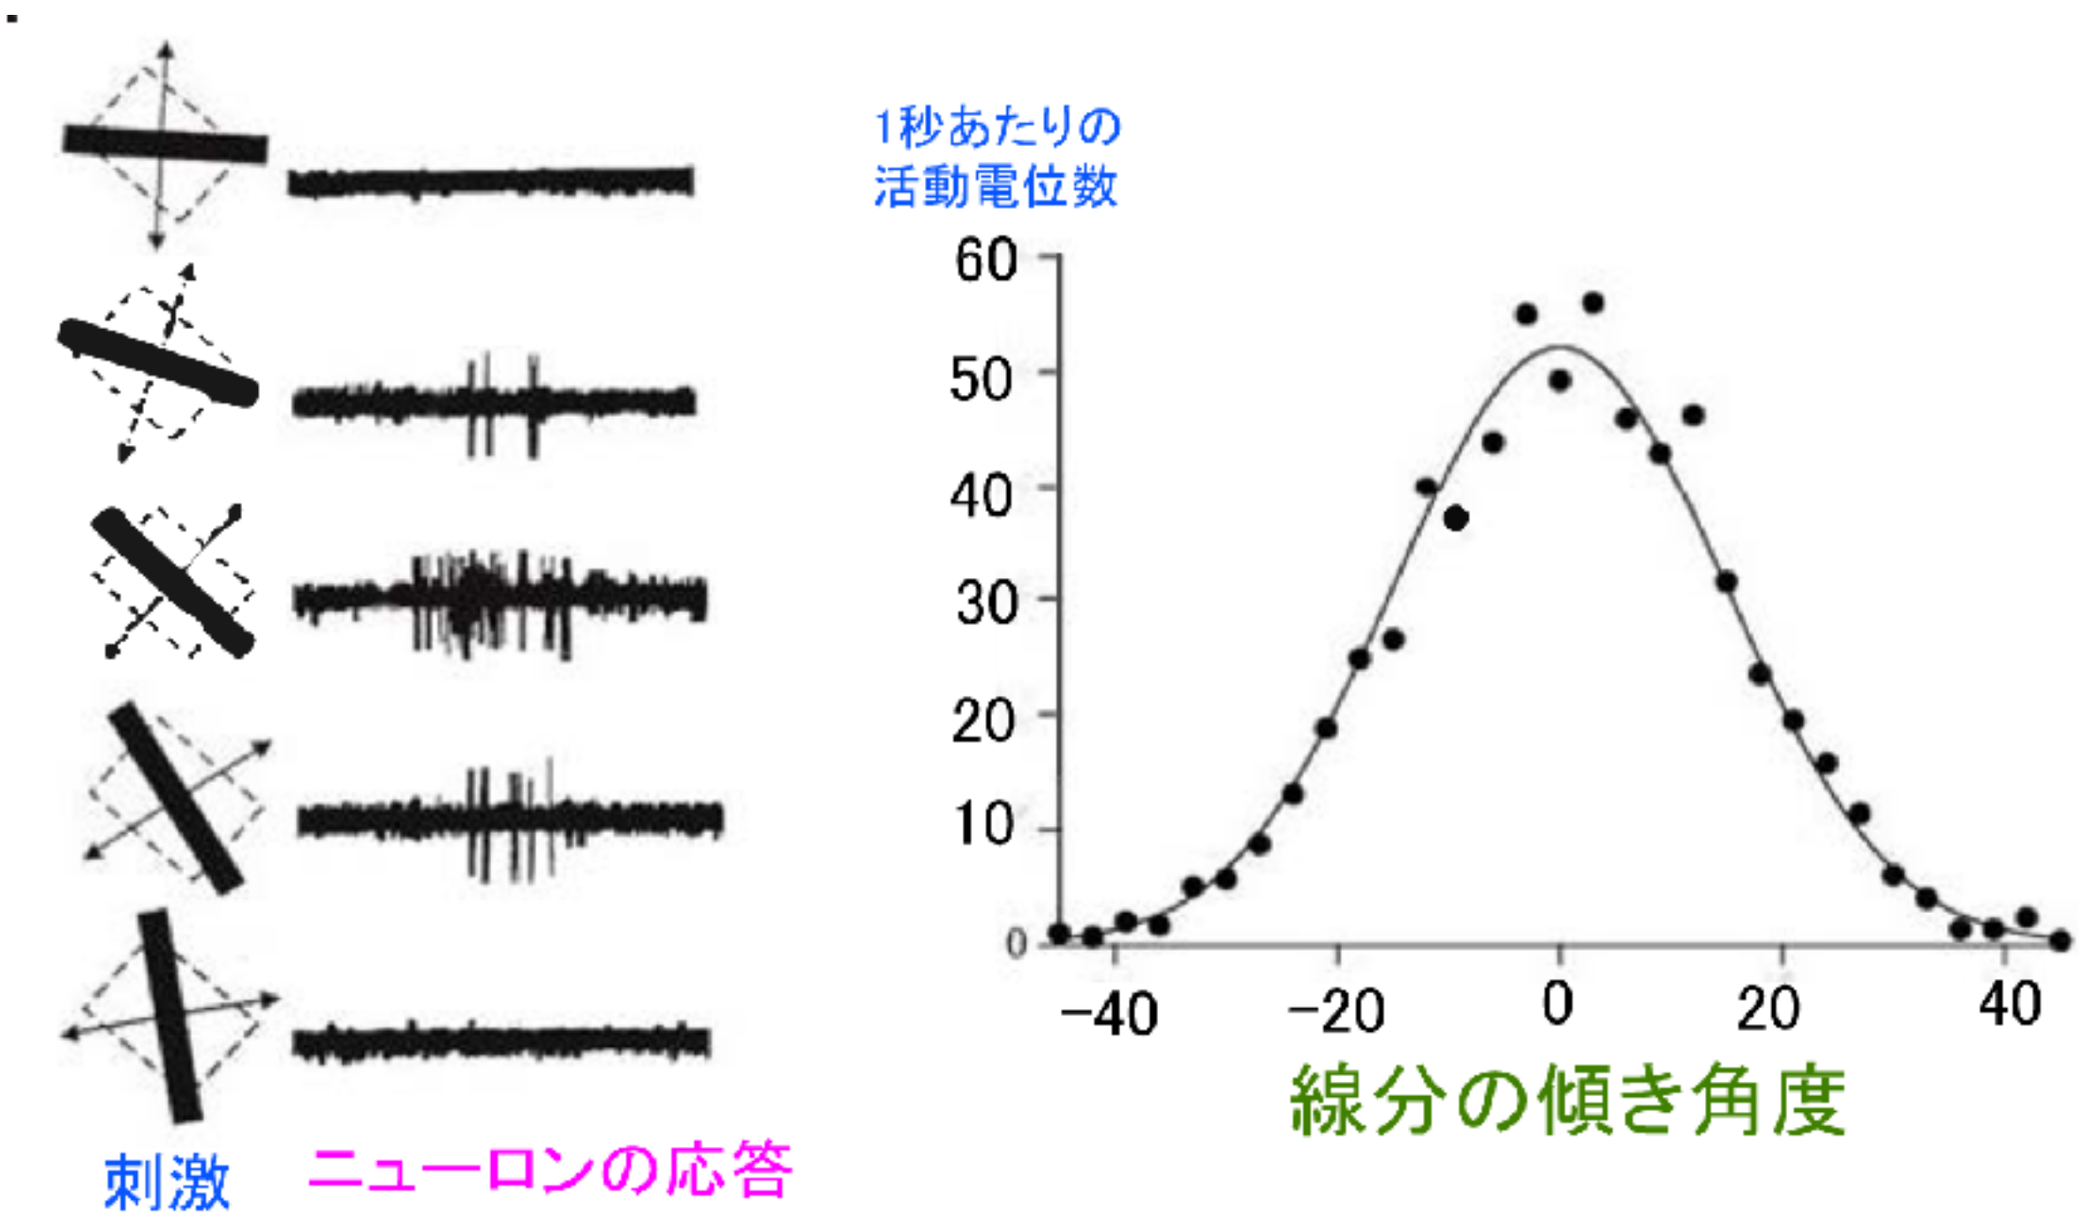

サルの第一次視覚野から記録した傾きに選択性を持つ細胞

Hubel and Wiesel, 1968

CNNとの類似性

AlexNetの1層目の可視化

→単純なパターンに反応するフィルタが獲得されている

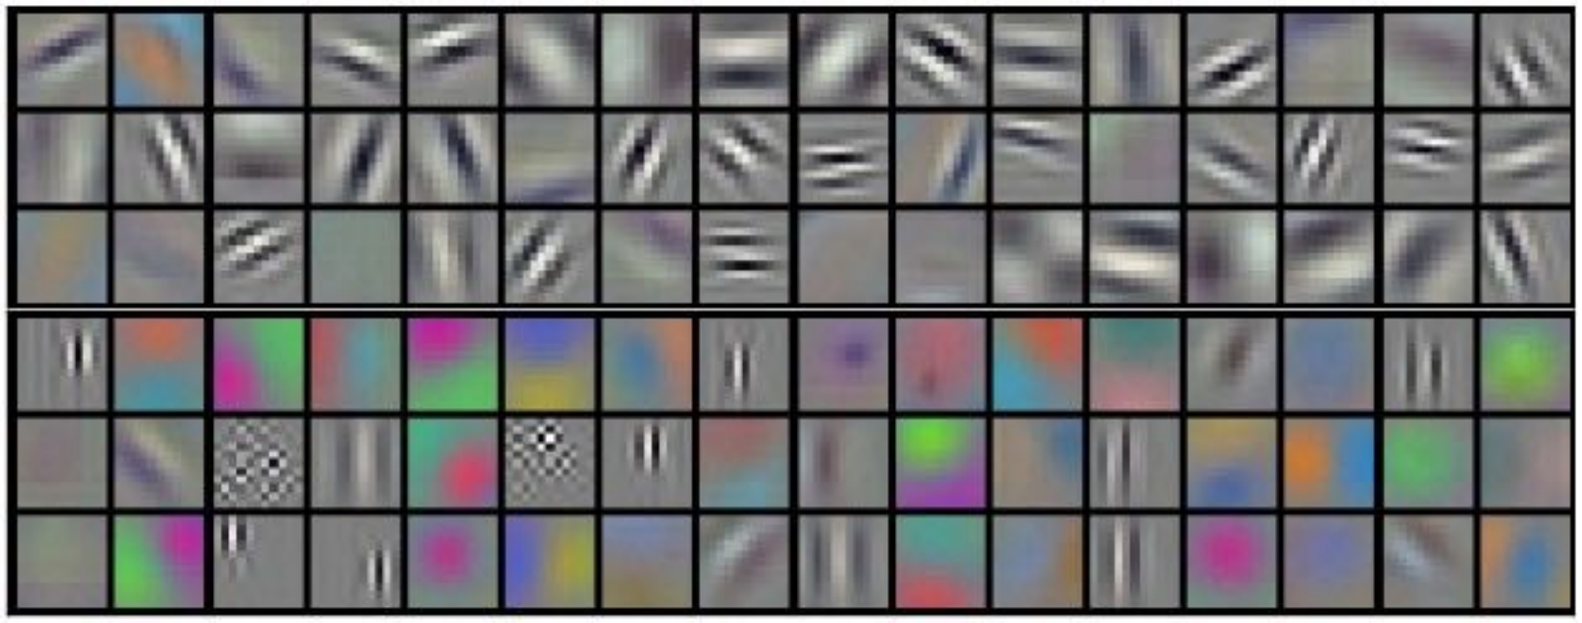

→1次視覚野と類似！（？）

Krizhevsky et.al., 2012

（再掲）より高次の特徴へ

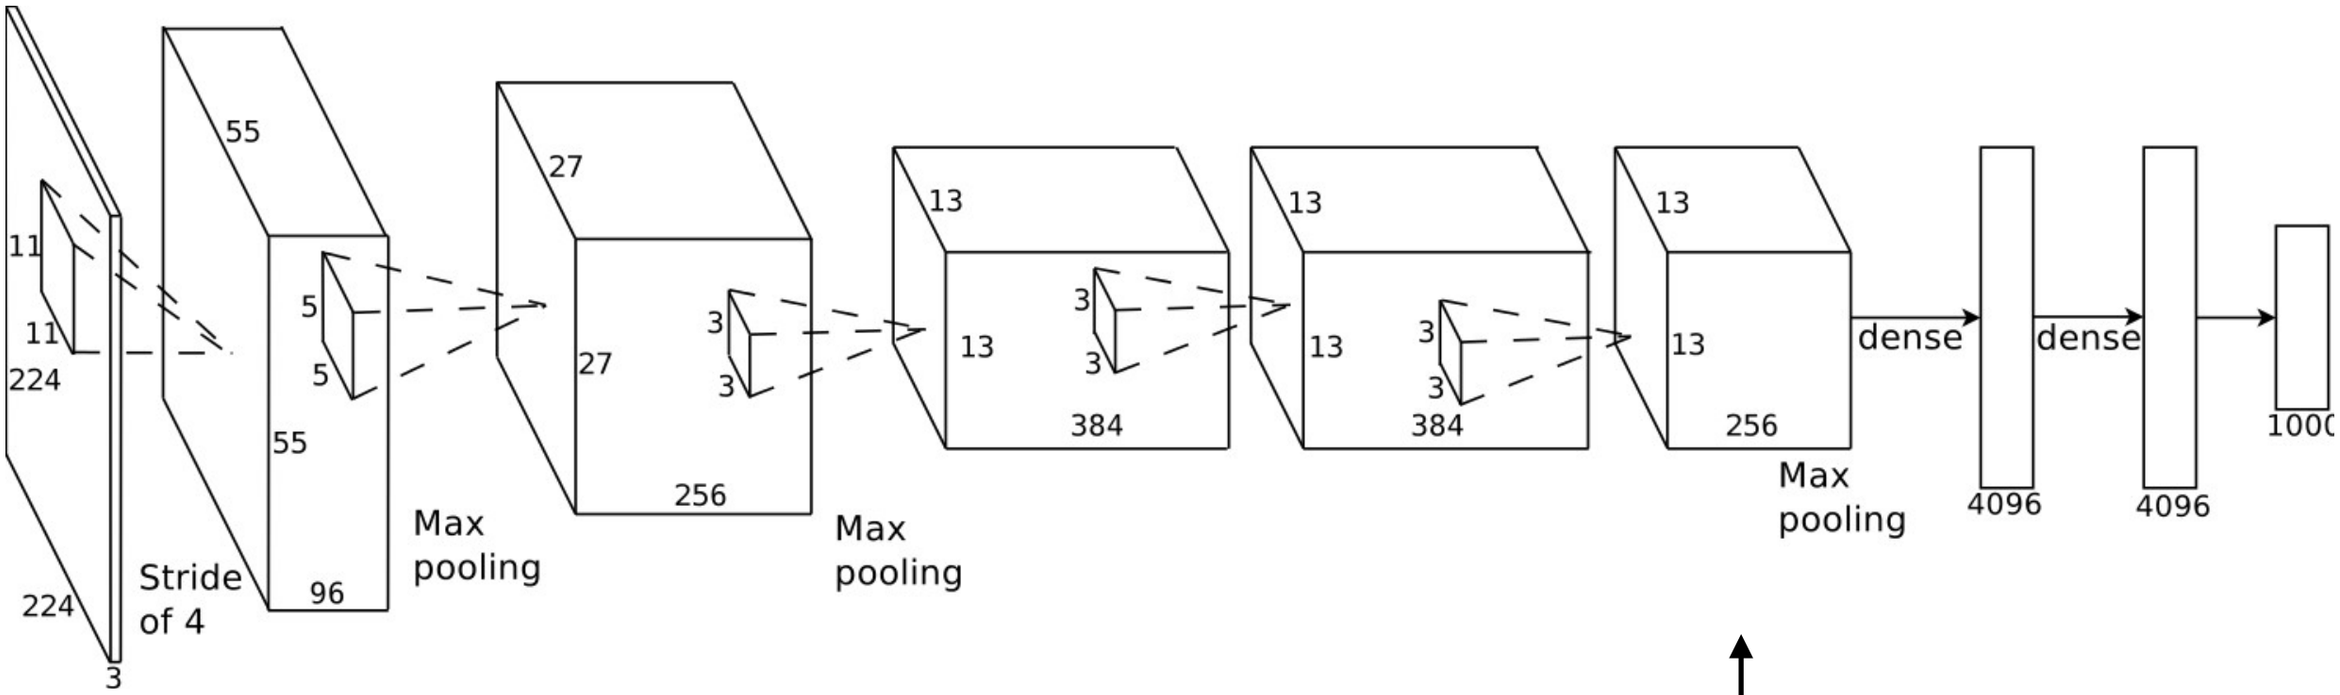

低次の特徴

エッジ・形状・色など

高次の特徴

「顔のパーツっぽさ」など

簡単なパターン抽出の組み合わせで高次の特徴を表現できる

単純型細胞・複雑型細胞

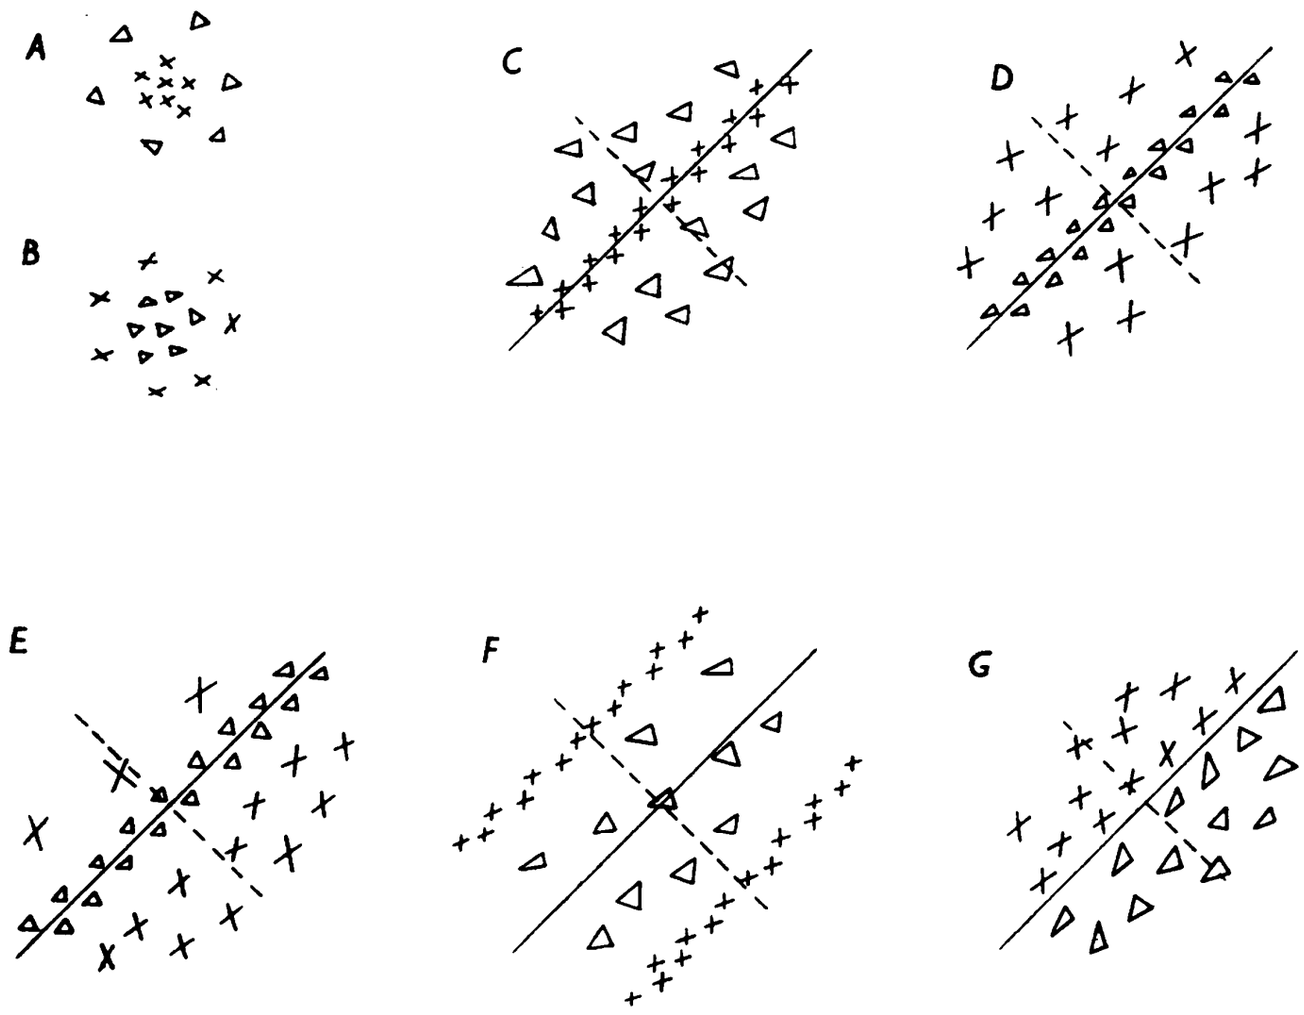

Text-fig. 2. Common arrangements of lateral geniculate and cortical receptive fields. *A*. 'On'-centre geniculate receptive field. *B*. 'Off'-centre geniculate receptive field. *C–G*. Various arrangements of simple cortical receptive fields. ×, areas giving excitatory responses ('on' responses); △, areas giving inhibitory responses ('off' responses). Receptive-field axes are shown by continuous lines through field centres; in the figure these are all oblique, but each arrangement occurs in all orientations.

単純細胞の組み合わせで複雑細胞が構成される

視覚神経モデル化の歴史

- ネオコグニトロン [Fukushima, 1980]
  - S 細胞と C 細胞との繰り返し。最初の多層（深層）化された物体認識モデルととらえることが可能
  - S 細胞：生理学の単純細胞 simple cells に対応。受容野 receptive fileds の概念を実現。特徴抽出，特徴検出を行う。
  - C 細胞：複雑細胞 complex cells に対応。広い受容野。位置，回転，拡大縮小の差異を吸収

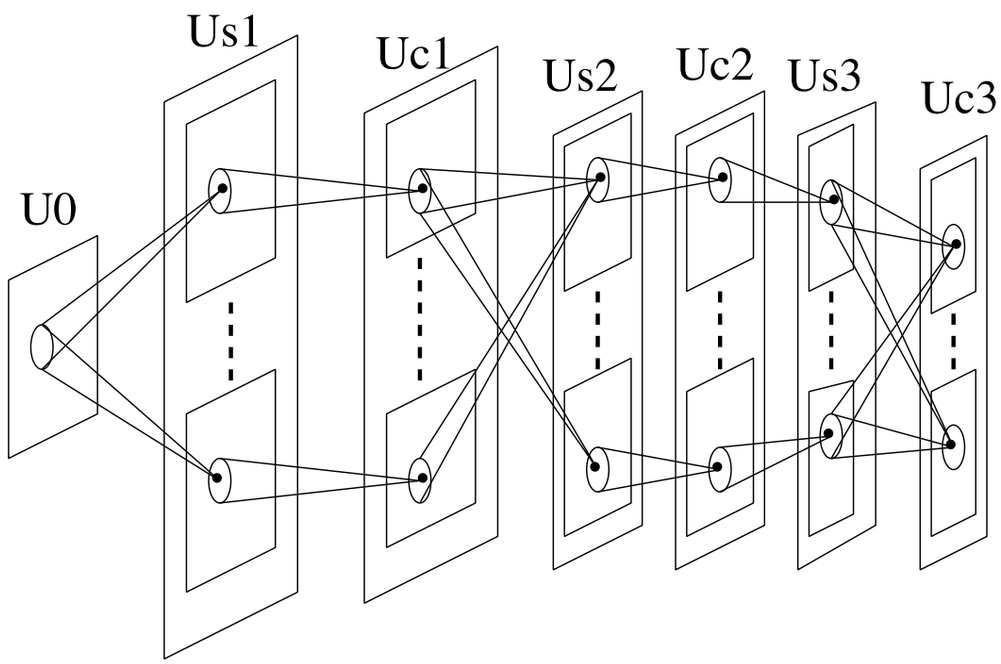

CNNの進化

LeNet [LeCun et al., 1998]

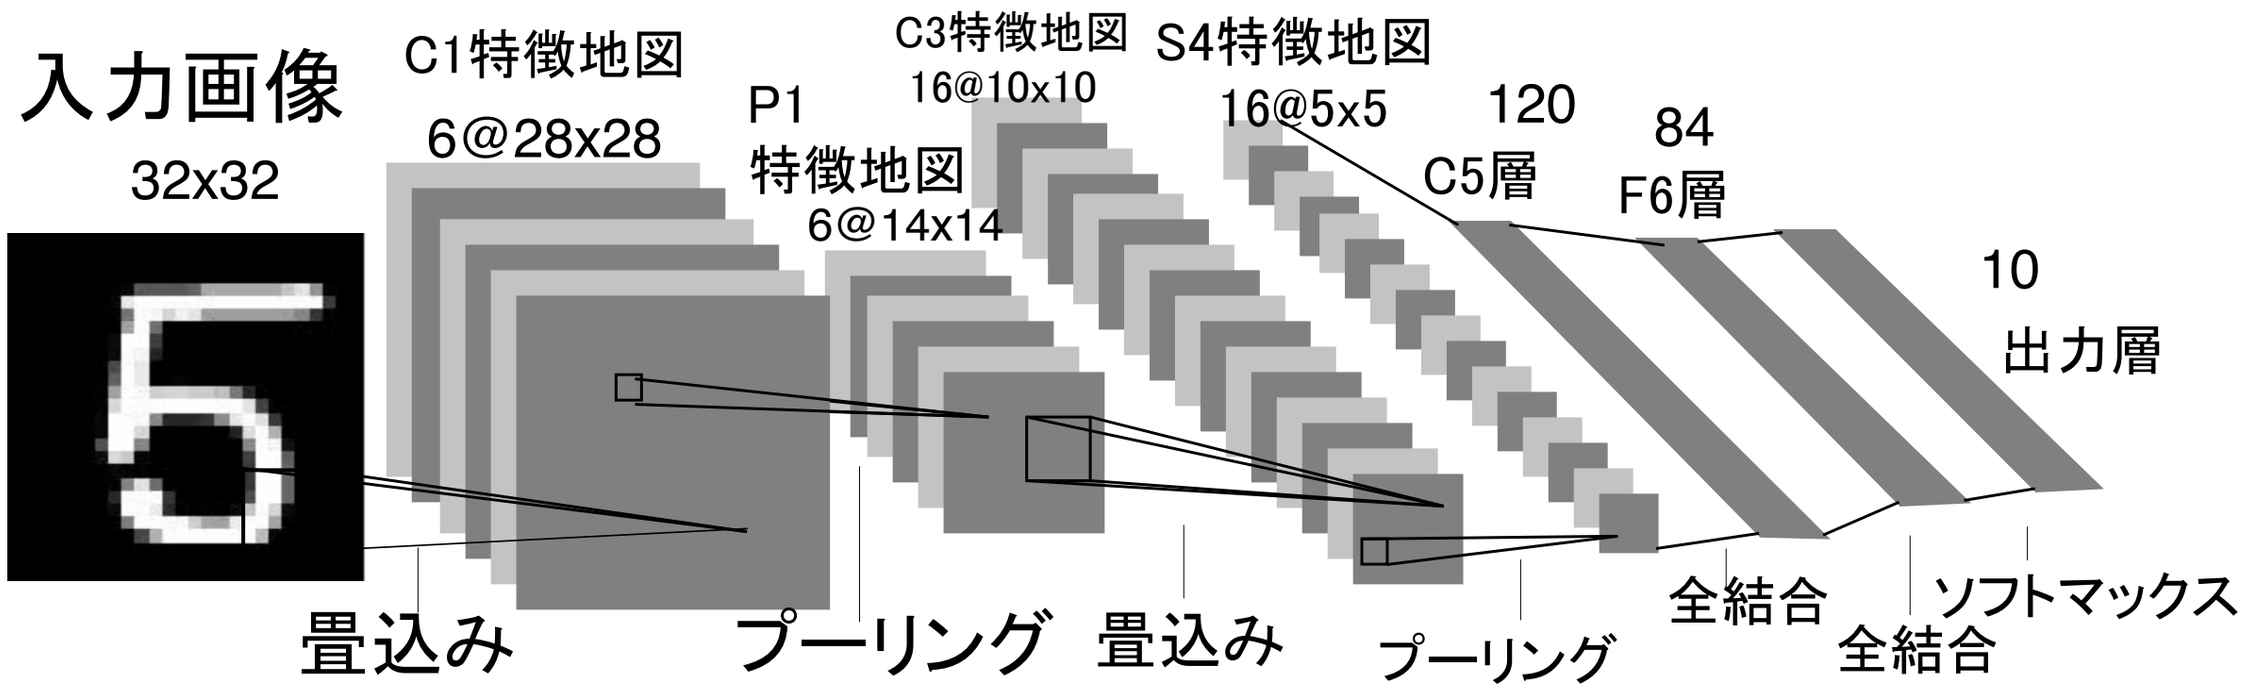

AlexNet [Krizhevsky et.al., 2012]

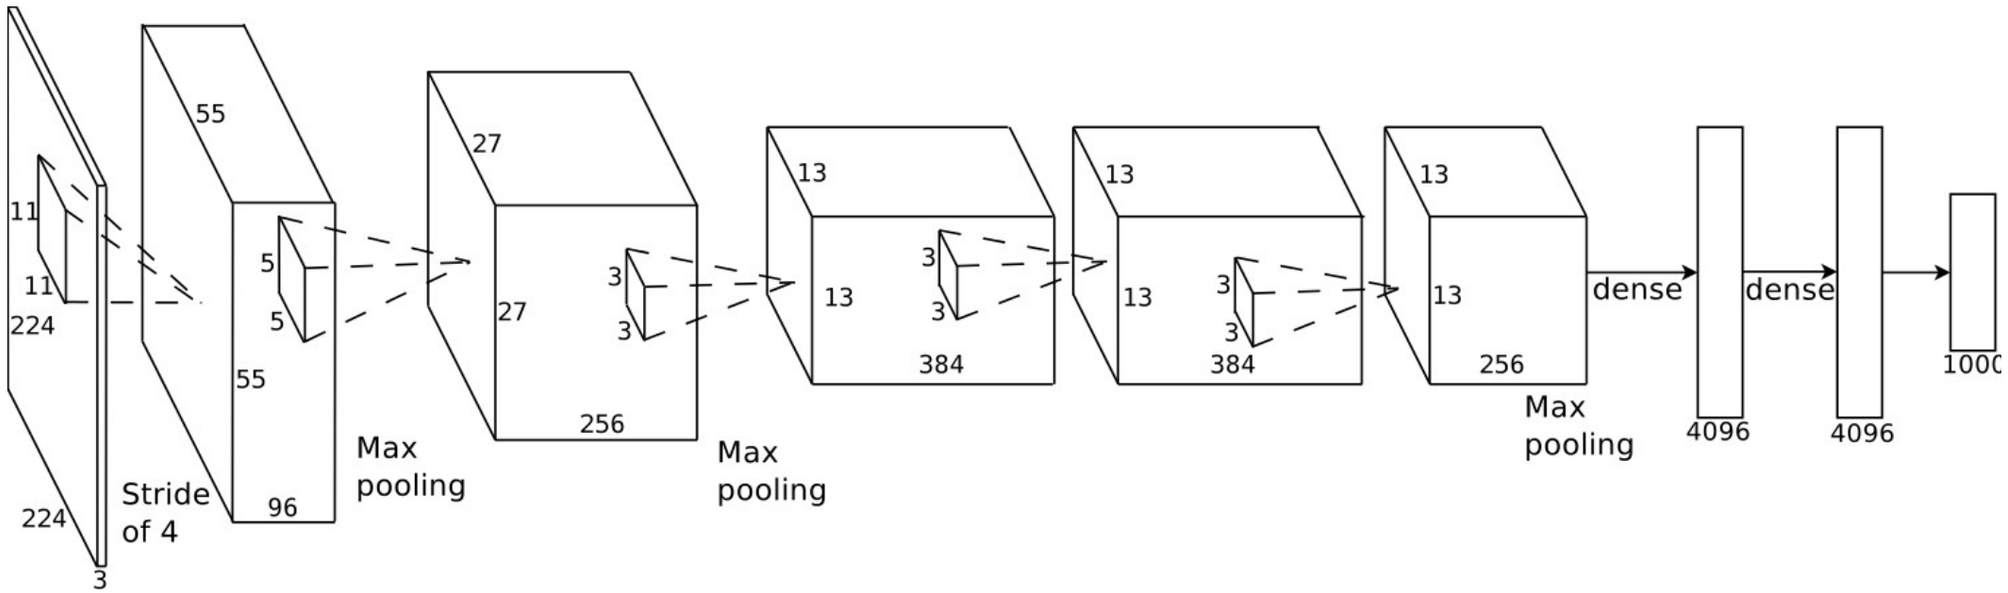

GoogLeNet [Szegedy et al., 2014]

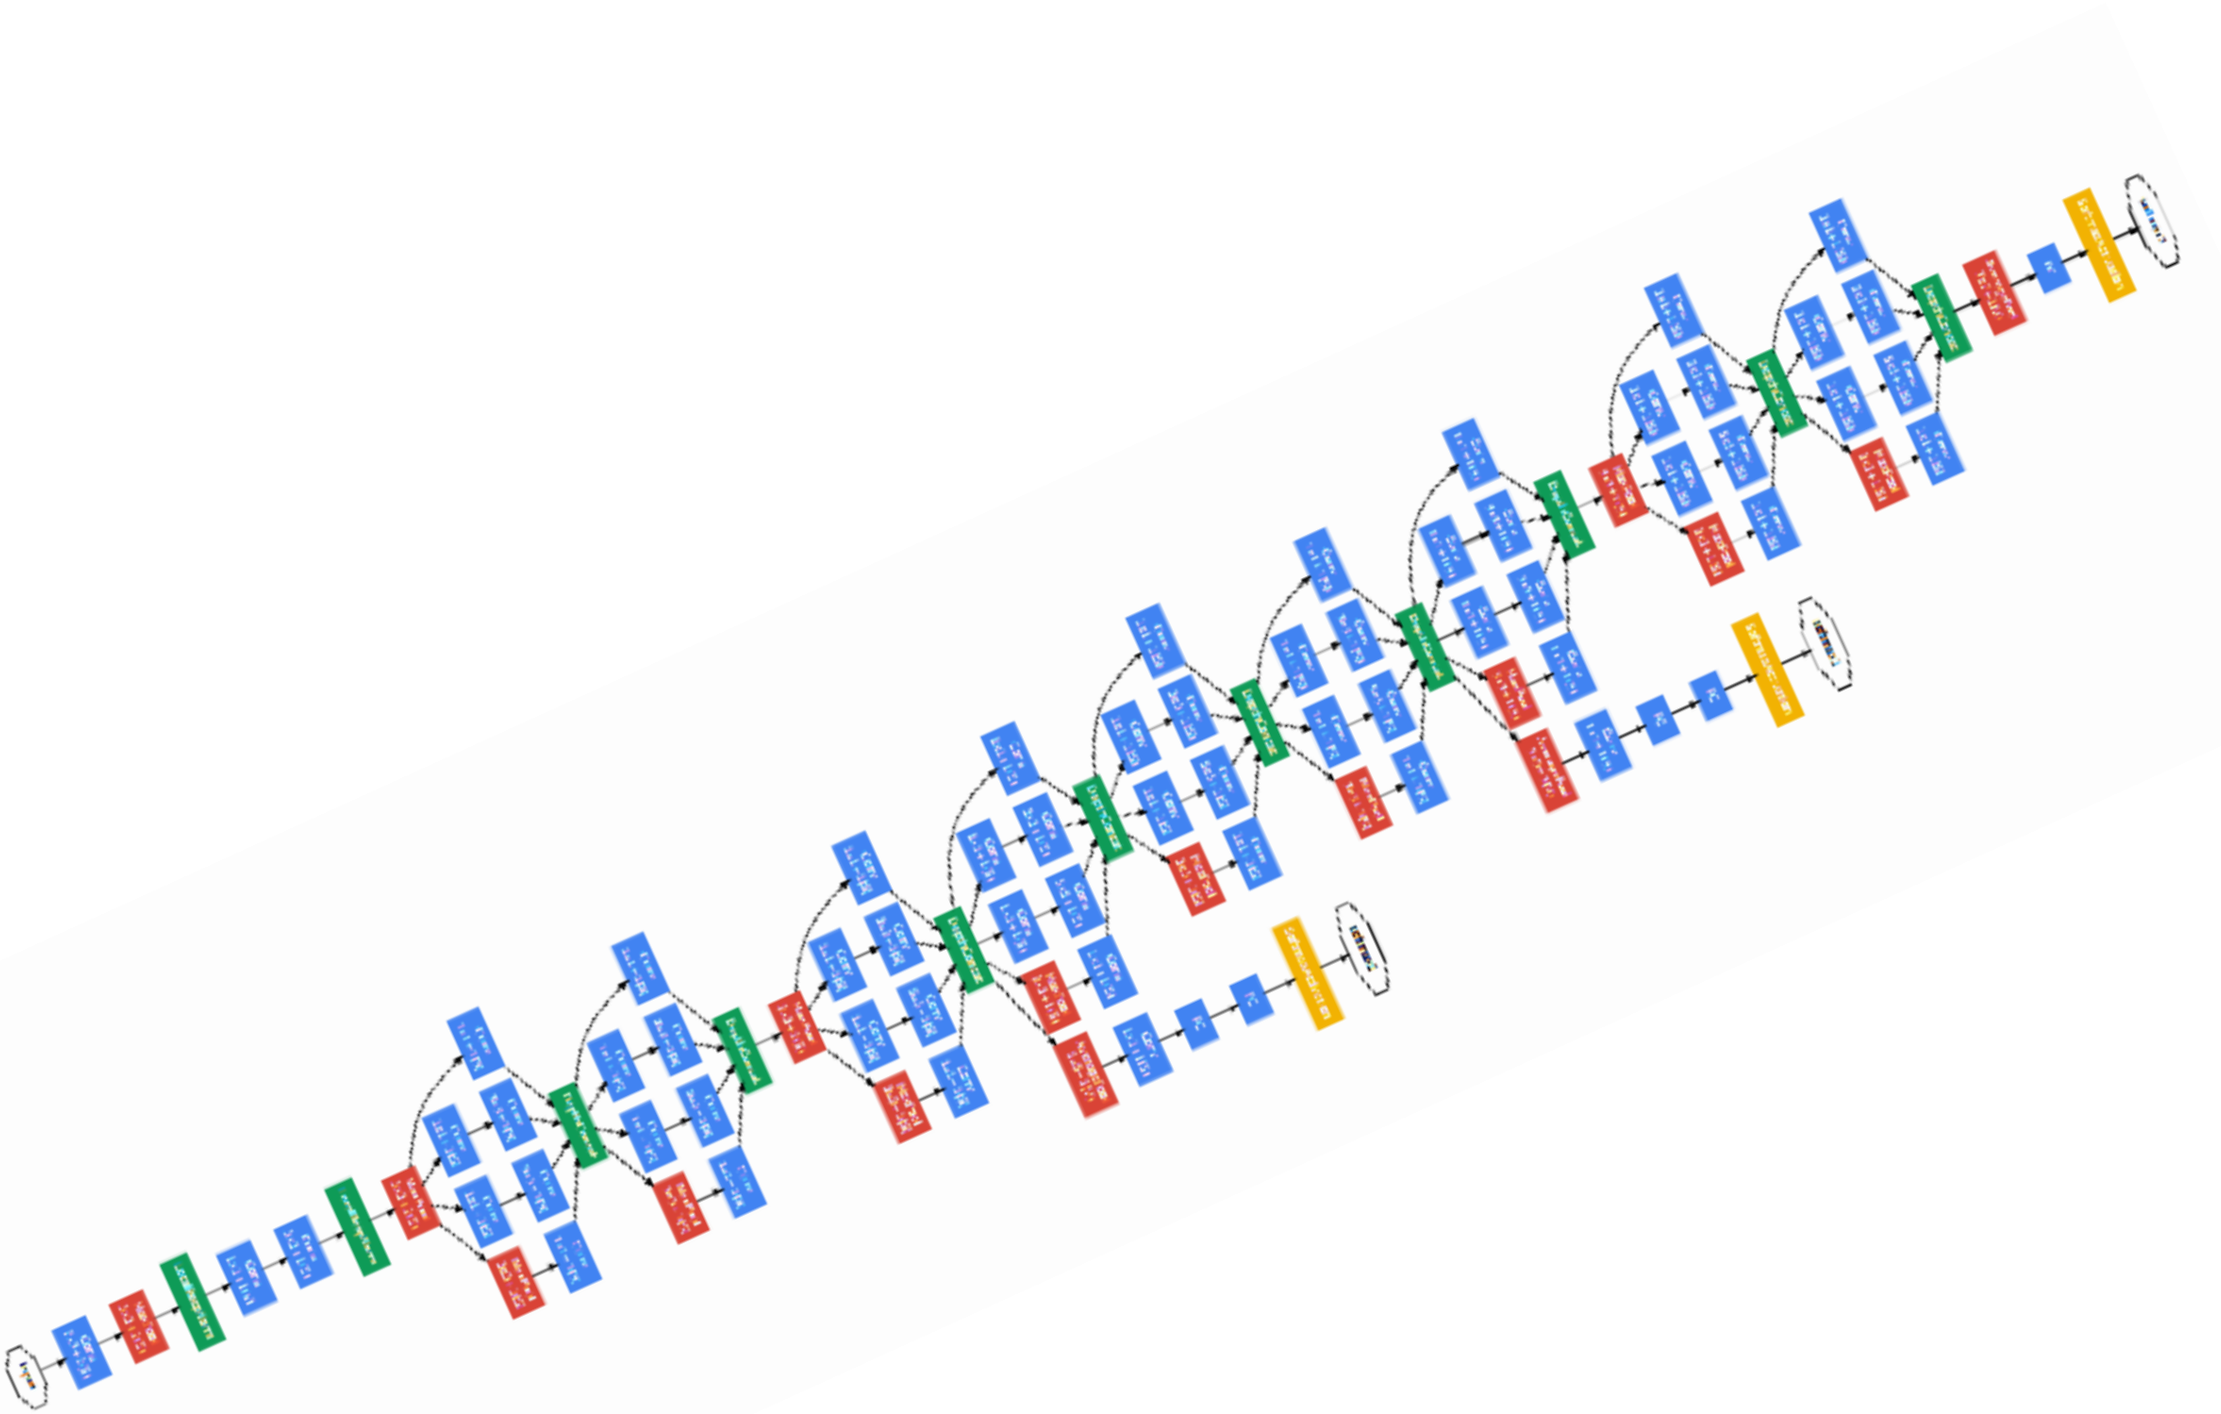

ResNet [He et al., 2015]

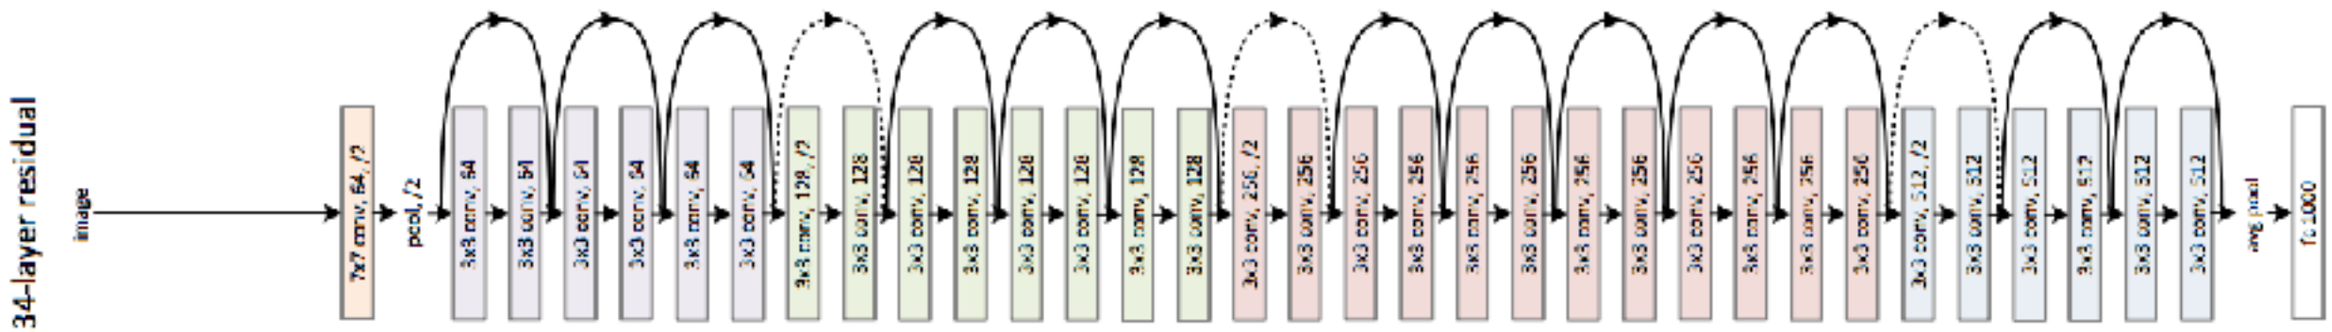

CNNの進化やばい

- 2012年のAlexNet以降、

  数え切れないモデルが提案されている（紹介しきれません）

  - NIN
  - SPP Net
  - GoogLeNet
  - ResNet
  - …
- 基本的に、よりDeepに、Deepに…
- 生物の視覚神経との類似性はどこへやら
- CNNの独自進化の結果、逆に生物を理解する成果が出るかも…？

局所結合ネットワーク Locally Connected Layers

- 結合の重みが位置によって違う＝Weight sharing**しない**
- 画像のアラインメントが仮定されるタスクではCNNより高精度なものも
- Deep Face [Taigman et al., 2014]

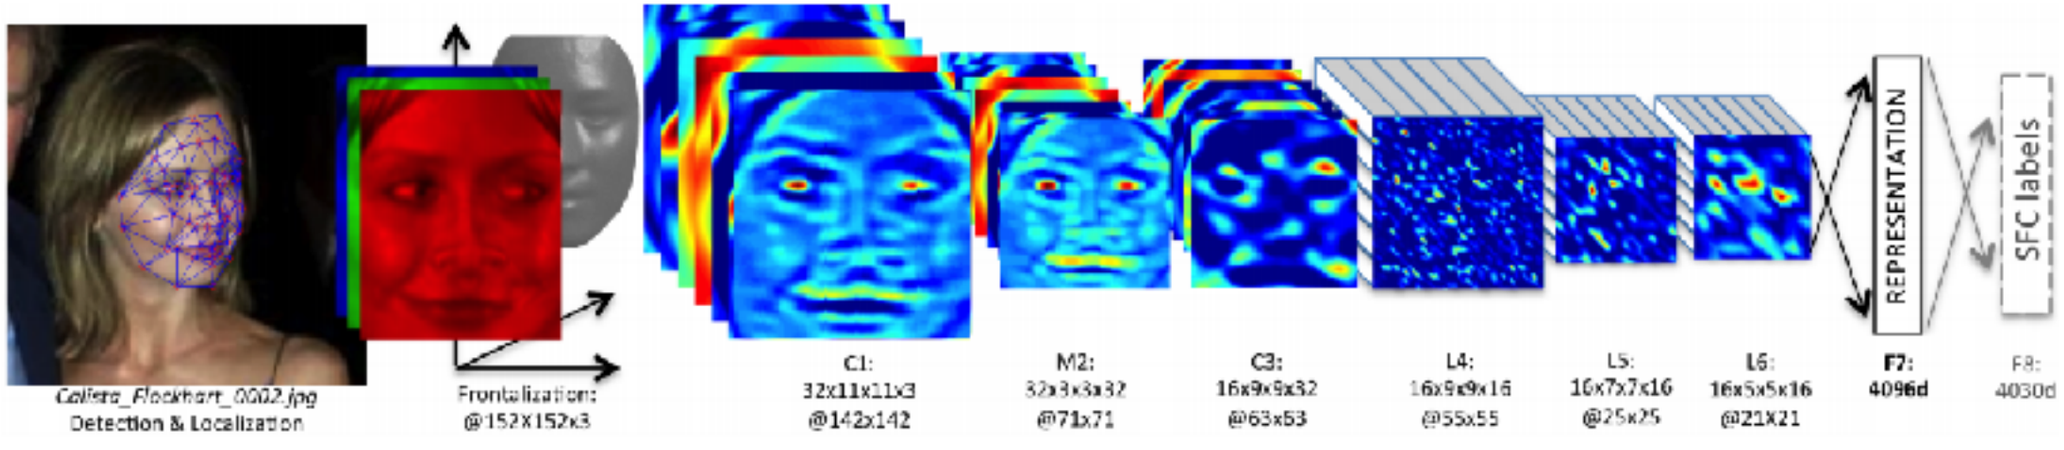

Chainerでやってみる

紹介した道具は全てchainerに用意されています

- Convolutional layer
  - Hyper parameters: k, s, p, (w, h)
- Pooling layer
  - Type: max, average, …
  - Hyper parameters: k, s
- Dropout
  - Hyper parameters: p
- Data augmentation
- Normalizations
- etc…

- 先にMNISTのダウンロードを実行しておく

宣伝

こんな会社にいます

PKSHA TECHNOLOGY

画像認識や自然言語処理やってます

東京都文京区本郷 2-35-10

本郷瀬川ビル 4F

https://pkshatech.com/ja/
https://www.wantedly.com/companies/pkshatech

9/22上場します