NICO2AI Lecture12

強化学習 II
Reinforcement Learning II

妹尾卓磨

目次

- **方策勾配**

方策を直接求めるには

- **深層強化学習**

DNNによる強化学習によって何ができるようになったのか

- **内発的動機**

生物は環境からの報酬のみから学習しているのか

方策勾配

目次

- **方策勾配**

方策を直接求めるには

- **深層強化学習**

DNNによる強化学習によって何ができるようになったのか

- **内発的動機**

生物は環境からの報酬のみから学習しているのか

方策ベースと価値ベース

- **方策ベース (policy based) ← 今日はこの話**

現在の方策での収益を計算して、収益が高くなる方策を学習する

方策自体を求める

- **価値ベース (value based)**

状態や行動に価値を設定して、その価値を元に方策を決定する

方策自体は求めない

価値ベース強化学習の課題

- **連続行動空間の扱い (continuous action space)**

Q学習ではQ関数は状態と行動を引数とした関数であった

➔**行動は離散的な値 (discrete action space)**

行動がモーターの制御値など連続的場合だと...

➔Q(s, 0.1), Q(s, 0.01), Q(s, 0.001), ...

無限通りの行動について価値を評価する必要がある

方策勾配 (policy gradient)

方策を確率的なモデルとして直接推定する

方策πをθでパラメタライズして**勾配法**により最適解を求める

$$\theta \leftarrow \theta + \delta\theta$$

方策πのパラメータを直接求めることで**連続的な行動も扱える**

方策ベースの学習フロー

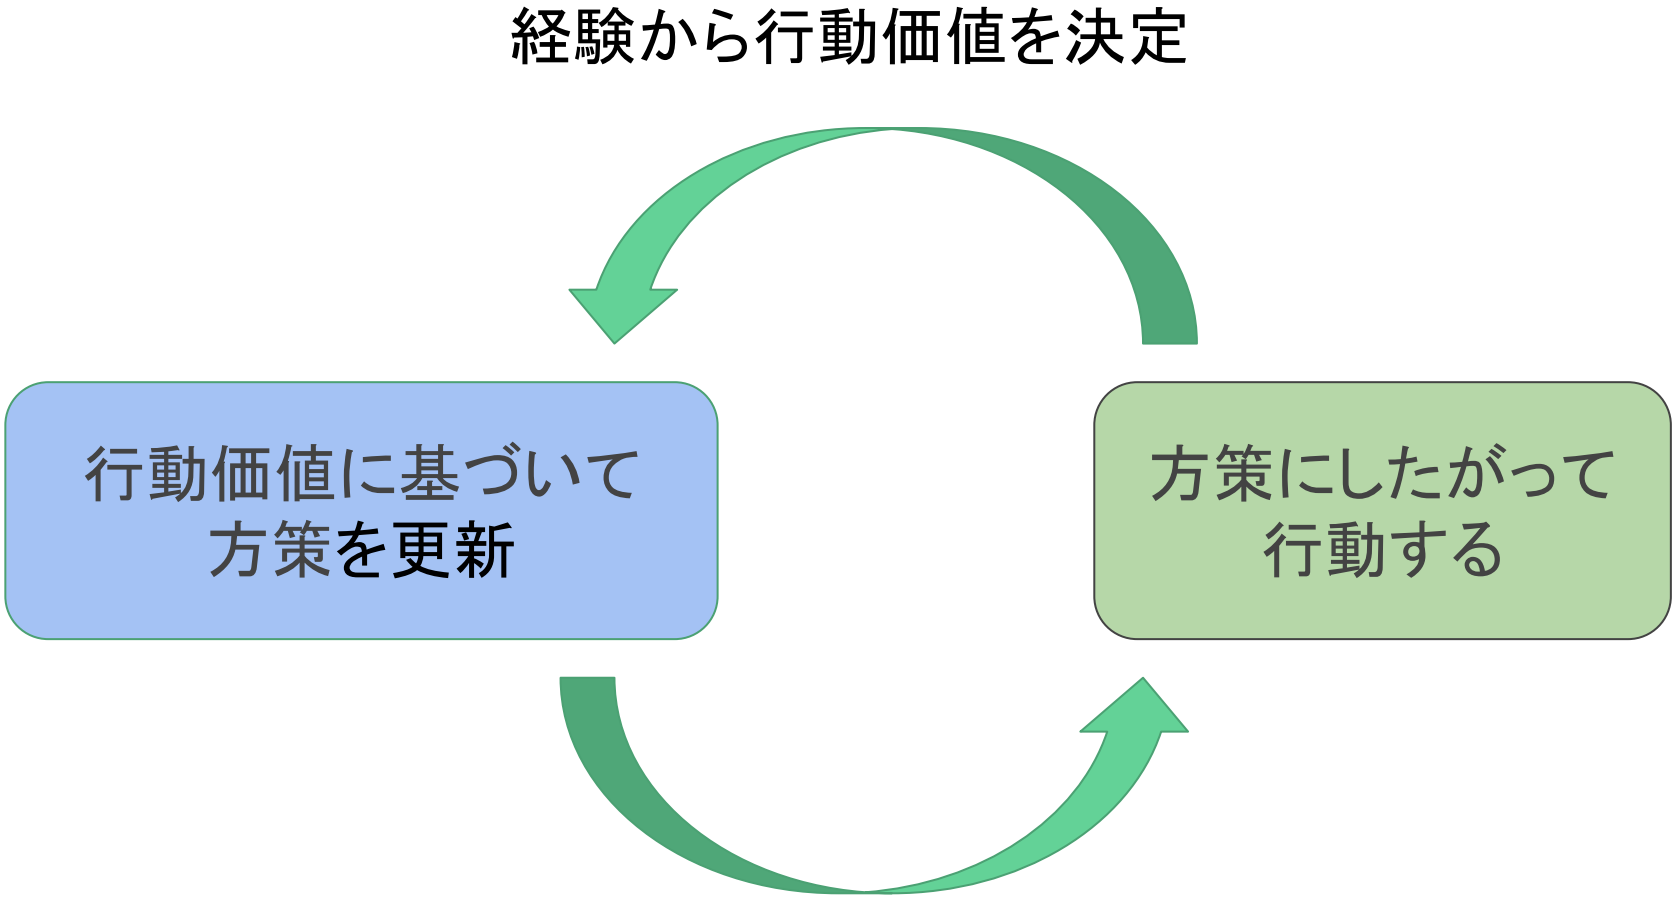

方策勾配の学習ステップ

- 方策πにしたがって行動

方策は**確率的**に表される。例えばsoftmax関数など。

$$\pi_\theta(a|s) = \frac{exp(\theta_{sa})}{\sum_{b \in A} exp(\theta_{sb})}$$

- 方策πの評価

上の行動で得られた**収益（または平均報酬）**で目的関数を定義

$$J(\theta) = \mathbb{E}\{\sum_{t=1}^{\infty} \gamma^{t-1} r_t | s_0, \theta\}$$

- 方策πの更新

目的関数を最大化するように**勾配法**で方策を更新

方策ベースの学習フロー

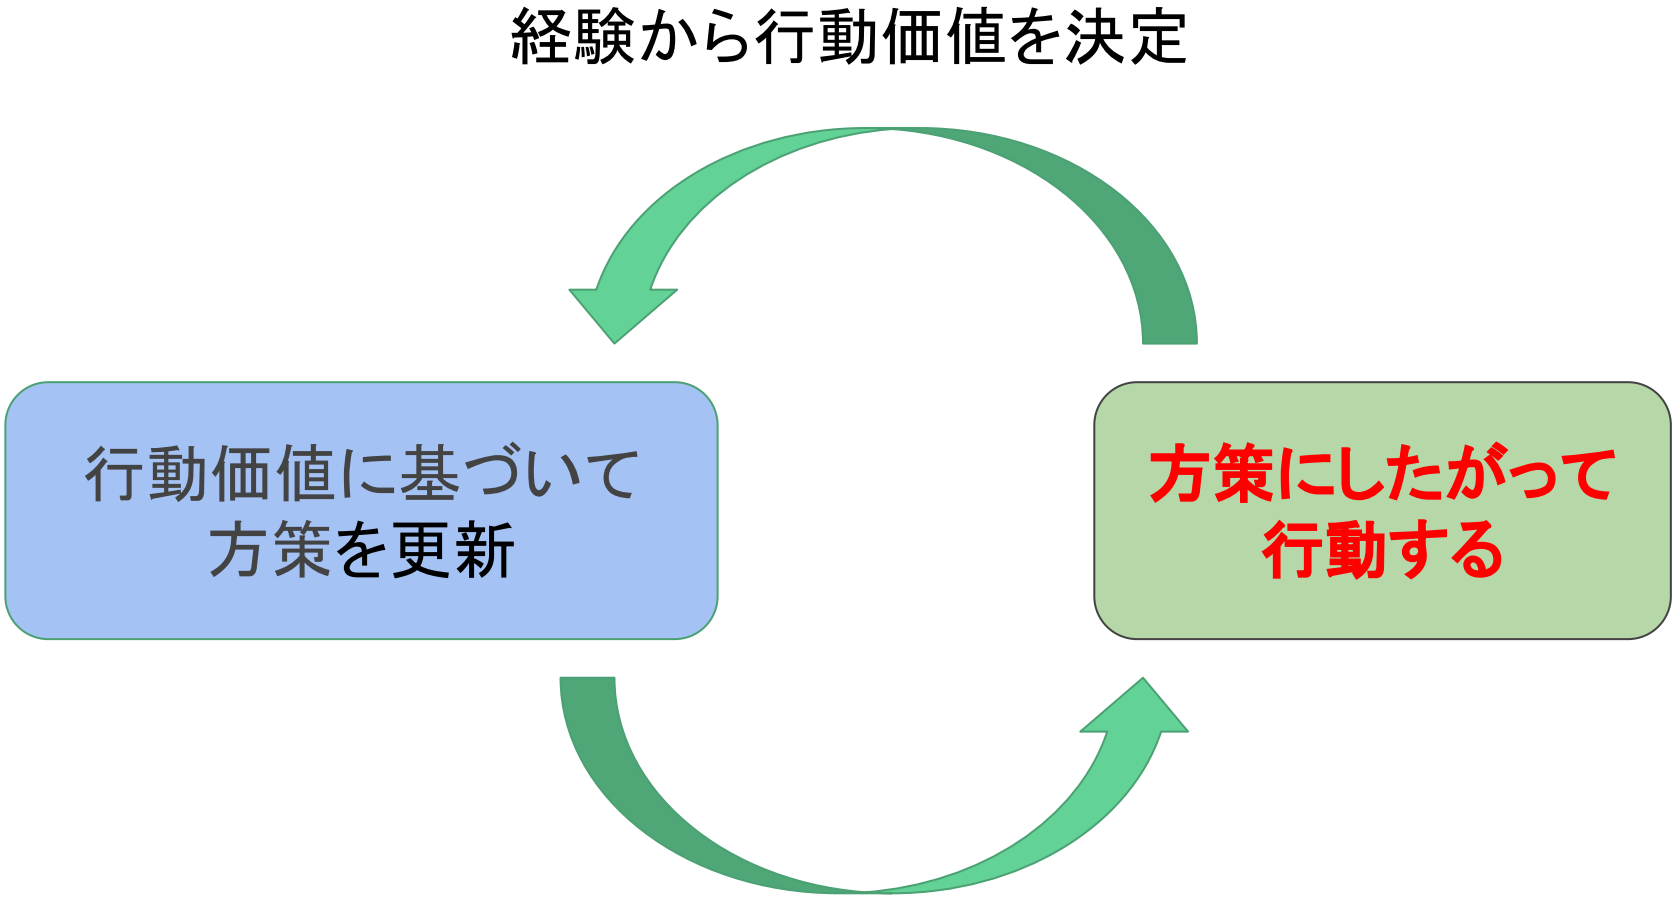

方策の決定

方策πは各行動の選択確率を表す確率関数である

- **行動が離散的な場合**

ソフトマックス関数などで確率分布を表す

$$\pi_\theta(a|s) = \frac{exp(\theta_{sa})}{\sum_{b \in A} exp(\theta_{sb})}$$

- **行動が連続的な場合**

正規分布などの確率分布で表す。この場合はW,Cをパラメタライズ

$$\pi_\theta(a|s) = \frac{1}{(2\pi)^{d_a/2}|C|^{1/2}} \exp(-\frac{1}{2}(a - Ws)^T C^{-1}(a - Ws))$$

行動の次元数　　共分散行列　　行動の次元数×状態の次元数の行列

方策ベースの学習フロー

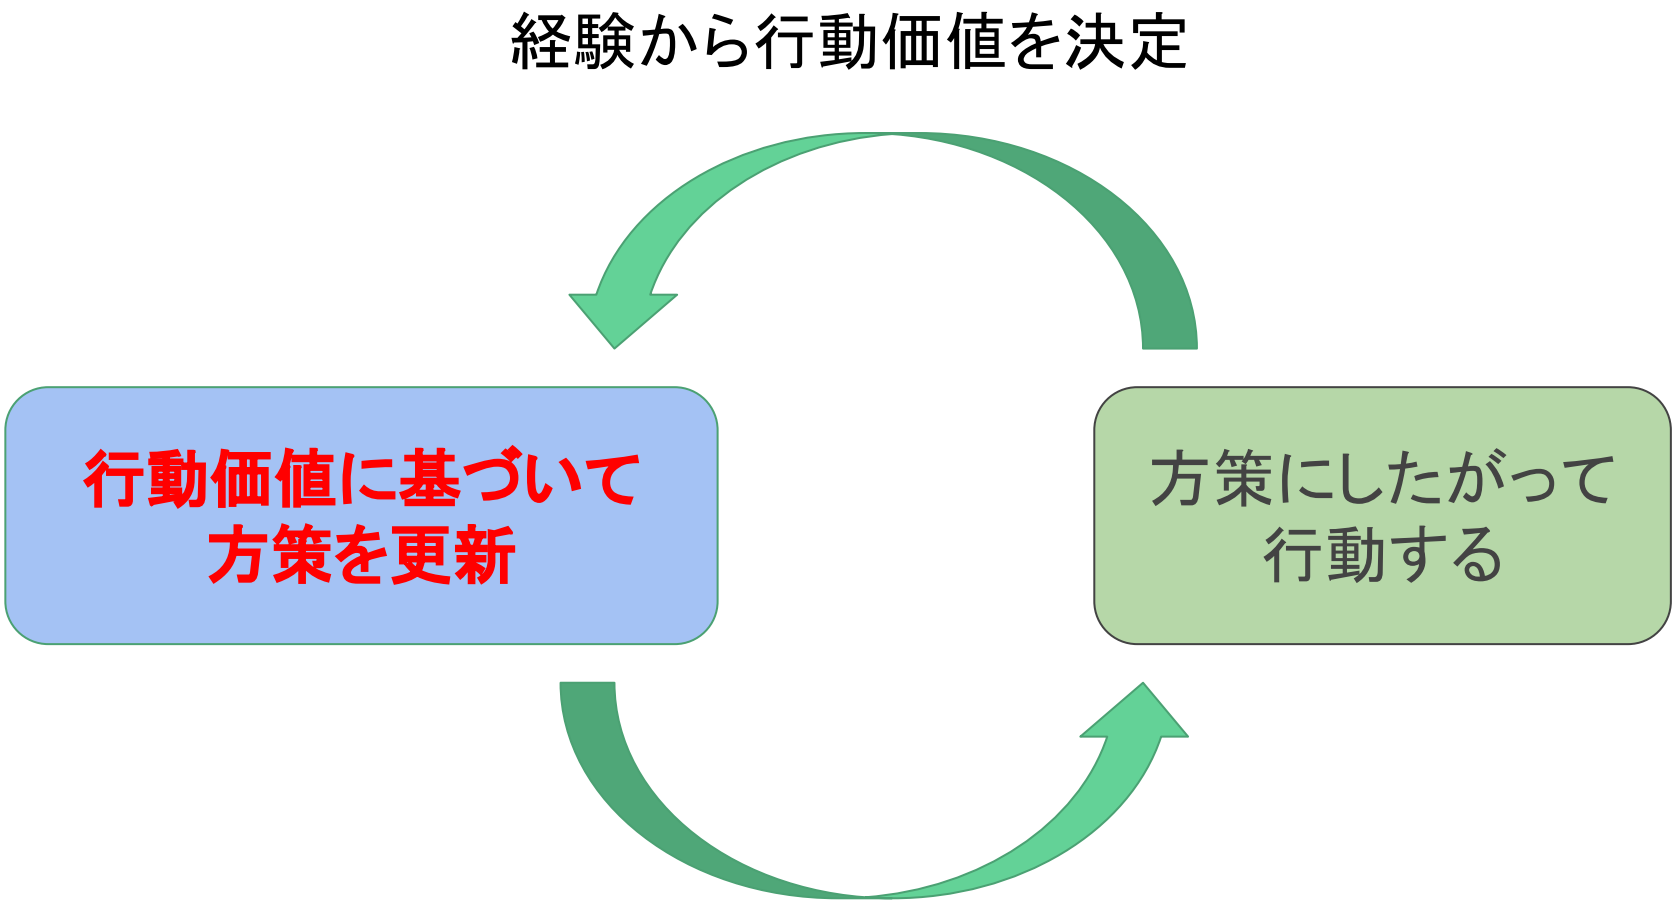

方策勾配定理

勾配を行動価値関数Q^{π}を用いて以下のように表せる

$$Q^{\pi}(s,a) = \mathbb{E}[\sum_{k=1}^{\infty} \gamma^{k-1} r_{t+k} | s_t, a_t, \theta]$$

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{\pi\theta}[\frac{\partial \pi_{\theta}(a|s)}{\partial \theta} \frac{1}{\pi_{\theta}(a|s)} Q^{\pi}(s,a)]$$

$$= \mathbb{E}_{\pi\theta}[\nabla_{\theta} \log \pi_{\theta}(a|s) Q^{\pi}(s,a)]$$

これが方策勾配定理である

方策ベースの学習フロー

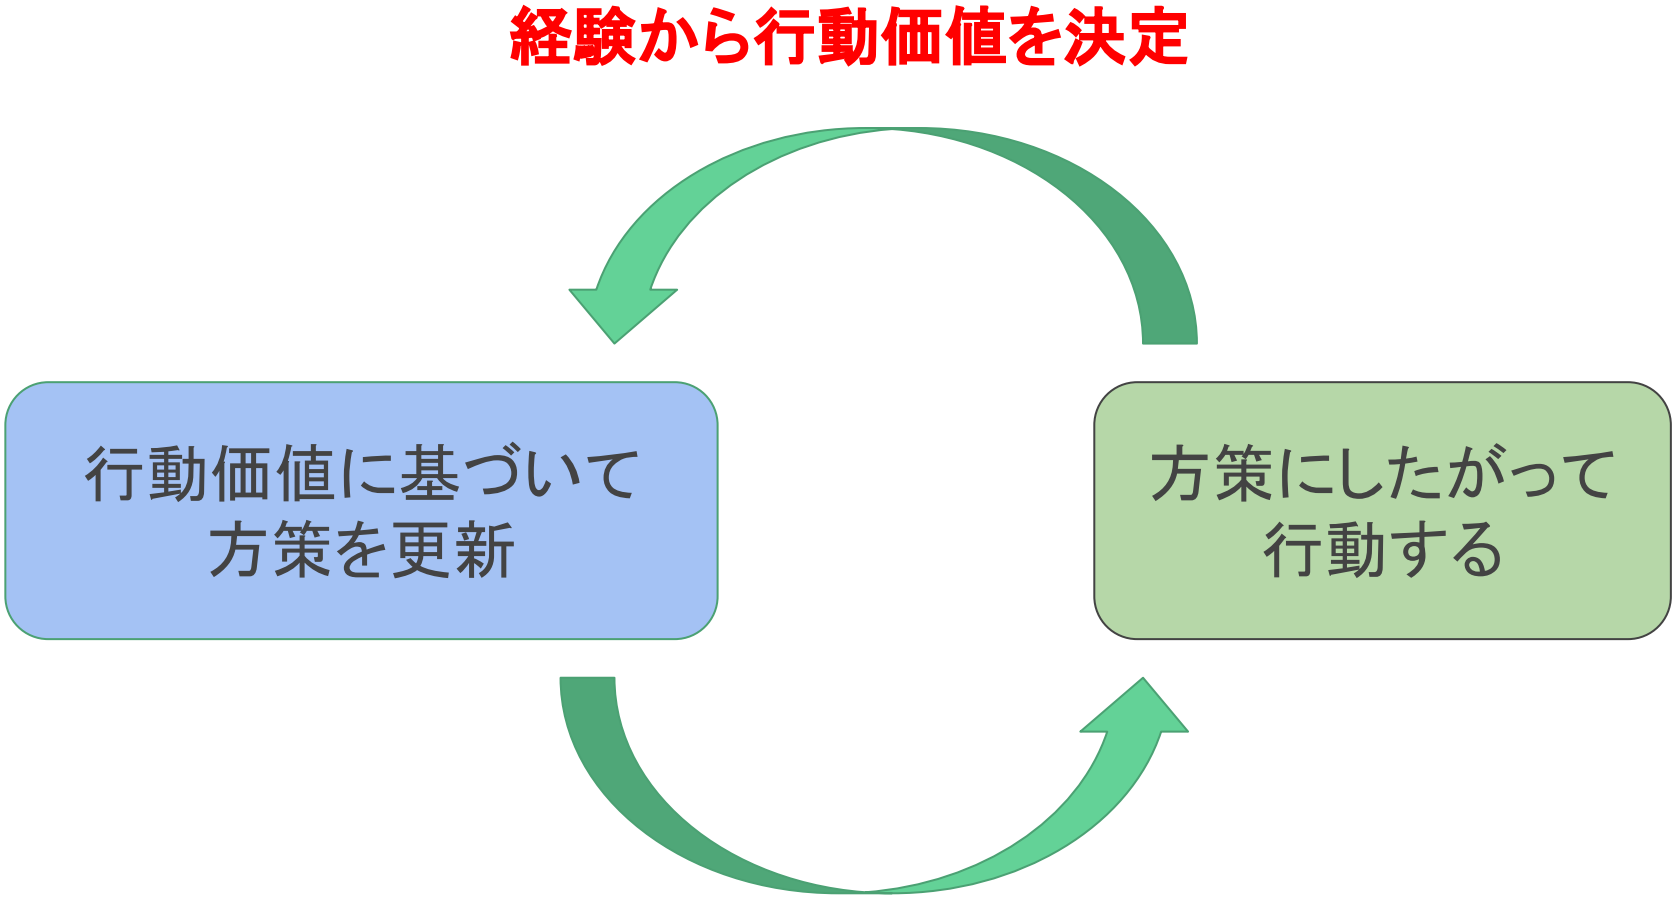

行動価値の決定方法

実際には行動価値関数は未知である

$$\nabla_\theta J(\theta) = \mathbb{E}_{\pi\theta}[\nabla_\theta \log \pi_\theta(a|s) Q^\pi(s,a)]$$

行動価値関数を推定して学習を行う2つの手法を紹介する

- **REINFORCE**
- **Actor-Critic**

REINFORCE

行動価値関数を**即時報酬**で近似する

$$\nabla_\theta J(\theta) = \mathbb{E}_{\pi\theta}[\nabla_\theta \log \pi_\theta(a|s)(r_t - b)]$$

分散を抑えるための定数

方策が確率的なので、ベースラインで**分散を抑える必要がある**

主にベースラインには平均報酬が使われる

$$b = \frac{1}{MT} \sum_{m=1}^{M} \sum_{t=1}^{T} r_{t,m}$$

エピソード数

ベースラインを含めてもいい理由

$$\mathbb{E}[b\nabla_\theta \log \pi(a|s)] = b\sum_a \frac{\partial \pi(a|s)}{\partial \theta}$$

$$= b\frac{\partial}{\partial \theta}\sum_a \pi(a|s)$$

期待値には影響を与えない

$$= b\frac{\partial}{\partial \theta}1 = 0$$

REINFORCEの弱点

$$\nabla_\theta J(\theta) = \mathbb{E}_{\pi\theta}[\nabla_\theta \log \pi_\theta(a|s)(r_t - b)]$$

即時報酬で近似しているので簡単に実装が可能

しかし、即時報酬だけだと**遅れて発生する報酬**を扱えない

Actor-Critic

方策関数と価値関数を**別々**に求める

$$\nabla_\theta J(\theta) = \mathbb{E}_{\pi\theta}[\nabla_\theta \log \pi_\theta(a|s)(Q^\pi(s,a) - V^\pi(s))]$$

$$= \mathbb{E}_{\pi\theta}[\nabla_\theta \log \pi_\theta(a|s)(R_t - V^\pi(s))]$$

行動選択を行う**Actor**と価値を推定する**Critic**で構成される

Actor: Criticの推定する価値より高くなる行動を学習

Critic: Actorの経験から価値を正確に推定するように学習

Actor-Criticの優れているところ

方策ベースと価値ベースのいいとこ取り

$$\nabla_\theta J(\theta) = \mathbb{E}_{\pi\theta}[\nabla_\theta \log \pi_\theta(a|s)(R_t - V^\pi(s))]$$

- **方策ベースのメリット**

ブートストラップ（推定値を使って更新）なしで学習ができる

- **価値ベースのメリット**

収益の推定を行うことで最適な方策を学習できるようにした

方策勾配

- **方策ベースの手法**

方策自体を確率分布として求めることで連続的な行動も扱える

- **方策勾配定理**

現在の方策で得られる**行動価値を最大化**するように勾配を計算して、
方策を更新する

- **行動価値の計算**
  - **REINFORCE**
    即時報酬で近似して、ベースラインで分散を下げる
  - **Actor-Critic**
    価値関数と方策を**別々のモデル**で学習して
    より最適な方策を学習できる

深層強化学習

目次

- **方策勾配法**

方策を直接求めるには

- **深層強化学習**

DNNによる強化学習によって何ができるようになったのか

- **内発的動機**

生物は環境からの報酬のみから学習しているのか

Arcade Learning Environment (ALE)

- **The Arcade Learning Environment: An Evaluation Platform for General Agents [Bellemare+ 2013]**

Atari 2600 という米アタリ社のゲーム機のエミュレータ

AI研究のためのフレームワーク

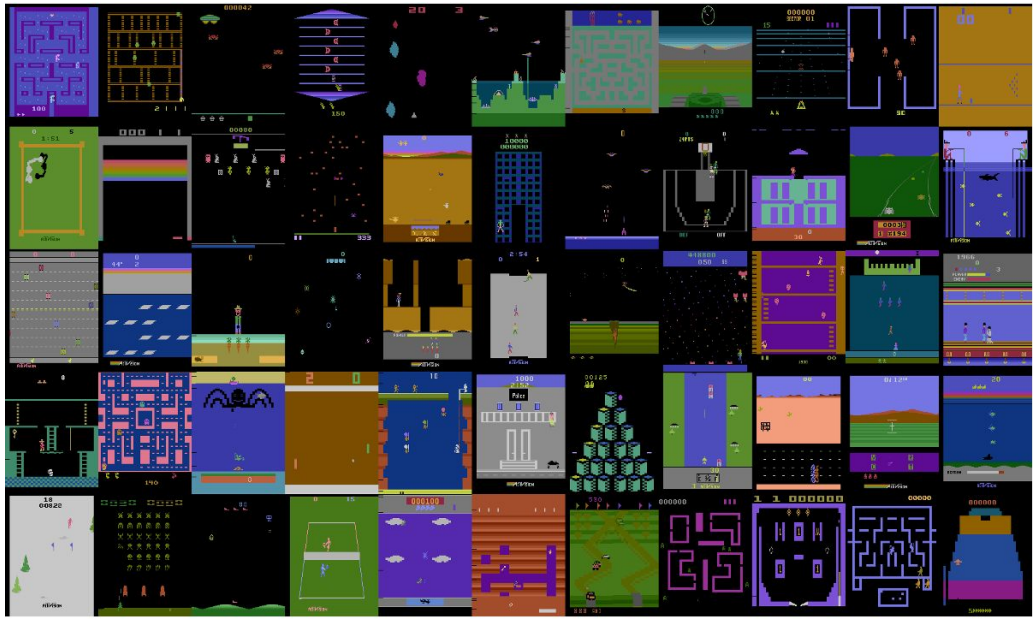

Atariのゲームの例

Pong

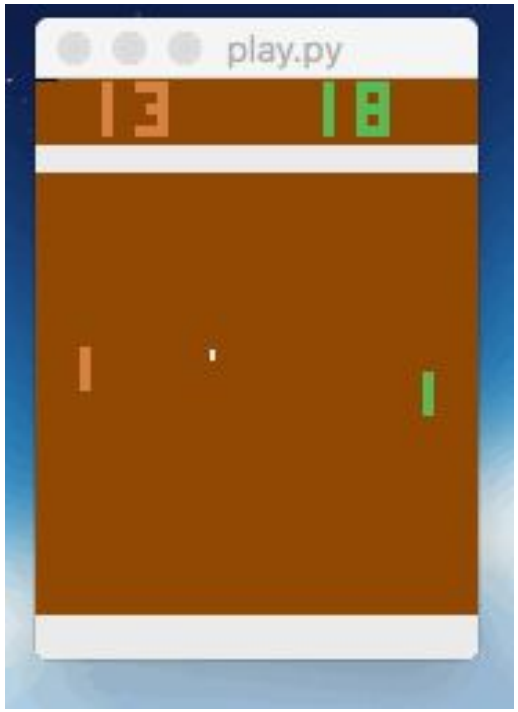

Breakout

Space Invaders

ALEにおける強化学習の設定

エージェントはエミュレータから**ゲーム画像**とスコアを

受け取り、エミュレータにゲームの操作を返す

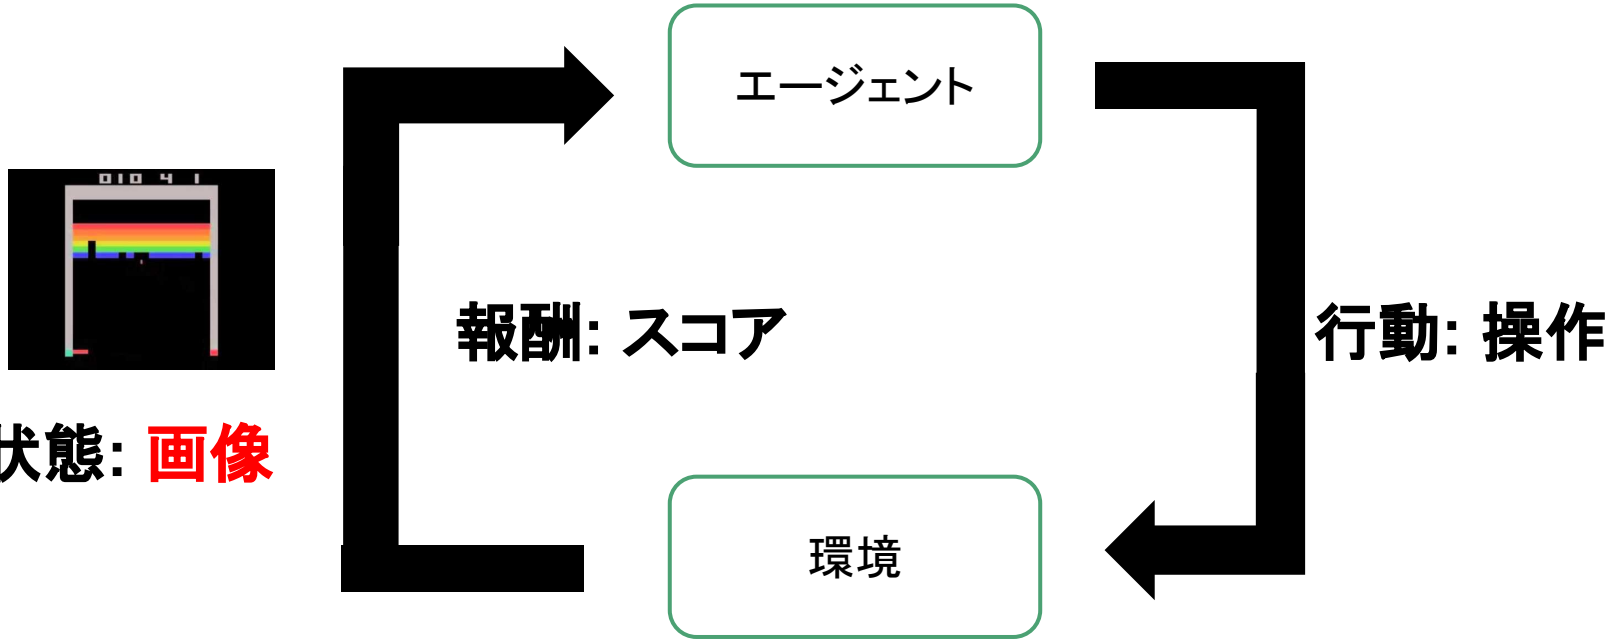

ALEが掲げていた課題

提供している様々なゲームに適応できるような手法の発明

敵の位置や自分の位置の情報など

ゲームに特有の特徴量を使わない

理想的な方法

直接ゲーム画像から価値（Q値）を推定する

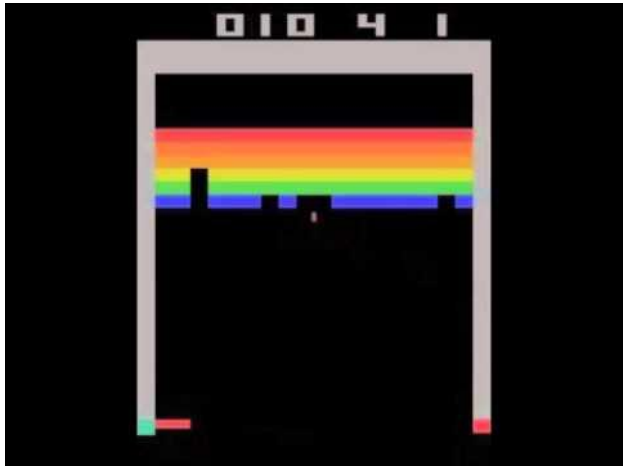

価値

テーブルでQ関数を表せないとき

入力状態は84x84の白黒画像

テーブルでQ関数を表すには256^{84x84}の状態の行が必要

Q関数をテーブルではなく関数で近似してみる

$$Q(s,a) \approx \theta_s^T \phi_s(s) + \theta_a^T \phi_a(a)$$

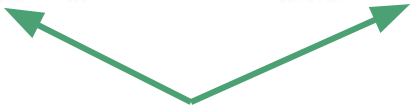

ベクトルを前処理する関数

線形関数で近似した結果

人間のスコアを以下のモデルと比較

- **Linear:** （前処理なし）画像から直接線形近似したモデル
- **HNeat:** （前処理あり）物体の位置が与えられているモデル

人間に勝てない...

	Breakout	B. Rider	Enduro	Sequest	S. Invaders
Human	31	**7456**	**368**	**28010**	**3690**
Linear*	3	2347	62	657	301
HNeat	**52**	3616	106	920	1720

*後述の工夫を行なって全結合層 1つで近似したモデル

どうすれば勝てるのか

ゲームに勝つために画像から直接

有用な特徴量を見つけることができれば勝てるはず

Deep Neural Network

DNNによる特徴抽出

層を重ねて、入力から推測までをend-to-endで学習すると
タスクに有用な特徴抽出ができる

人間が特徴量を設計する必要がなくなった

（画像ではCNNを使うのが一般的）

Deep learning

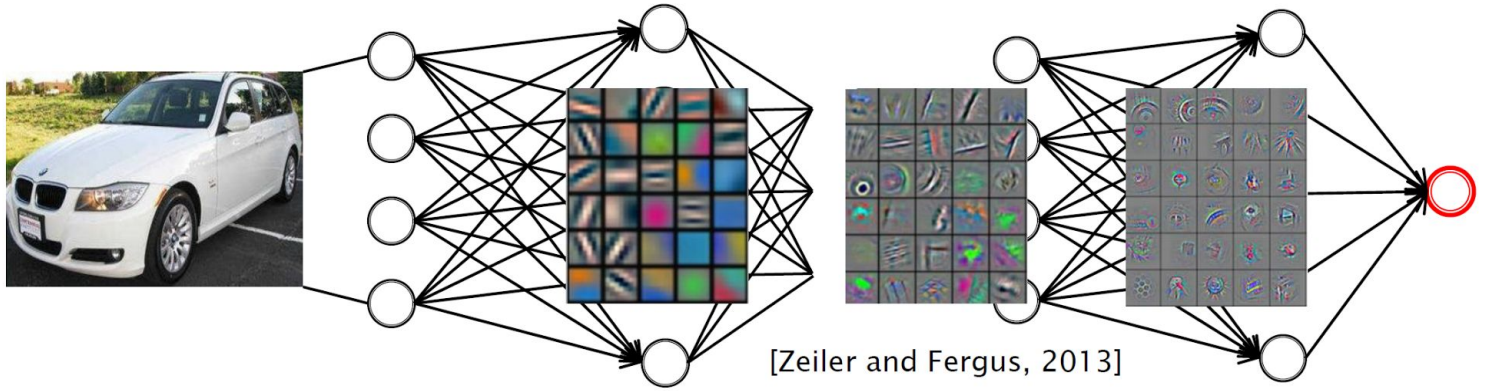

学習によって得られた特徴表現

https://www.slideshare.net/nlab_utokyo/deep-learning-49182466

DQN (Deep Q-Network)とは

- **Playing Atari with Deep Reinforcement Learning [Mnih+ 2013]**
- **Human-level control through deep reinforcement learning [Mnih+ 2015]**

Q関数を**DNNで近似**した

$$Q(s_t, a) \leftarrow Q(s_t, a) + \alpha \left[r_{t+1} + \gamma \max_p Q(s_{t+1}, p) - Q(s_t, a) \right]$$

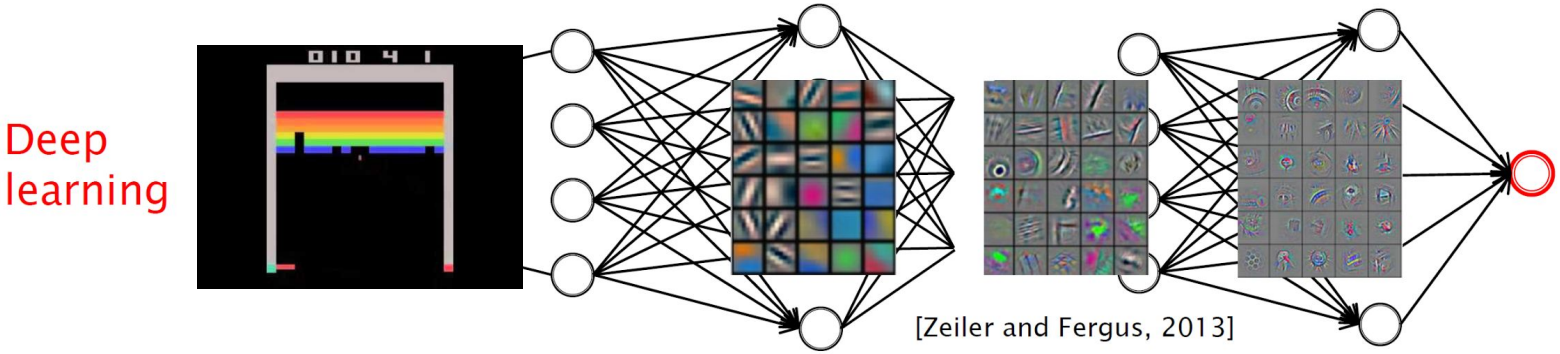

Q関数をDNNで表すとは

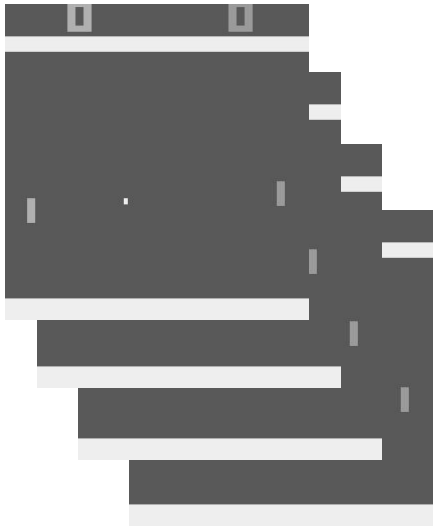

84x84の白黒ゲーム画像

行動a？

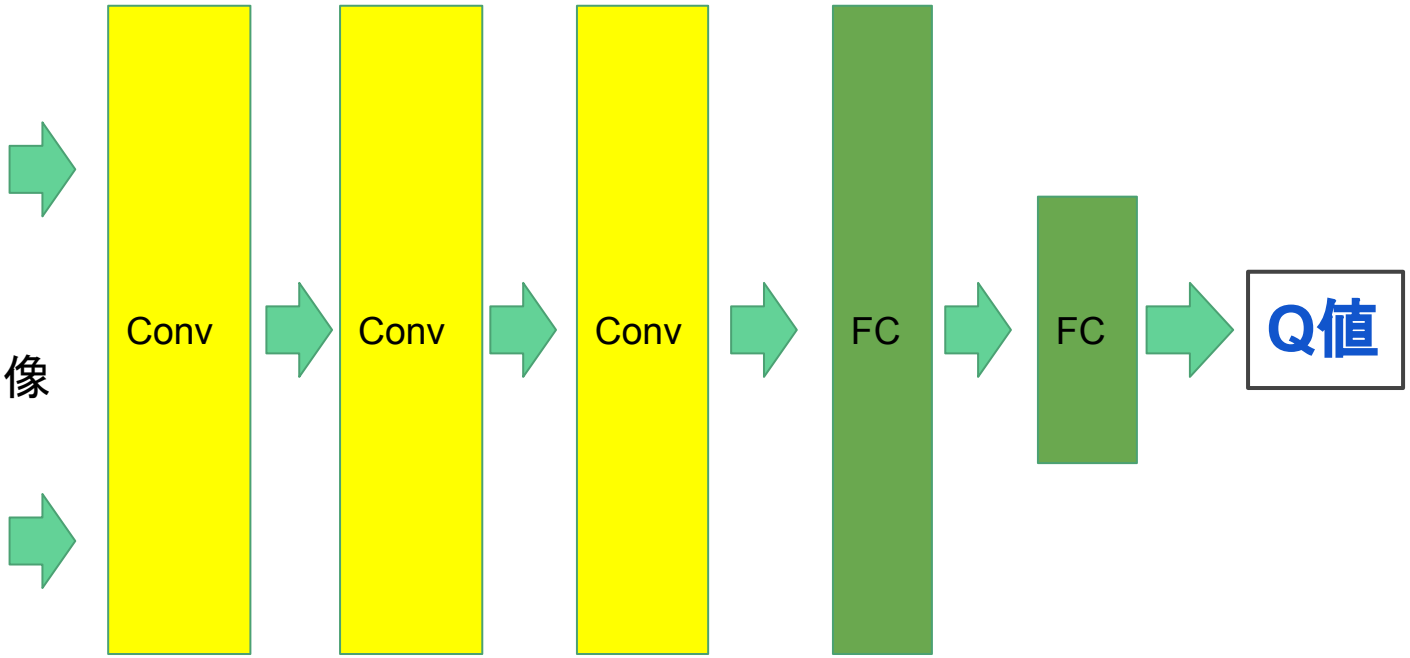

行動全てに対してこの計算をするのはコストがかかる

DQNのネットワーク構成

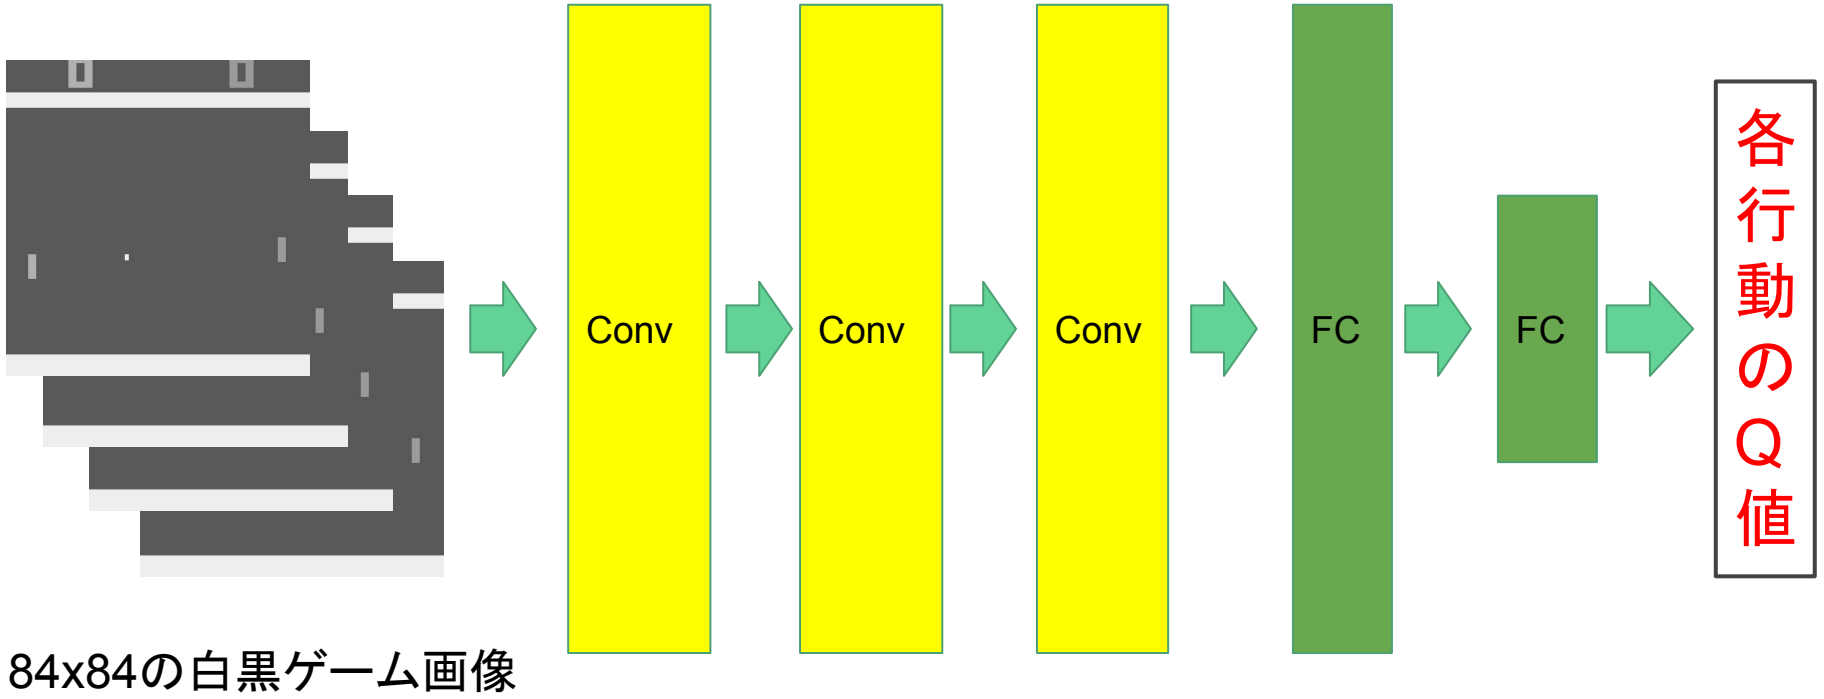

各行動に対してQ値を計算するよりも
一回の計算で全てのQ値を計算するように構成する

しかしQ関数をDNNにしただけだと...

さっきの線形モデルの手法に負けている....

	Breakout	R. Raid	Enduro	Sequest	S. Invaders
Naive DQN	**3.2**	1453.0	29.1	275.8	**302.0**
Linear	3.0	**2346.9**	**62.0**	**656.9**	301.3

DQNの工夫

DQNはQ関数を**ディープにしただけではない**

- **Experience Replay**
  - 保存した経験からランダムに学習に使用する
- **Freezing the Target Network**
  - TD誤差の目標値に古いネットワークを使用する
- **Clipping Rewards**
  - スコアのスケールを統一する
- **Skipping Frames**
  - 数フレームごとに行動を選択する

DQNの工夫: Experience Replay

Reinforcement Learning for Robots Using Neural Network [Lin+ 1993] で最初にExperience Replayが提案されている

- 経験の相関性が高いとNNが過学習してしまう

過去の経験をメモリーに溜めて
ランダムに経験を選んで学習に使用する

- 価値を前の状態に伝搬させるには多く学習する必要がある

経験をミニバッチで学習させることで加速！

- いい経験を一回しか使わないのは勿体無い

過去の経験を使いまわそう！

DQNの工夫: Experience Replay

昔経験したこと$e_t=(s_t, a_t, r_t, s_{t+1})$をメモリーに貯めて

ランダムに複数（n=32）選んで学習に使うことで

学習を**高速**且つ**安定させた**

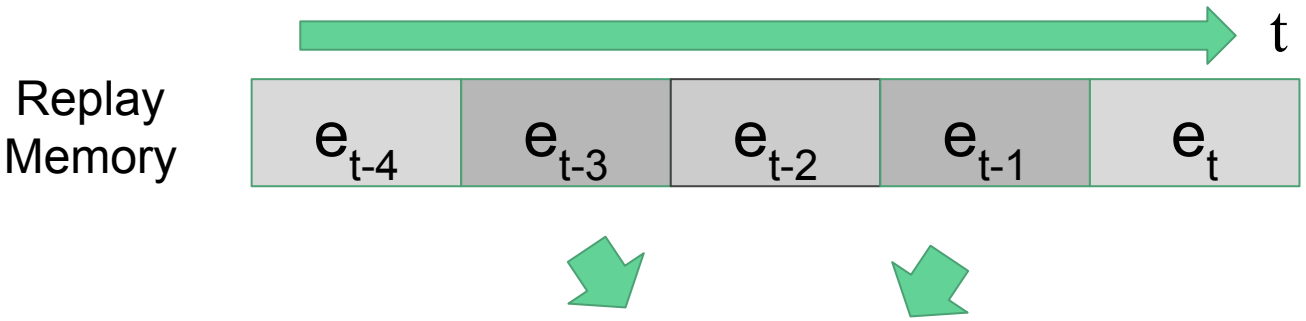

DQNの工夫: Freezing the Target Network

ここを古いDNNにする

$$Q(s_t, a) \leftarrow Q(s_t, a) + \alpha \left[r_{t+1} + \gamma \max_p Q(s_{t+1}, p) - Q(s_t, a) \right]$$

TD誤差の目標計算に予測値を使っている

目標値の変動に伴うDNNで表現されたQ関数の
学習不安定性を解消するために

- 誤差計算を行うときの目標のDNNを古いもので固定
- 一定周期（10000step毎）で現在のDNNと同期

DQNの工夫: Clipping Rewards

ゲームによってスコアの大きさが異なると
ハイパーパラメータを変える必要がある

学習率
割引率
などなど

例

- Pongでは一回点を取ると1点もらえる
- Space Invadersでは倒したインベーダの場所に応じて10~30点

様々なゲームに同じハイパーパラメータで対応するために、

- 負のスコアは-1
- 正のスコアは+1

で統一する

DQNの工夫: Skipping Frames

ALEは60fpsで描画されるが
必ずしも毎フレームで行動選択を行う必要がない

4フレーム毎に前の4フレームを使って行動選択を行う

4フレーム後まで同じ行動を繰り返し選択する
(Space Invaders では3フレーム)

行動選択のコストが減り、多くの経験を積むことができる

DQNと線形モデルの比較

ついに勝った…

	Breakout	R. Raid	Enduro	Sequest	S. Invaders
DQN	**316.8**	**7446.6**	**1006.3**	**2894.4**	**1088.9**
Naive DQN	3.2	1453.0	29.1	275.8	302.0
Linear	3.0	2346.9	62.0	656.9	301.3

Experience ReplayとTarget networkの影響

Experience Replay がスコアの向上にもっとも寄与していた

Replay	○	○	×	×
Target	○	×	○	×
Breakout	**316.8**	240.7	10.2	3.2
River Raid	**7446.6**	4102.8	2867.7	1453.0
Seaquest	**2894.4**	822.6	1003.0	275.8
Space Invaders	**1088.9**	826.3	373.2	302.0

Atari 2600 のゲームで学習した結果を人間のスコアと比較

人間より何%高いスコアが取れているかを示している

人間のプレイヤーは熟練者で

- 効果音なし
- それぞれのゲームで2時間の練習後、20エピソードの平均値

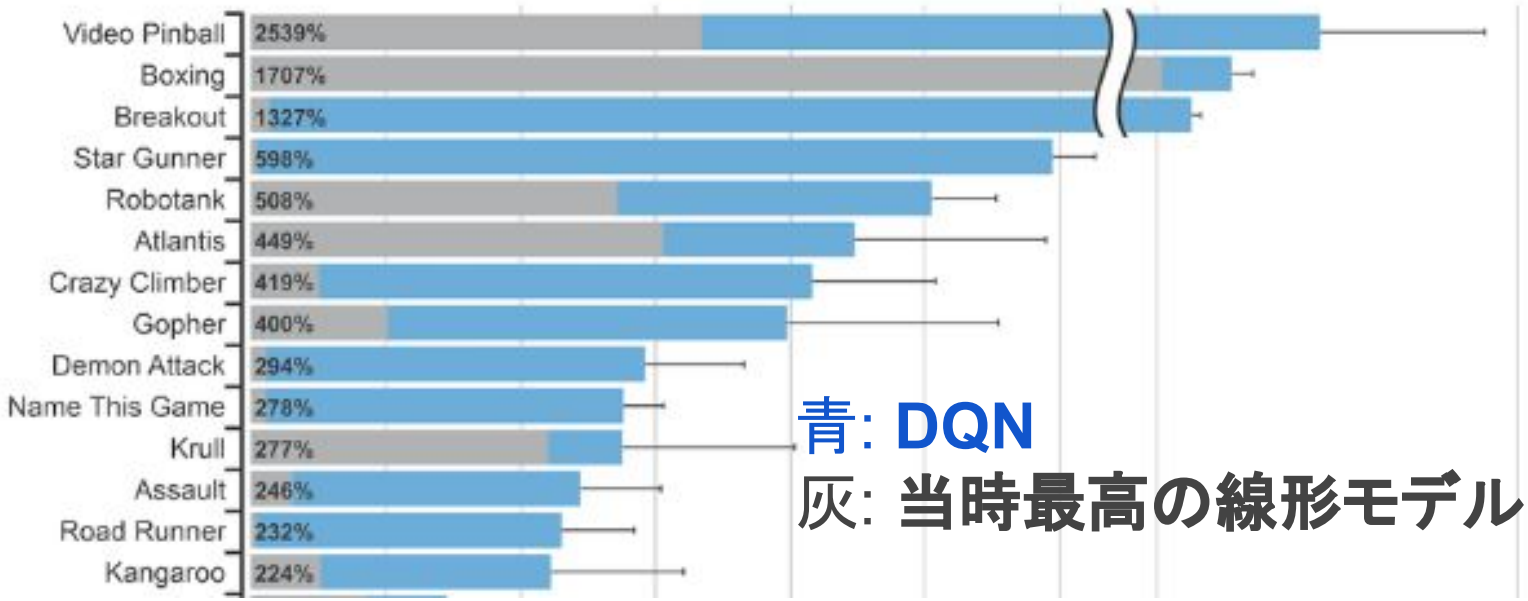

特徴量を設計しなくても

人間より高いスコアが取れるようになった

ただし全てのゲームで勝ってはない

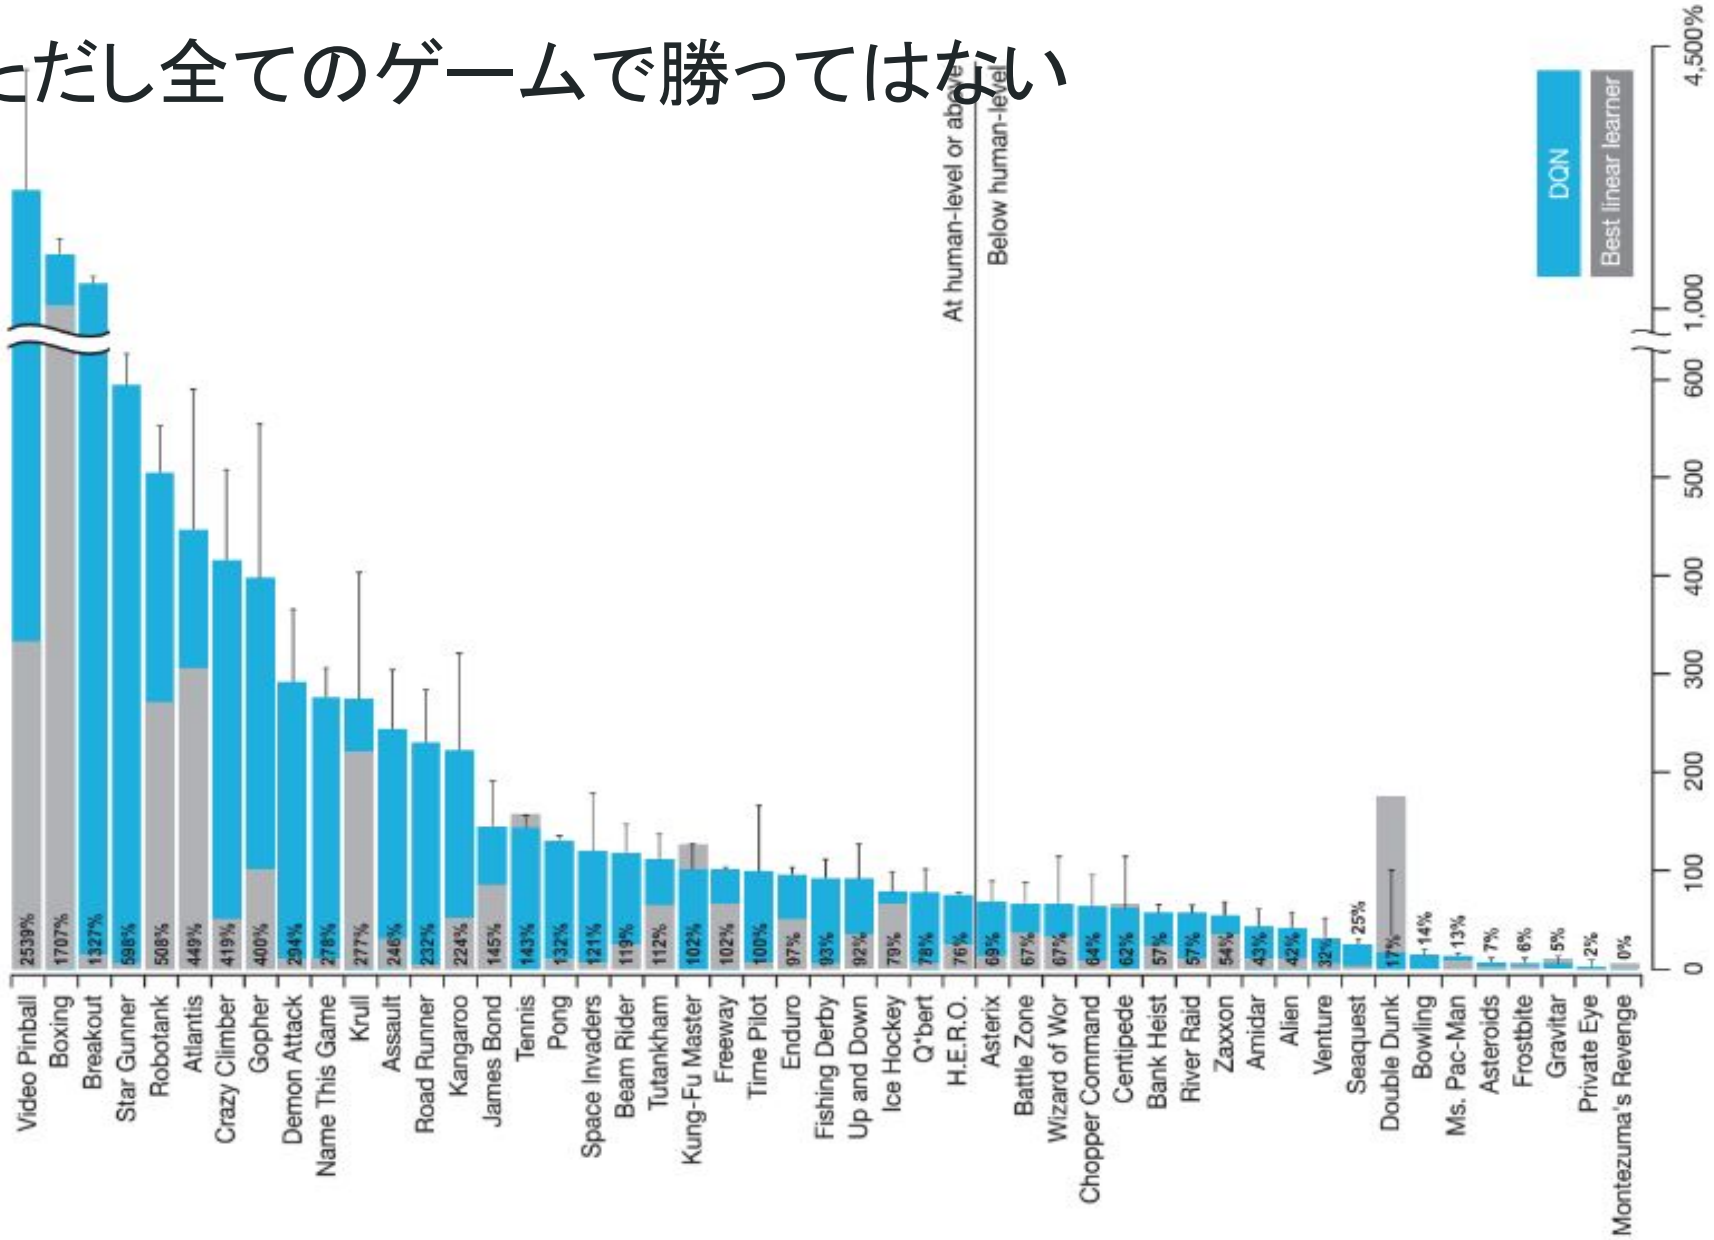

Experience Replay と脳の関係

- 課題後、ノンレム睡眠中のラットCA1領域の**場所細胞の発火率**が上昇することが確認された [Pavlides+]
- さらに、課題中の場所細胞の活動とノンレム睡眠中の場所細胞の活動に**相関がある**ことがわかった [Wilson+]

メモリーリプレイが動物の脳内で行われている

しかし場所細胞の発火は時間順序を保って発火しており
DQNの Experience Replay とは異なる

深層強化学習: まとめ

- **DNNの導入**

DNNで価値関数を表現することで、高次元の入力から直接価値の推定まで**end-to-end**でできるようになった

- **DQNの工夫**
  - **Experience Replay**
    経験を保存してミニバッチで学習することで過学習を避ける
  - **Target Network**
    TD誤差のターゲットの計算に以前のDNNを固定して用いる
  - **Frame Skipping**
    複数フレーム毎に行動選択を行うことでより多くの経験を集める
  - **Clipping Reward**
    報酬のスケールを統一する

内発的動機

目次

- **方策勾配法**

方策を直接求めるには

- **深層強化学習**

DNNによる強化学習によって何ができるようになったのか

- **内発的動機**

生物は環境からの報酬のみから学習しているのか

内発的動機

人間は**環境からの報酬だけ**で学習しているだろうか？

例えば趣味は外の環境の報酬を最大化するためにやっている？

自分自身の**内発的動機**を満足させるためにやっている

intrinsic motivation

内発的動機と外発的動機

心理学的に以下のように定義できる [Rynan+]

- **内発的動機**

行為それ自身が**本質的にもつ楽しみや満足**のための
動機、興味、挑戦など

e.g. 宿題が面白いからやる

- **外発的動機**

行為自身とは**別の結果を得ることが目的**の
行為をとり続ける動機、操作的価値

e.g. 宿題を親から怒られないためにやる

内発的動機付けするものは何か

かなり古くから議論がなされている

- **最適不一致理論**

知覚と刺激の差異が興味ある対象
最も報酬があるのは、新規性が半ば、すなわち既知と完全な新規の間である

- **有能さと自己決定のための動機付け**

自分の能力を最大限に発揮できる自体を追求する行動や自身の
能力を向上させようとする行動を駆り立てる源

新規性や驚きが内発的動機に繋がる

内発的動機と大脳基底核

新規事象が上丘を活性化し
ドーパミンのバーストが発生する

このドーパミンが大脳基底核の
以下の情報を想起させる

- **新規事象を引き起こした行動**
- **新規事象のコンテキスト**

繰り返し発生すると上丘は
活性化しなくなる

新しいスキルの学習

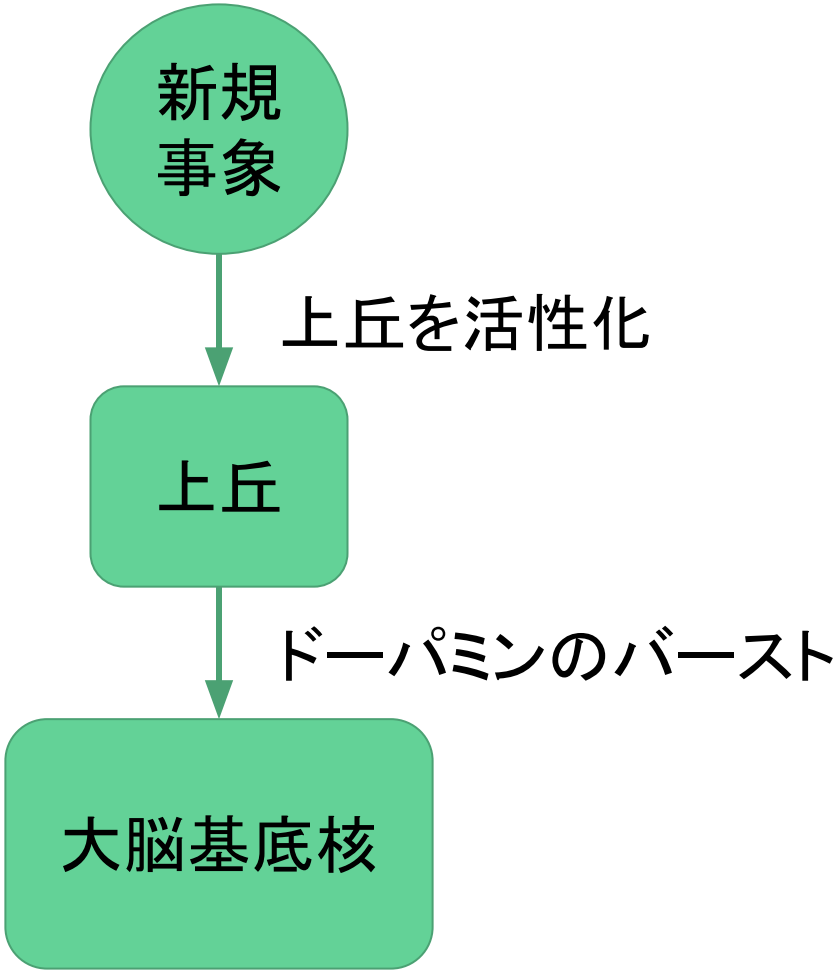

内発的動機を考慮したアーキテクチャ

Hierarchical Deep Reinforcement Learning: Integrating Temporal Abstraction and Intrinsic Motivation [Kulkarni+ 2016]

階層的な構成でサブゴールを達成するように学習する手法

階層的な3つのモジュールからなっている

- Meta Controller: サブゴールを識別する学習器
- Controller: 状態とサブゴールから行動を選択する学習器
- Critic: 行動がサブゴールを達成しているか識別する学習器

Criticは**内発的動機**を発生させて、**Controller**がそれを満足させる

しかし、新規事象などは考慮していない

モジュール構成

- **Meta-Controller: s → g**

状態からサブゴールを選択
環境からの報酬を最大化

- **Contoller: s, g → a**

状態とサブゴールから行動を選択
Criticからの報酬を最大化

- **Critic: s, a, s' → r**

サブゴールを達成できていれば
Controllerに内部報酬を与える

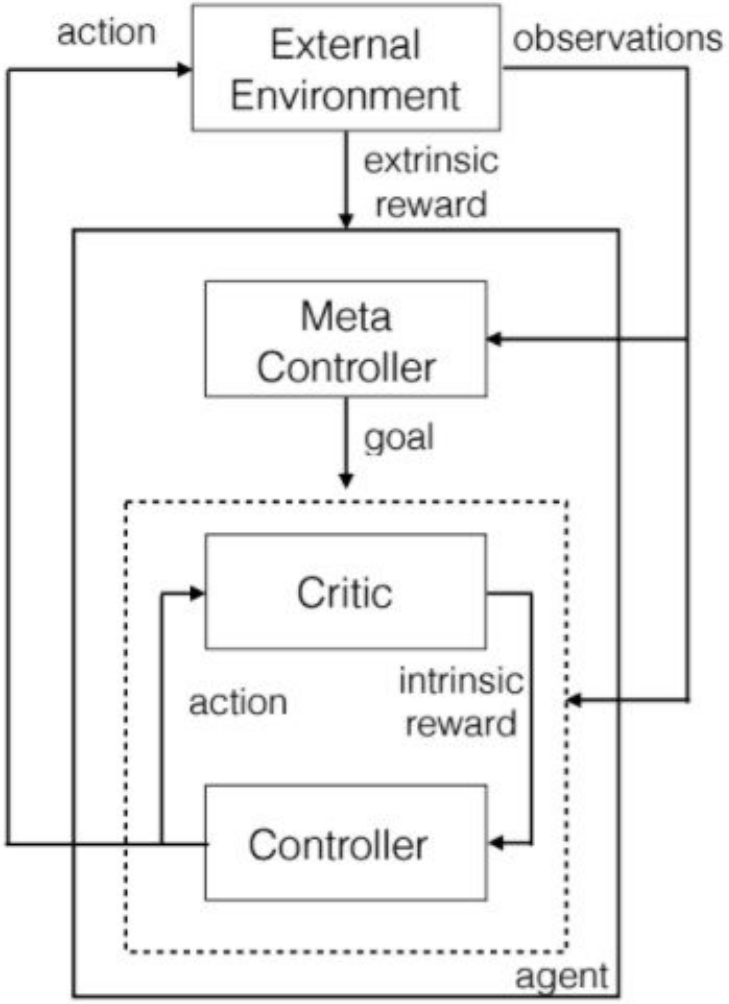

Curiosityを強化学習に導入する

A Possiblity for Implementing Curiosity and Boredom in Model-Building Neural Controllers [Schmidhuber 1991]

オンラインモデルベース強化学習において好奇心を導入する
コンセプトを提案している

Curiosityとは環境のモデルを改善したいという動機である

環境モデルによる推定と実際の観測の差から

- **誤差の大きい状態**: 正の内部報酬を与える
- **誤差の小さい状態**: 少ない正の内部報酬を与える

飽きるまで（誤差がなくなるまで）探索することで
環境のモデルを改善できる

最新のCuriosity

Curiosity-driven Exloration by Self-supervised Prediction [Pathak+ 2017]

次のフレームの表現を推測して、実際のフレームの表現との差分を好奇心として内部報酬を発生させる手法

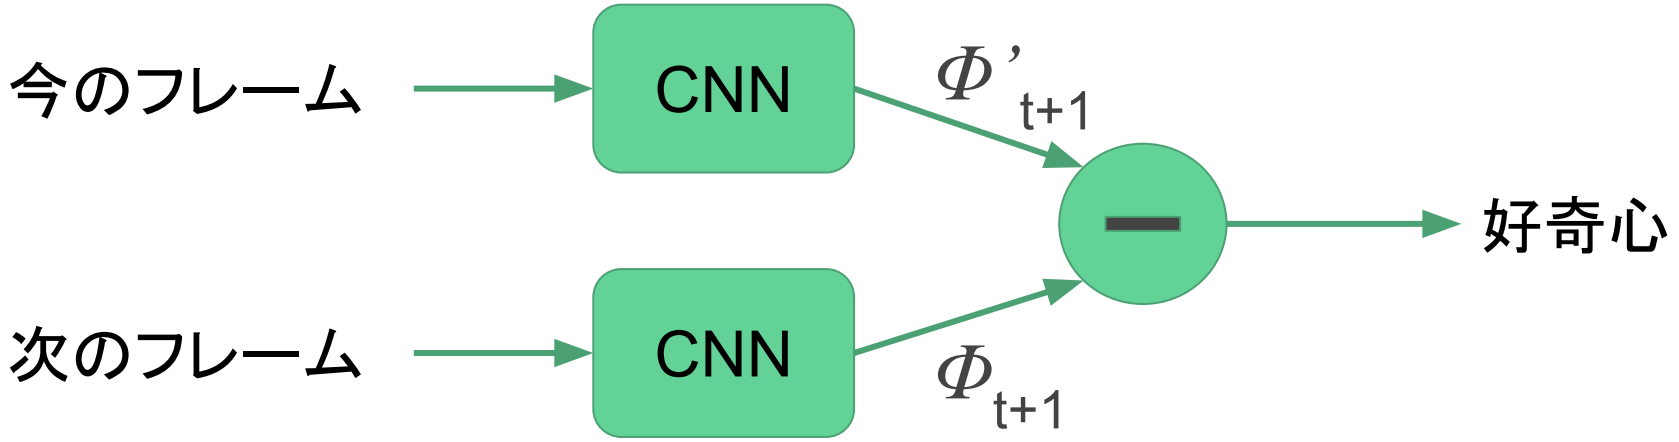

外部報酬一切なしで効率的な探索が行えるようになった

学習モデル

方策と別に以下の二つのものを一緒に学習して内部報酬を計算

- 逆モデル: s_tとs_{t+1}からa_tを推定
- 順モデル: a_tと上で得られる特徴量$\Phi(s_t)$から$\Phi(s_{t+1})$を推定

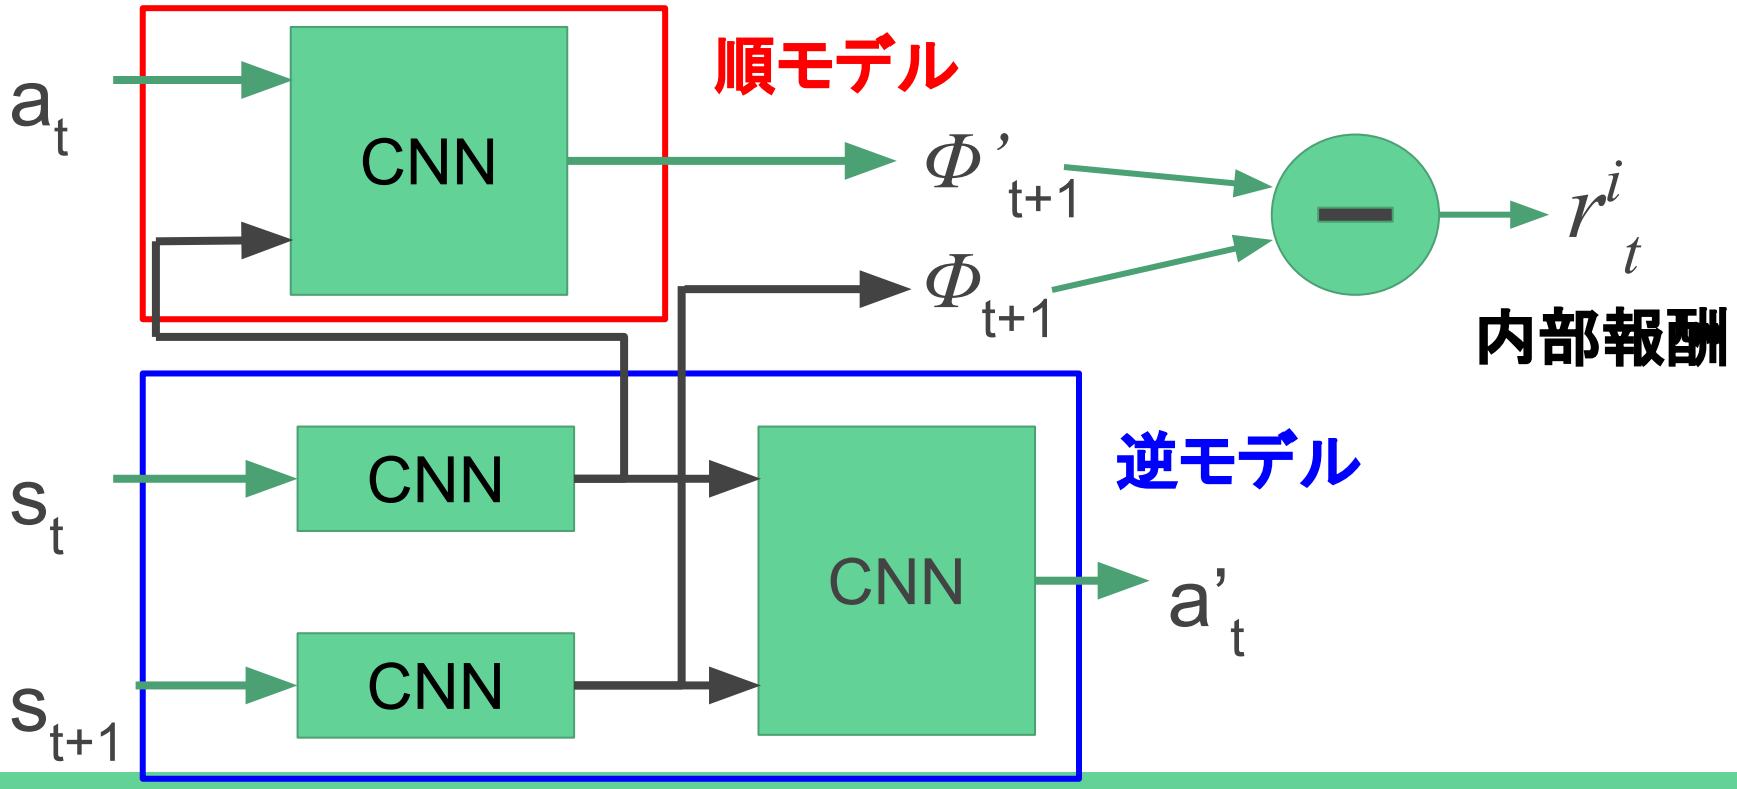

内部報酬の計算

$$r_t^i = \frac{\eta}{2}\|\hat{\phi}(s_{t+1}) - \phi(s_{t+1})\|_2^2$$

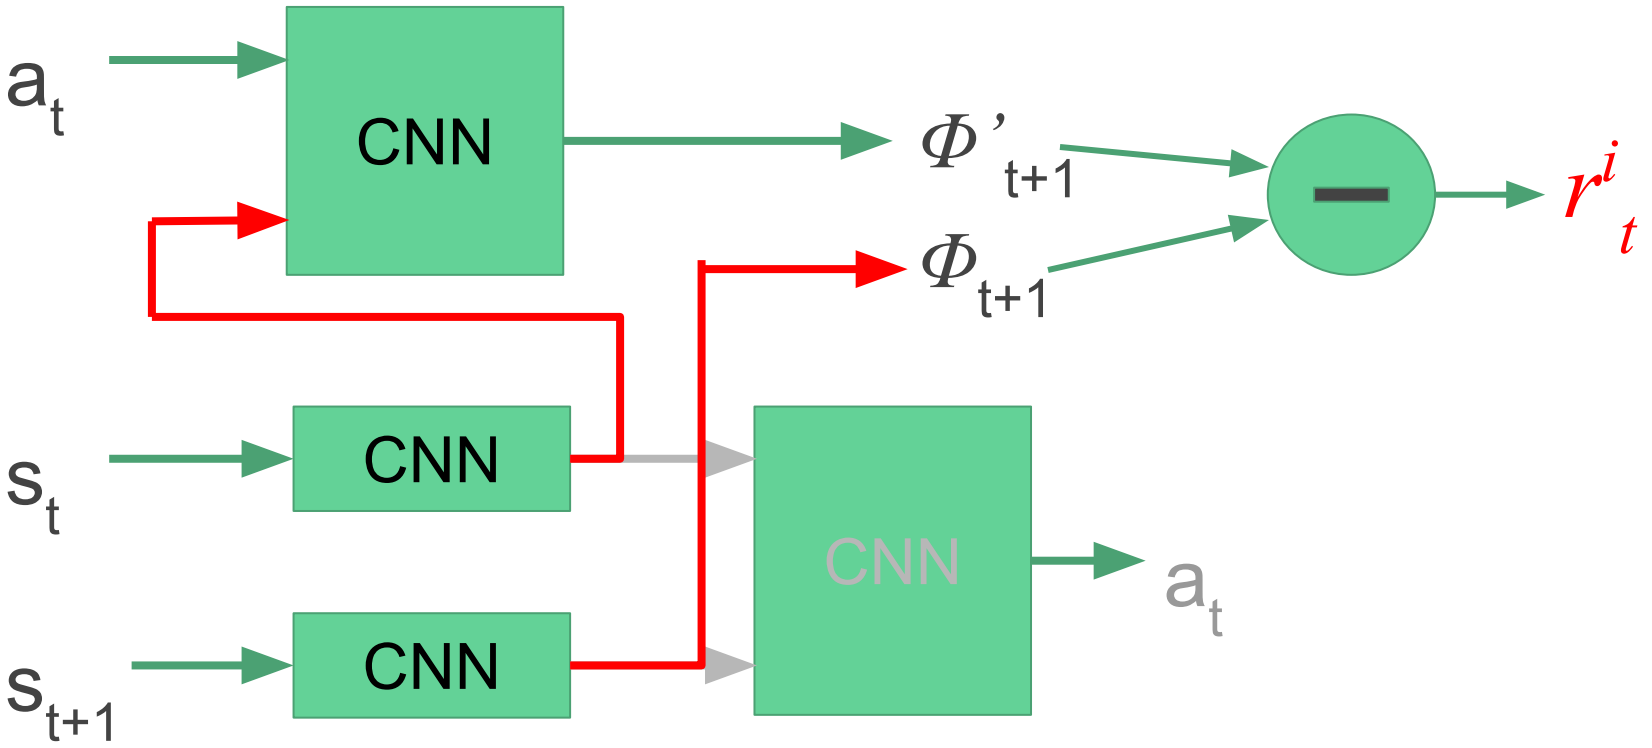

動画

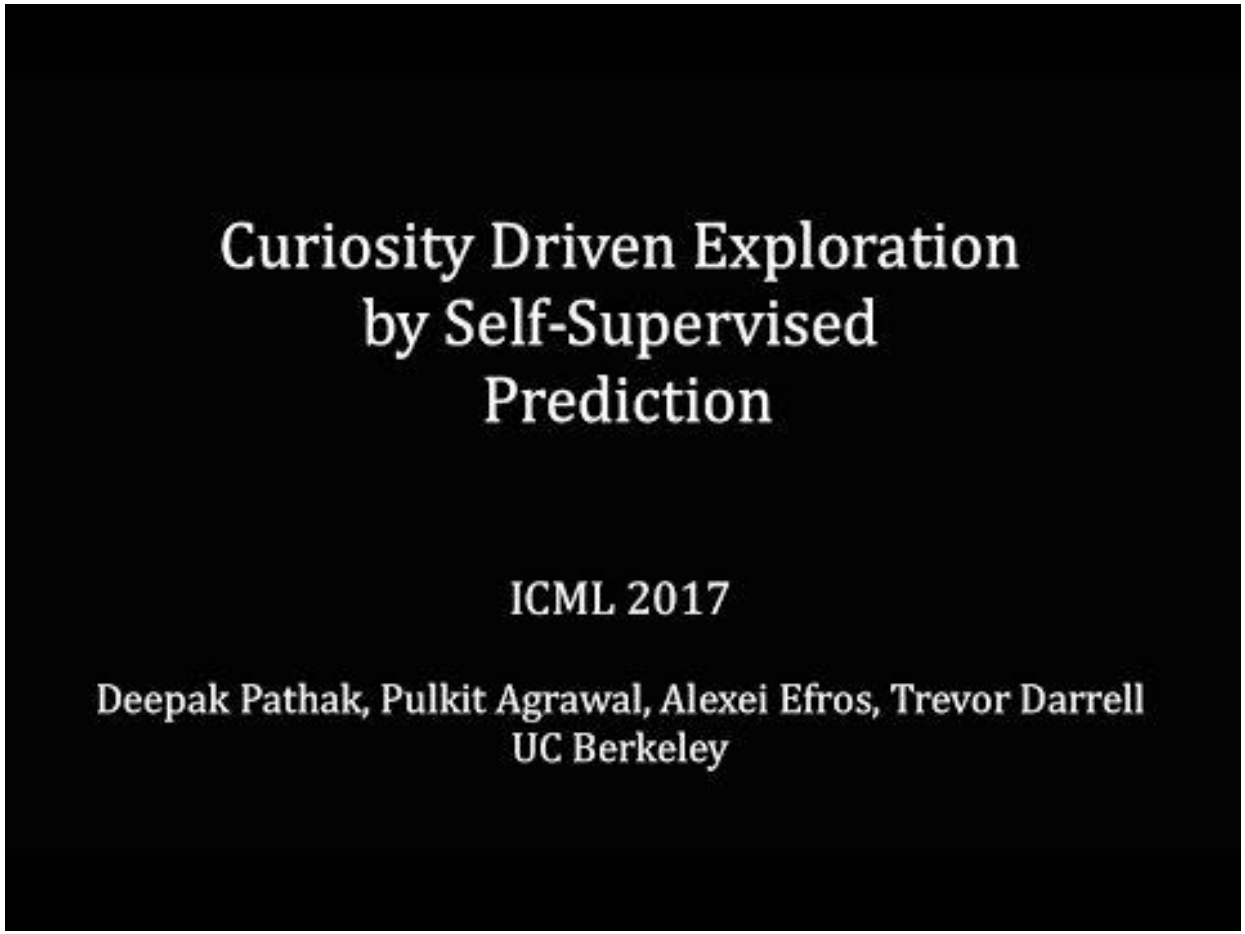

https://www.youtube.com/watch?v=J3FHOyhUn3A&t=35s

内発的動機: まとめ

- **内発的動機**

人間は外部からの報酬だけでなく、**新規性や驚き**に対して内発的動機を発生させて学習を行なっている

- **大脳基底核の新スキルの学習**

上丘が**新規事象**に対してドーパミンバーストを起こして大脳基底核の情報を想起できるようにしている

- **好奇心**

観測の推定と実際の観測の差が大きい状態に**好奇心**として
内部報酬を与えることで、外部の報酬に頼らない探索を行える